




DigiBot

Eine GenAI-Lösung für personalisierte Selbsteinschätzungstests

Bachelorthesis (BTI3041)

Studiengang:

BSc Computer Science

Autoren:

Christian Schmidhalter, Roman Schneiter

Betreuer:

Prof. Dr. Kenneth A. Ritley

Wissenschaftlicher Berater

Prof. Dr. Roman Rietsche

Auftraggeber:

Berner Fachhochschule

Experte:

Adrian Egli

Datum:

16. Januar 2025

Selbständigkeitserklärung

Ich bestätige mit meiner Unterschrift, dass ich meine vorliegende Bachelor-Thesis selbständig durchgeführt habe. Alle Informationsquellen (Fachliteratur, Besprechungen mit Fachleuten, usw.) und anderen Hilfsmittel, die wesentlich zu meiner Arbeit beigetragen haben, sind in meinem Arbeitsbericht im Anhang vollständig aufgeführt. Sämtliche Inhalte, die nicht von mir stammen, sind mit dem genauen Hinweis auf ihre Quelle gekennzeichnet.

Ort, Datum:
Biel, 16. 01. 2025

Unterschrift:



Christian Schmidhalter



Roman Schneiter

Abstract

Selbsteinschätzungstests sind essenziell für die berufliche Weiterentwicklung, stossen jedoch oft an Grenzen, da sie individuelle Bedürfnisse oft unzureichend berücksichtigen. Ziel dieser Arbeit ist es, persönliche Profile zu erstellen und zu untersuchen, inwiefern ein Large Language Model (LLM) auf Basis dieser Profile Fragen generieren kann, die individuell angepasst sind und tatsächlich hilfreich für eine Selbsteinschätzung sind.

In einer zunehmend digitalisierten Welt gewinnen Selbsteinschätzungstests an Bedeutung, um Kompetenzen und Fähigkeiten individuell zu evaluieren. Traditionelle Ansätze stossen häufig an Grenzen, da sie den spezifischen Bedürfnissen der Nutzer; innen nur unzureichend gerecht werden. Diese Bachelorthesis präsentiert das «DigiBot»-System, eine generative GenAi-Lösung, die personalisierte Selbseinschätzungstests auf Basis des Europäischen «DigComp»-Rahmenwerks ermöglicht. Mithilfe eines Chatbots und Large Language Models (LLMs) werden individuelle Benutzerprofile erstellt, welche die Grundlage für die Generierung massgeschneiderter Umfragen bilden.

Das Projekt verfolgt das Ziel, die Relevanz solcher Tests durch personalisierte Inhalte zu steigern und wissenschaftliche Daten zur Bewertung des Systems bereitzustellen. Die Ergebnisse aus Benutzerstudien und qualitativen Analysen zeigen, dass der Einsatz von generativer AI die Relevanz der generierten Tests erhöht, jedoch ähnlich gut bewertet wird wie die originalen Tests. Die Arbeit legt somit den Grundstein für innovative, auf den Benutzerkontext zugeschnittene Selbsteinschätzungslösungen.

Inhalt dieser Thesis

Diese Thesis dokumentiert die Entwicklung von «DigiBot», einer innovativen generativen GenAI-Lösung, die personalisierte Selbsteinschätzungstests auf Basis des europäischen DigComp-Rahmenwerks ermöglicht. Ziel ist es, die Qualität und Relevanz solcher Tests durch den Einsatz von Large Language Models (LLMs) wie GPT-4 zu verbessern und wissenschaftliche Erkenntnisse für zukünftige Forschung bereitzustellen.

Die Arbeit gliedert sich in mehrere zentralen Abschnitte, die einen strukturierten Überblick über die Problemstellung, Methodik, technische Umsetzung und die Evaluation der Ergebnisse bieten:

Im ersten Kapitel «Einleitung» wird die Relevanz von Selbsteinschätzungstests in einer digitalisierten Welt erläutert, sowie die Zielsetzung des Projekts und die definierten Erfolgskriterien vorgestellt.

Im zweiten Kapitel «Methodik und Organisation» wird die methodische Herangehensweise erläutert, die eine Kombination aus agilen Prinzipien und traditionellen Projektmanagementmethoden umfasst. Die Strukturierung des Projekts in Sprints, die Nutzung von Tools wie GitLab und die Organisation von Meetings werden beschrieben.

Das dritte Kapitel «Grundlagen» beschreibt die theoretischen Grundlagen des DigComp-Rahmenwerks, die Funktionsweise von LLMs sowie die eingesetzten Technologien wie FastAPI, Vue.js und PostgreSQL. Es wird dargestellt, wie die verschiedenen Komponenten miteinander interagieren, um eine benutzerfreundliche Plattform zu entwickeln.

Das vierte Kapitel «Journal» sowie die Einträge im Anhang dokumentieren den iterativen Entwicklungsprozess für jeden Sprint. Sie beschreiben experimentelle Ansätze, Herausforderungen und erzielte Ergebnisse. Ziel war es, praktische Erkenntnisse zur Integration von Large Language Models zu gewinnen und darauf aufbauend die nächsten Schritte zu planen.

Das fünfte Kapitel «Konzeption» liefert die Grundlage für einen reibungslosen Entwicklungsprozess. Sie beschreibt die Anforderungs- und Risikoanalyse, sowie das Architekturkonzept und Entity-Relationship-Modell des Systems.

Das sechste Kapitel «Systemintegration» wird Implementierung des Systems beleuchtet, einschliesslich der Einrichtung der Entwicklungsumgebung, der Containerisierung mit Docker und der Automatisierung von Deployment-Prozessen durch eine CI/CD-Pipeline.

Im siebten Kapitel «DigiBot-App» werden die Webplattform und ihre Funktionalitäten vorgestellt.

Das achte Kapitel «Benutzertests und Ergebnisse» behandelt die Ergebnisse aus umfangreichen Benutzertests. Dazu gehören die Bewertung der generierten Inhalte hinsichtlich Berufsrelevanz, Klarheit, Lesbarkeit, Detailliertheit und Nutzen für Selbsteinschätzungstests, sowie die Analyse von Qualitätsmetriken wie Cosine Similarity und Lesbarkeitsindizes.

Im neunten Kapitel «Diskussion» werden die Ergebnisse kritisch reflektiert. Potenziale für zukünftige Verbesserungen, wie das Fine-Tuning des Modells oder die Erweiterung um zusätzliche Testtypen, werden aufgezeigt.

Das zehnte Kapitel «Fazit» schliesst mit einer Zusammenfassung der wichtigsten Erkenntnisse und der Bedeutung des Projekts für die weitere Forschung und Entwicklung im Bereich personalisierter Selbsteinschätzungstests ab.

Jeder dieser Kapitel trägt dazu bei, das Ziel der Arbeit zu erreichen: eine innovative Lösung zu entwickeln, die den Benutzerkontext berücksichtigt und die Qualität von Selbsteinschätzungstests nachhaltig verbessert.

Inhaltsverzeichnis

Abstract	3
Inhalt dieser Thesis	4
Inhaltsverzeichnis	5
1 Einleitung	7
1.1 Zielsetzung	7
1.2 Erfolgskriterien	7
1.3 Funktionalität	7
1.4 Qualitätssicherung	7
1.5 Dokumentation	8
1.6 Lieferobjekte	8
1.6.1 Scope	8
1.6.2 Out of Scope	8
2 Methodik und Organisation	9
2.1 Projektmethodik	9
2.1.1 Agiles Vorgehen	9
2.1.2 Planung & Rahmenbedingungen	9
2.1.3 Zeitplan und Entwicklungsetappen	10
2.1.4 Issue-Board	11
2.2 Aufwand	12
2.3 Umsetzung	13
2.4 Meetings & Kommunikation	14
2.4.1 Meetings	14
2.4.2 Kommunikation	15
3 Grundlagen	16
3.1 Techstack	16
3.1.1 Frontend	17
3.1.2 Backend	17
3.1.3 Database	18
3.1.4 Webintegration	19
3.1.5 Entwicklungsumgebung	19
3.2 DigComp	21
3.3 Auswahl von Large-Language-Model	22
Einsatz des Modells im Projekt	22
3.4 Integration Langchain-Framework für Interaktion mit OpenAi	23
Einsatz von LangChain im Projekt	23
3.5 Promptengineering	24
3.6 Qualitätsmetriken	28
3.6.1 Syntaktische Ähnlichkeit	28
3.6.2 Semantische Ähnlichkeit	30
3.6.3 Lesbarkeitsindizes	32
4 Journal	35
5 Konzeption	38
5.1 Anforderungen	38
5.1.1 Funktionelle Anforderungen	38
5.1.2 Nicht Funktionelle Anforderungen	39
5.2 Risikoanalyse	40
5.2.1 Risikoanalyse	40
5.2.2 Risiko-Matrix	41
5.2.3 Evaluieren der Risiken und Massnahmen	42
5.3 Mockups	43
5.4 Systemarchitektur	45
5.4.1 System Komponenten Übersicht	45
5.4.2 Systemfluss	46

5.5 Entity-Relationship Modell	51
5.6 CI/CD-Ablauf	52
5.7 Benutzertest	53
5.8 Prolific	55
6 Systemintegration	56
6.1 Docker Containers	56
6.2 Die Google Cloud Platform (GCP)	57
6.3 Einrichten eines CI/CD-Pipelines in GitLab	59
7 DigiBot-App	63
8 Benutzertests und Ergebnisse	66
8.1 Prozess Test	66
8.2 Repräsentativer Test	68
8.3 Ergebnisse Repräsentativer Test	70
8.3.1 Ergebnisse Digitale Kompetenz und Meta-Umfrage	70
8.3.2 Ergebnisse Meta-Umfrage	71
8.3.3 Ergebnisse Digitale Kompetenz und Meta-Umfrage	73
8.3.4 Semantische und Syntaktische Ähnlichkeit	75
9 Diskussion	78
9.1 Ergebnisse im Kontext der Hypothese	78
9.2 Verständlichkeit und Lesbarkeit	78
9.3 Detaillierungsgrad, Relevanz und Nutzen für Selfassessment	79
9.4 Vergleiche mit aktueller Literatur	79
9.5 Übereinstimmungen und Widersprüche	80
9.6 Stärken des Systems	80
9.7 Schwächen des Systems	81
9.8 Einflussgrößen auf die Qualität - Die perfekte Aussage	81
9.9 Interpretation Resultate	82
10 Fazit	84
10.1 Persönliches Fazit	84
10.2 Herausforderungen	84
10.3 Entwicklung	84
10.4 Fazit	84
10.5 Nächste Schritte	85
11 Danksagung	87
12 Quellen	88
12.1 Abbildungsverzeichnis	88
12.2 Tabellenverzeichnis	90
12.3 Codeverzeichnis	91
12.4 Literaturverzeichnis	92
13 Anhang	94
13.1 Funktionsweise von Large Language Models	94
13.2 Journal 1	100
13.3 Journal 2	103
13.4 Journal 3	108
13.5 Journal 4	114
13.6 Journal 5	120
13.7 Journal 6	123
13.8 Journal 7	129

1 Einleitung

In einer zunehmend digitalisierten Welt sind Assessments und Prüfungen von entscheidender Bedeutung, um Kompetenzen und Fähigkeiten von Individuen in Bildung, Beruf und persönlicher Entwicklung zu evaluieren. Insbesondere Situational Judgement Tests (SJTs) [1] und Self Assessment Tests (SA) spielen eine wichtige Rolle bei der psychologischen Profilbildung, beruflichen Weiterentwicklung und sogar in forensischen Analysen. Traditionelle Assessments stossen jedoch oft an ihre Grenzen, da sie nicht ausreichend auf die individuellen Bedürfnisse und Kontexte der Teilnehmer eingehen.

Das «DigiBot» System adressiert diese Herausforderung, indem es Generative Künstliche Intelligenz (GenAI) einsetzt, um personalisierte Self Assessments Tests (SA) bzw. Selbsteinschätzungstests zu erstellen. Durch die Integration von Benutzerkontext und individuellen Hintergrundinformationen generiert «DigiBot» massgeschneiderte Fragen, die besser auf die Bedürfnisse und das Verständnis der Teilnehmer abgestimmt sind.

1.1 Zielsetzung

Das Ziel des «DigiBot» Projekts besteht darin, die Relevanz von Selbseinschätzungstests, insbesondere des europäischen «DigComp» SA [2] zur digitalen Kompetenz, durch die Einführung von personalisierten Aussagen (Statements) massgeblich zu verbessern.

Durch diese generative Anpassung soll der jeweiliger Benutzerkontext in Aussagen des Tests einfließen und so zu verständlicheren und spezifischeren Fragen führen. Dadurch soll die Benutzerfreundlichkeit und Benutzerzufriedenheit gesteigert werden.

Darüber hinaus soll das Projekt wissenschaftliche Daten bereitstellen, die als Grundlage für weiterführende Forschung und Entwicklung dienen können. Diese Daten ermöglichen es, innovative Ansätze in der Gestaltung und Anwendung von Assessments voranzutreiben.

1.2 Erfolgskriterien

Die Erfolgskriterien des Projekts «DigiBot» definieren die Anforderungen und Massstäbe, an denen der Projekterfolg gemessen wird. Dabei werden die Dimensionen Funktionalität, Qualitätssicherung und Dokumentation vordergründig berücksichtigt. Diese Erfolgskriterien stellen sicher, dass das «DigiBot» Projekt sowohl technisch als auch inhaltlich den höchsten Standards entspricht.

1.3 Funktionalität

Ein zentrales Kriterium ist die vollständige Implementierung aller funktionalen Anforderungen. Dies schliesst insbesondere die erfolgreiche Integration von generativer künstlicher Intelligenz (GenAI) ein, die in der Lage sein muss, Kontext bzw. Nutzerangepasste Fragen zu generieren. Das System soll zuverlässig und effizient arbeiten, um die geplanten personalisierten SAs bereitzustellen.

1.4 Qualitätssicherung

Zur Sicherstellung der Qualität des «DigiBot» Systems und dessen Resultate wird zur Validierung der generierten Inhalte einerseits durch Technische Tests andererseits durch Benutzertests überprüft. Das umfasst die Überprüfung der inhaltlichen Relevanz und Verständlichkeit der SA-Aussagen. Darüber hinaus sollen umfassende Benutzertests mit repräsentativen Zielgruppen erfolgen, um Akzeptanz und Zufriedenheit der Teilnehmer zu bewerten. Diese Tests dienen zur kontinuierlichen Optimierung und Bewertung des «DigiBot» Systems.

1.5 Dokumentation

Ein weiteres Erfolgskriterium ist die vollständige Dokumentation des Projekts. Dazu gehören sowohl eine technische Dokumentation, die den Aufbau des Systems beschreibt, ein Journal die einzelnen Experimente dokumentiert und auch eine Wissenschaftliche Auseinandersetzung als Bericht über das ganze Projekt. Sowie alle zusätzlichen Anforderungen, wie Video und Plakat, der Berner Fachhochschule (BFH) [3].

Das Journal wurde geführt, um alle Experimente, deren Ergebnisse sowie den allgemeinen Fortschritt zu dokumentieren. Dieses Journal bot nicht nur eine Übersicht über den Entwicklungsprozess, sondern dient auch als wissenschaftliche Grundlage für Entscheidungen für dieser Arbeit.

Alle Änderungen am Quellcode sowie die Bearbeitung von Aufgaben wurden über Git und das GitLab-Issue-Board organisiert. Dies ermöglichten die Nachvollziehbarkeit und Dokumentation des technischen Fortschritts.

1.6 Lieferobjekte

Der Projektumfang von «DigiBot» definiert die zentralen Aktivitäten, Ziele und Grenzen des Projekts und welche Resultate nach Abschluss abgeliefert werden («Lieferobjekte»). Er beschreibt, welche Funktionen und Komponenten entwickelt innerhalb des Umfangs und umgesetzt werden sollen («scope») und grenzt klar ab, welche Aspekte nicht Teil des Projekts und damit ausserhalb des Umfangs sind (engl. «out of scope»)[4]. Der Fokus liegt auf der Bereitstellung einer innovativen Plattform, die mithilfe von Generativer Künstlicher Intelligenz personalisierte SAs erstellt und dabei den Benutzerkontext integriert.

1.6.1 Scope

Der Projektumfang umfasst die Entwicklung und Bereitstellung der «DigiBot» Web App Plattform. Diese Plattform wird über eine CI/CD-Pipeline mittels automatischer Verteilung (engl. «Deployment») auf dem «Google Cloud» Service bereitgestellt. Mithilfe einer intelligenten Fragegenerierungsverfahrens, die auf generativen LLMs basiert, wird der Benutzerkontext erfasst und in Form eines persönlichen Profils gespeichert. Dieses Profil wird durch einen Chatbot erstellt und auf Qualität und Validität überprüft.

Darüber hinaus ermöglicht das System die kontextspezifischen Anpassungen und Verwaltung von Fragen für SA-Tests. Ein zentraler Bestandteil ist die Integration und Personalisierung des europäischen «DigComp» SA-Tests [2], um welcher digitale Kompetenzen misst.

Das «DigiBot» Projekt implementiert ausserdem ein qualitatives Bewertungssystem, das präzise und vertrauenswürdige Ergebnisse durch generative Evaluation und klassischen Bewertungsalgorithmen sicherstellt. Ergänzt wird die «DigiBot» Plattform durch Funktionen zur Benutzerverwaltung, zur Datenerfassung für wissenschaftliche Zwecke (z.B. Logs und Statistiken) und durch umfassende Benutzertests zur Qualitätsprüfung. Zusätzlich wird das Projekt im Rahmen einer Bachelorthesis dokumentiert und es werden weitere Anforderungen der Berner Fachhochschule (z.B. Präsentation, Plakat und Video) umgesetzt.

1.6.2 Out of Scope

Kein Teil des Projektumfangs sind die generativen Zusammenfassungen der Umfrageresultate und die generative Ableitung von Empfehlungen basierend auf den Ergebnissen des Fragebogens. Ebenso ausgeschlossen ist die Integration von «Situational Judgement Tests» (SJTs) [1]. Diese Testart baut auf der Logik von SAs Tests auf und kann daher zu einem Späteren Zeitpunkt hinzugefügt werden. Diese Funktionen liegen aus Zeitgründen ausserhalb des geplanten Umfangs und um den Fokus auf die Kernziele des Projekts zu gewährleisten.

2 Methodik und Organisation

Die Methodik und Organisation der «DigiBot»-Projekts bildet die Grundlage für strukturierte, effiziente und zielgerichtete Durchführung. Bewährte Methoden und Tools wurden eingesetzt, um die gesteckten Ziele zu erreichen und den Projektumfang erfolgreich umzusetzen. Dabei standen agile Ansätze im Vordergrund, um flexibel auf Veränderungen reagieren zu können und gleichzeitig Transparenz sowie die Zusammenarbeit im Team zu fördern.

Der iterative Ansatz des Projekts ermöglichtes es, das System in verschiedenen Entwicklungsphasen zu testen und zu optimieren. Aufgrund der Projektvorgaben seitens der BFH für die Bachelorarbeit konnte jedoch nicht rein agil gearbeitet werden. Deshalb wurden im Rahmen des agilen Prozesses auch langfristige und konkrete Ziele zu festgelegten Terminen in den Entwicklungsprozess integriert.

Gleichzeitig wurden kontinuierliche Abstimmungen durch Meetings und eine strukturierte Dokumentation mit Arbeitsjournals sichergestellt, dass sowohl Qualität der Ergebnisse als auch die Nachvollziehbarkeit des Projektverlaufs gewährleistet werden.

Im folgenden Kapitel wird beschrieben, wie die Projektmethodik, die verwendeten Tools und die organisatorischen Massnahmen zur erfolgreichen Umsetzung des «DigiBot»-Projekts beigetragen haben.

2.1 Projektmethodik

Die Methodik des «DigiBot»-Projekts basierte auf einer hybriden Herangehensweise, die agile Prinzipien mit klassischen Projektmanagement-Elementen kombinierte. Dieser Ansatz wurde gewählt, um sowohl iterative Entwicklungsstrategien einsetzen zu können und den traditionellen Rahmenbedingungen des Projekts, mit Planungssicherheit und klarer Zieldefinition, gerecht zu werden.

2.1.1 Agiles Vorgehen

Ein zentraler Bestandteil der Projektmethodik war die Orientierung an agilen Praktiken, insbesondere inspiriert durch das Scrum-Framework. Hierbei wurde das Projekt in sieben Iterationen, sogenannte Sprints, unterteilt, die jeweils zwei Wochen dauerten. Während jedes Sprints wurden spezifische Aufgaben, sogenannte Issues, aus dem Backlog priorisiert, bearbeitet und abgeschlossen.

Wichtige Elemente des agilen Prozesses waren:

- Sprintplanung: In zweiwöchentlichen Abständen wurde das Gitlab-Issue-Board gepflegt und Ziele sowie Aufgaben für den jeweiligen Sprint definiert und im festgehalten.
- «Daily» Meetings: Zur Synchronisation des Teams wurden kurze Abstimmungen meist per Teams durchgeführt, um Fortschritte, Hindernisse und nächste Schritte zu besprechen. Diese fanden aufgrund anderer Verpflichtungen im Studium jedoch nicht täglich statt.
- Bi-Weekly Sprint-Review / Retrospektive: Am Ende jedes zweiwöchigen Sprints wurden die Ergebnisse vorgestellt und kritisch evaluiert, um die weitere Planung und Priorisierung zu optimieren.

2.1.2 Planung & Rahmenbedingungen

Aufgrund der Rahmenbedingungen der Bachelorarbeit war es notwendig, zusätzlich zu den agilen Methoden auch langfristige, klar definierte Meilensteine und Entwicklungsetappen zu setzen. Diese Meilensteine waren notwendig, um wichtige Anforderungen der BFH wie Dokumentation, Präsentation und spezifische Lieferobjekte rechtzeitig zu erfüllen. Die Mischung aus agiler Flexibilität und festen Zielvorgaben sorgten dafür, dass sowohl die Qualität als auch die rechtzeitige Fertigstellung der Arbeit gewährleistet waren.

2.1.3 Zeitplan und Entwicklungsetappen

	September					Oktober					November					Special	Dezember					Januar					Februar				
KW	38	39	40	41	42	43	44	45	46	47	48	49	50	51	52	1	2	3	4	5											
Semesterwoche	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20											
	Weekly		Weekly		Weekly		Weekly		Weekly		Weekly		Weekly																		
Organisation																															
Kickoff und Initialisierung	1/16.9 - 22.9.																														
Setup Application / Setup Basic Chatbot		2/22.9-8.10.																													
Context, Agents, Modularer Aufbau, Dokumentation Aufbau			2/22.9-8.10.			3/8.10.-22.10.																									
Implementation Settings, Basis Personal Profile, Basis Enrichment						4/22.10.-5.11.																									
Enrichment speichern und Survey starten, Export mit Metriken								5/05.11.-18.11.																							
Fehlerbehebung und Testfunktionalität										6/18.11.-04.12.																					
User Testing finalisieren											7/04.12.-18.12.			USER TEST																	
Lieferobjekte																3.1.															
Abgabetermin Arbeit																		16.1.													
Abgabetermin Film																		16.1.													
Präsentation Finaltag																		17.1.													
Verteidigung																		17.1.													
Ausstellung Finaltag																			27.1.												
																			20.1. bis 5.2.												

Abbildung 2 - Projektplan

Die Umsetzung des «DigiBot»-Projekts erfolgte nach einem klar strukturierten Zeitplan, der die wichtigsten Aktivitäten und Meilensteine definierte. Die zeitliche Planung erstreckte sich über mehrere Monate und wurde in folgende Phasen unterteilt:

Monat	KW	Aktivität
September	38-39	Kickoff und Initialisierung: Projektstart und Definition der Ziele.
September - Oktober	39-41	Setup App und Basic Chatbot: Grundlegende Infrastruktur und erste Chatbot-Funktionen.
Oktober	41-43	Kontext, modularer Aufbau und Dokumentationsstruktur: Fokus auf Skalierbarkeit und Struktur.
Oktober - November	43-45	Implementation Settings, Basis Benutzerprofile und «Enrichment»: Aufbau der Nutzerprofile und deren Erweiterung.
November	45-47	«Enrichment» speichern, Umfragen starten und Metrik-Export: Optimierung und Erweiterung der Funktionalitäten.
November - Dezember	47-49	Fehlerbehebung und Testfunktionalität: Sicherstellung der Systemstabilität und Beseitigung von Problemen.
Dezember	49-52	Benutzer Tests finalisieren: Durchführung und Analyse von Benutzerstudien zur Systembewertung.
Januar - Februar	1-5	Lieferobjekte: Fertigstellung der Arbeit, Abgabe von Plakat, Film und schriftlicher Dokumentation sowie Präsentation und Verteidigung.
		Ausstellung Finaltag: Präsentation der Projektergebnisse in der öffentlichen Ausstellung.

Tabelle 1 - Projektplan

2.1.4 Issue-Board

Für die Sprintplanung wurde das Issue Board von GitLab benutzt. Mit der intuitiven grafischen Benutzeroberfläche konnten die Aufgaben in den laufenden Sprints eingegliedert werden und jederzeit angepasst werden. Dies erlaubte es eine strukturierte Kommunikation innerhalb der Sprints und im Team zu gewährleisten. Es half Missverständnisse zu reduzieren und Transparenz im Entwicklungsprozess zu fördern.




Abbildung 3 - Issueboard am Ende des Sprint 4

Aufbau des Issue Boards

Es wurden zwei Boards eingesetzt eines für die Organisation von Aufgaben zur Systementwicklung und eines für die Planung und Erstellung der Dokumentation.

Beide Boards wurden in vier Bereiche unterteilt, die den Status der Aufgaben im Prozess visualisieren:

1. Open: Enthalten alle offenen Aufgaben, die noch bearbeitet werden müssen. Dieser Bereich diente gleichzeitig als «Backlog», in dem Zukünftige Aufgaben gesammelt und erfasst wurden.
2. In Progress: Hier befanden sich alle Aufgaben die aktuell bearbeitet werden.
3. Review: Aufgaben, die fertiggestellt wurden und zur Überprüfung im jeweiligen zweiwöchigen Treffen mit dem ganzen Team bereitstanden.
4. Aufgaben, die vollständig abgeschlossen sind.

Mit dem Issue-Board konnten bestehende Probleme in der Entwicklung schnell erkannt, priorisiert und effizient bearbeitet werden. Durch die enge Kopplung der Aufgaben und dem Quellcode war eine flüssige Entwicklung ohne grosse Überschneidung gewährleistet. So konnten alle Aufgaben systematisch erfasst, bearbeitet, besprochen und abgeschlossen werden.

2.2 Aufwand




Abbildung 4 - GIT Task Time Tracking Transfer Tool

Die Erfassung von Zeit und Aufwand im Projekt erfolgte mithilfe der Zeiterfassungsfunktionen im Issue-Board, wo jeweils pro Aufgabe die geschätzte und tatsächliche Zeit eingetragen werden konnte. Mit dem «GIT Task Time Tracking Transfer Tool» (GITTTTTT) konnten dann die Werte als Excel rausexportiert werden. Dies ermöglichte eine detaillierte Analyse der Zeitaufwände für jeden Sprint. Abweichungen zwischen geplanten und genutzten Zeiten traten vor allem bei komplexen Entwicklungsaufgaben auf, insbesondere in den finalen Sprints, wo zusätzliche Iterationen und Tests erforderlich waren und die nachführen der Zeiten weniger priorisiert wurden. Dennoch blieb die Planung insgesamt realistisch mit kleinen Abstrichen im Umfang.

2.3 Umsetzung




Abbildung 5 - Die Methodik des «DigiBot»-Systems in vier Schritten.

Das Umgesetzte «Digibot»-System besteht aus einem Vue.js-Frontend und einem Python-Backend, das mit der OpenAI GPT-4-Integration arbeitet. Ziel war es, eine Plattform zu schaffen, die personalisierte SAs basierend auf dem europäischen «DigComp»-Framework generiert kann und dessen Resultate in repräsentativen Tests evaluiert. Das System durchläuft folgende vier Schritte, dabei wird zwischen Testsystem (A), Umfragesystem (B) und Administratorsystem (C) unterschieden:

1. Benutzerprofile erstellen

Der Chatbot stellt den Nutzer:innen fünf gezielte Fragen zu ihrem Beruf und ihrer Erfahrung. Auf Basis der Antworten gibt er Feedback, wie diese konkretisiert oder verbessert werden können, um ein genaues Benutzerprofil zu erstellen. Diese Interaktion bildet die Grundlage für die Individualisierung der folgenden SA-Umfragen.

2. Generierung des Personalisierten Fragebogens

Das erstellte Benutzerprofil wird genutzt, um generische Fragen aus dem «DigComp»-Framework durch GPT-4 zu personalisieren. Diese Anpassung stellt sicher, dass die Fragen relevanter und auf den individuellen Kontext der Nutzer:innen zugeschnitten sind. Diese Methodik ist flexibel und kann potenziell auf eine Vielzahl standardisierter Umfragen übertragen werden.

3. Tests

A) Die Nutzer:innen bewerten die originalen und personalisierten Fragen in einem A/B-Test hinsichtlich Informationsgehalt, Lesbarkeit und Nutzen. Die Rückmeldungen werden in einer PostgreSQL-Datenbank gespeichert, um sie für die weitere Optimierung des Systems auszuwerten.

- B) Die Nutzer:innen erhalten die personalisierten SA-Fragen in einem Test mit jeweils vier Antwortoptionen zu den Fragen. Die Rückmeldungen werden ebenfalls in die PostgreSQL-Datenbank abgespeichert.
- C) Der Administrator erhält zusätzlich ein «Control Panel» um die Konfiguration des Fragebogens und Debug Optionen zu überprüfen. Weiter können spezifische Resultate aus der Datenbank untersucht werden.

4. Analyse und Resultate

- A) Die Nutzer:innen erhalten die Resultate ihrer Umfrage. Die Ergebnisse des A/B-Tests werden weiter in separaten «Jupyter-Notebooks» analysiert, um die Qualität der generierten Fragen zu bewerten. Hierbei kamen Methoden wie «Cosine Similarity» sowie Lesbarkeitmetriken wie «Flesch Reading Ease» und «Gunning Fog» zum Einsatz.
- B) Die Nutzer:innen erhalten die zusammengefassten Resultate der SA-Umfrage.
- C) Der Admin erhält eine Übersicht mit erweiterten Möglichkeiten zur Untersuchung aller Resultate.

2.4 Meetings & Kommunikation

Die Dokumentation und die regelmässigen Meetings spielten eine zentrale Rolle, um den Fortschritt des «DigiBot»-Projekts zu überprüfen und eine klare Kommunikation aller Beteiligten sicherzustellen. Dabei wurden mehrere Ansätze und Tools eingesetzt, um einen reibungslosen Ablauf zu gewährleisten.

2.4.1 Meetings




Abbildung 6 – Miro Board

Alle zwei Wochen fand ein Meeting statt mit allen Teilnehmern des Projekts. In diesem wurden Ergebnisse und der Fortschritt im «DigiBot»-Projekt besprochen. Dieses Treffen wurde mit «Microsoft Teams» und einem «Miro Board» durchgeführt, wodurch eine strukturierte Diskussion ermöglicht wurde. Die Agenda der Meetings wurde im Vorfeld per E-Mail an alle Teilnehmenden versendet, um die Besprechungspunkte zu priorisieren und festzuhalten. Zu jedem Meeting wurde ein Protokoll erstellt, in dem die besprochenen Themen, Entscheidungen und nächste Schritte festgehalten wurden.

2.4.2 Kommunikation

	Schneiter Roman 🗨️ Ausgehend	2Std. 50Min.	08.11.2024
	Schneiter Roman 🗨️ Ausgehend	50Min. 12Sek.	07.11.2024
	Schneiter Roman 🗨️ Eingehend	42Min. 23Sek.	06.11.2024
	Schneiter Roman 🗨️ Eingehend	11Min. 11Sek.	06.11.2024

Abbildung 7 - Teams Kommunikation

Regelmässige «Daily»-Meetings wurden innerhalb des Entwicklungsteam rege genutzt und über Teams durchgeführt. Dies diente dazu um schnelle Abstimmungen, den Fortschritt, nächste Schritte und eventuelle Probleme zu besprechen.

3 Grundlagen

Das Kapitel «Grundlagen» behandelt die technischen und inhaltlichen Bausteine der Arbeit. Der Techstack kombiniert etablierte Vorgehensweisen zur Datenback, Front- und Backend Programmierung und ergänzt sie durch brandneue AI-Technologien und Frameworks (Kapitel 3.1). Dies dient dem Ziel der Modifizierung des europäischen «DigComp»-Rahmenwerks, welches zur Bewertung der eigenen digitalen Kompetenz (SA-Test) verwendet wird (Kapitel 3.2). Diese Bereicherung findet mittels eines Large Language Models (LLM) statt (Kapitel 3.3). Dabei steht eine gut begründete Wahl des «Prompt Engineerings» im Vordergrund, da dies den grössten Effekt auf die Bereicherung des «DigComp»-Fragebogens hat (Kapitel 3.4). Zur wissenschaftlichen Bewertung der Resultate müssen die Richtigen Qualitätsmetriken gewählt werden, um eine Aussage treffen zu können (Kapitel 3.5).

3.1 Techstack




Abbildung 8 - Star History Grafik des Techstack; Erstellt mit star-history.com

Der Techstack ist darauf ausgelegt, eine robuste Anwendung zu erstellen, die in der Lage ist, in Echtzeit personalisierte SA-Tests über OpenAI zu generieren. Zum Einsatz dazu kommen bewährte Technologien für Front- und Backend Applikationen. Für die Integration von LLMs hingegen kommen brandneue Frameworks zum Einsatz, da es sich um ein neues Bereich in der Entwicklung handelt.

3.1.1 Frontend

Frontend		
	Vue.js	Ein progressives JavaScript-Framework zur Erstellung interaktiver und dynamischer Benutzeroberflächen. Ideal für die Entwicklung von responsiven und skalierbaren Front-End-Anwendungen.
	Chart.js	Chart.js ist eine flexible Open-Source-JavaScript-Bibliothek für die Datenvisualisierung. Es werden verschiedene Diagrammtypen wie Balken, Linie, Fläche, Kuchen (Ring), Blase, Radar, Polar und Streuung unterstützt. Chart.js ermöglicht es, interaktiv Diagramme für Webanwendungen effektiv und einfach umzusetzen.

Tabelle 2 - Techstack Frontend

Das Frontend des Techstacks basiert auf Vue.js, einem JavaScript-Framework. Entscheidend für die Wahl diese Frameworks war, dass es schnelle und einfache Integration von Webapps erlaubt. Die Entwicklung wird weiter durch Chart.js unterstützt, welches die rapide Einbindung von visuellen Statistiken ermöglicht.

3.1.2 Backend

Backend		
	Python	Python ist eine vielseitige Programmiersprache, die sich in ihrer breiten Anwendbarkeit auszeichnet. Für AI-Entwicklung zählt sie zum gängigen Standard und wird durch zahlreiche Bibliotheken in diesem Bereich unterstützt.
	FastAPI	Ein leistungsstarkes Python-Web-Framework zur Entwicklung von APIs, bekannt für seine Geschwindigkeit und Benutzerfreundlichkeit. Es unterstützt moderne Python-Standards wie Typenhinweise und eignet sich hervorragend für den Aufbau schneller, asynchroner Backend-Dienste sowie für die Integration mit Machine Learning- und KI-Systemen.
	OpenAI	Integration von GPT-4 zur Erzeugung kontextuell personalisierter Fragen und Tests unter Verwendung fortschrittlicher Natural Language Processing (NLP) und generativer KI.
	LangChain LangGraph	Tools zur Orchestrierung und Entwicklung von komplexer AI-Workflow, die LLMs mit Datenquellen und APIs verbinden.

Tabelle 3 - Techstack Backend

Das Backend nutzt Python, da es sich dabei um den momentanen Standard in der Entwicklung mit LLMs handelt. Ergänzt wird die Backendentwicklung mit «FastAPI», welches eine schnelle und moderne Integration für APIs ermöglicht.




Abbildung 9 - Star History Grafik von Orchestrierungsframeworks; Erstellt mit star-history.com

Zur Integration von OpenAI wurde, neben der direkten Abfrage, vorwiegend LangChain gewählt. Es handelt sich dabei um eines der beliebtesten und somit am besten dokumentierten Orchestrierungsframeworks zum Zeitpunkt der Entwicklung.

3.1.3 Database

Database	
	PostgreSQL Ein fortschrittliches, quelloffenes relationales Datenbanksystem, das sich durch seine Skalierbarkeit, Zuverlässigkeit und Unterstützung komplexer Abfragen auszeichnet. Es wird genutzt, um strukturierte Daten wie Benutzerprofile, Testergebnisse und generierte Fragen zu speichern.

Tabelle 4 - Techstack Database

PostgreSQL dient als zuverlässiges relationales Datenbanksystem und wird in der Google Cloud unterstützt.

3.1.4 Webintegration

Webintegration		
	GitLab	Eine DevOps-Plattform, die Versionskontrolle, CI/CD-Pipelines und Projektmanagement in einem Tool vereint. Sie bietet verschiedene Tools, die die Zusammenarbeit im Softwareentwicklungsprozess ermöglicht und vereinfacht.
	Vue.js	Zur Containerisierung der Anwendung, um Konsistenz in Entwicklungs-, Test- und Produktionsumgebungen sicherzustellen.
	Google Cloud	Cloud-Infrastruktur für das Hosting der Anwendung, die serverlose Funktionen, KI-Integration und skalierbare Speicherlösungen bietet.
	Artifact Registry	Zentraler Speicher für Container-Images, Pakete oder Artifacts, der nahtlosen Integration in CI/CD Pipelines ermöglicht.
	Cloud SQL	Ein vollständig verwalteter relationaler Datenbankdienst für PostgreSQL oder MySQL in der Cloud, der Skalierbarkeit, Sicherheit und einfache Wartung der Datenbankinfrastruktur bietet.

Tabelle 5 - Techstack Webintegration

Für die Versionskontrolle, CI/CD-Pipelines und Projektmanagement wurde GitLab verwendet. Die «DigiBot»-Anwendung wird in der Google Cloud gehostet. Dabei dient das «Artifact Registry» als Speicher Ort der dockerisierten front- und backend Applikationen. Die Daten Bank wird auf Cloud SQL gehostet.

3.1.5 Entwicklungsumgebung

Entwicklungsumgebung		
	WebStorm	IDE der Firma JetBrains die auf Webentwicklung spezialisiert ist. Sie bietet Funktionalität zur Codevervollständigung, Debugging und Unterstützung für Frameworks wie Vue.js.
	PyCharm	Eine leistungsstarke Python-IDE der Firma JetBrains. Sie bietet ebenfalls eine ausgereifte Entwicklungsumgebung mit Funktionalität zur Codevervollständigung, Debugging und Environment Verwaltung.

	DBeaver	Ein universelles Datenbank-Tool, das eine benutzerfreundliche Oberfläche für Verwaltung, Abfragen und Analyse von Datenbanken wie PostgreSQL bietet.
	Jupyter	Interaktive Notebooks welche Python unterstützt und für Datenanalyse Zwecke verwendet wird.

Tabelle 6 - Techstack Entwicklungsumgebung

Für die Entwicklung wurden die JetBrains Programme «WebStorm» und «PyCharm» gewählt. Diese bieten jeweils eine exzellente Umgebung in dessen Angedachten Programmiersprachen. Für die Verwaltung der PostgreSQL Datenbank wurde DBeaver gewählt. Zur Untersuchung von Resultaten wurde Jupyter genutzt, welches eine schnelle Analyse mittels Python erlaubt.

3.2 DigComp

Das europäische «Digital Competence Framework for Citizens» (DigComp) dient als bewährte Grundlage für die Selbsteinschätzung digitaler Kompetenzen und bildet die Basis für unseren Proof-of-Concept, in dem wir untersuchen, ob eine massgeschneiderte Anpassung durch einen LLM zusätzliche Vorteile bieten kann [1][2].



Abbildung 10 - DigComp Themengebiete und Testresultate

Das Rahmenwerk umfasst 81 Selbsteinschätzungsfragen eingeordnet in insgesamt 21 Kompetenzen und fünf Themengebieten [5]. Folgende Bereiche werden behandelt:

Themengebiet	Digitale Kompetenz
1 Informations- und Datenkompetenz	1.1 Suchen und Filtern von Daten, Informationen und digitalen Inhalten
	1.2 Bewerten von Daten, Informationen und digitalen Inhalten
	1.3 Verwalten von Daten, Informationen und digitalen Inhalten
2 Kommunikation und Zusammenarbeit	2.1 Interagieren durch digitale Technologien
	2.2 Teilen durch digitale Technologien
	2.3 Einbindung in die Bürgerschaft durch digitale Technologien
	2.4 Zusammenarbeiten durch digitale Technologien
	2.5 Netiquette
	2.6 Verwalten der digitalen Identität
3 Erstellen von digitalen Inhalten	3.1 Erstellen digitaler Inhalte
	3.2 Integrieren und Neugestalten digitaler Inhalte
	3.3 Urheberrecht und Lizenzen
	3.4 Programmierung
4 Sicherheit	4.1 Schutz von Geräten
	4.2 Schutz personenbezogener Daten und der Privatsphäre
	4.3 Schutz von Gesundheit und Wohlbefinden
	4.4 Schutz der Umwelt
5 Problemlösung	5.1 Technische Probleme lösen
	5.2 Bedarfe und technologische Antworten identifizieren
	5.3 Kreative Nutzung digitaler Technologien
	5.4 Erkennen von Kompetenzlücken

Tabelle 7 - DigComp Kompetenzen

Insgesamt wird durch diese Auswahl ein breites Spektrum an Fähigkeiten zu den digitalen Kompetenzen abgedeckt. Anhand dessen ermöglicht es der DigCompSAT-Test Nutzern und Nutzerinnen eine Aussagekräftige Selbsteinschätzung durchzuführen. Dies hilft, Kompetenzlücken zu erkennen und zielgerecht zu adressieren. DigComp wird auch für andere Zielgruppen wie Pädagogen (DigCompEdu) oder Organisationen (DigCompOrg) adaptiert. Ziel im «DigiBot»-Projekt ist es eine Automatisierte Anpassung anhand selbsterstellter Profile in Echtzeit zu generieren.

3.3 Auswahl von Large-Language-Model

Im «DigiBot»-System wird das KI-Modell ChatGPT-4 von OpenAI verwendet. GPT-4 verwendet eine Deep-Learning-Architektur und ist ein transformerbasiertes Sprachmodell. Transformer (neuronale Netze) erlauben Kontext und die Beziehung zwischen Tokens innerhalb des Textes zu verstehen. Eine genauere Erklärung, wie die wesentlichen Schritte eines transformerbasierten Modells funktionieren, ist im Anhang beschrieben.

Einsatz des Modells im Projekt

- **Erhebung des «Personal Profile»**
Evaluieren der Antworten der Benutzer: innen auf die Frage des Chatbots und Bewertung der Kriterien «Vollständigkeit, Klarheit und Glaubwürdigkeit»
- **Generierung der Statements**
Optimierung und personalisieren der originalen Statements durch die erfassten Informationen des «Personal Profile».
- **Evaluation der generierten Statements**
Das Modell wurde verwendet, um generierte Statements auf Kriterien wie «Clarity, Relevance, Original Meaning, Difficulty» zu evaluieren.

3.4 Integration Langchain-Framework für Interaktion mit OpenAi

Für die Interaktion mit dem Model wurde die LangChain-Bibliothek verwendet. Durch die bereitgestellten Prompt-Templates und die LLM-Chain der Bibliothek konnte die Interaktion mit dem OpenAI-API-Endpoint vereinfacht, werden.

Dies ist ein vereinfachtes Beispiel, wie LangChain-Bausteine eingesetzt werden können:

```
assessment_prompt_template = """
Based on the following user information: Age: {age},
Profession: {profession},
Digital Proficiency: {digital_proficiency},
Responsibilities: {responsibilities},
Strategies: {strategies},
Skill Improvement: {skill_improvement} Generate 2 personalized multiple-choice questions for the
category: {category}.
Provide 4 answer options for each question, with one clearly being the best, another as second-
best, and so on."""
```

Source Code 1 – «Prompt Template» enthalten die effektive Anweisung für das LLM mit Platzhalter für die Inputvariablen.

```
chain = LLMChain(
    llm=llm,
    prompt=PromptTemplate(
        input_variables=["age", "profession", "digital_proficiency",
            "responsibilities", "strategies", "skill_improvement", "category"],
        template=assessment_prompt_template
    ))
assessment_input = {
    "age": user_answers[0],
    "profession": user_answers[1],
    "digital_proficiency": user_answers[2],
    "responsibilities": user_answers[3],
    "strategies": user_answers[4],
    "skill_improvement": user_answers[5],
    "category": category
}
# Generate multiple-choice questions
generated_questions = chain.run(assessment_input)
```

Source Code 2 – Die LLM Chain dient dazu, die Interaktion mit einem Language Model wie GPT strukturiert und effizient zu gestalten.

Die LLM-Chain kombiniert Eingaben, wie Benutzerdaten oder Kontextinformationen, mit dem vordefinierten Prompt-Template, um Anweisungen für das Modell möglichst einfach zu gestalten. Die LLM-Chain ermöglicht so die Automatisierung komplexer Workflows, vereinfacht die Vor- und Nachbearbeitung von Daten und sorgt für eine flexible Integration von Sprachmodelle.

Einsatz von LangChain im Projekt

Die Framework-Bausteine wurden für die Interaktion mit dem LLM-Model für den Einsatz von Erhebung des «Personal Profile», Generierung der Statements und für die Evaluation der generierten Statements gemäss Kapitel 3.3 «Einsatz des Modells im Projekt» verwendet. Die Integration hat die Abläufe deutlich beschleunigt und übersichtlich gestaltet.

3.5 Promptengineering

In der Interaktion mit dem Large Language Model wurden verschiedenen Prompttechniken angewendet [6] [7].

Zero Shot Prompt

Der Prompt besteht aus einer natürlichen Sprachinstruktion. Das Model löst eine Aufgabe, indem es sich vollständig auf das Verständnis der Instruktion stützt. Für das Model ist dies eine komplexe Ausgangslage, da es sogar für Menschen schwierig ist manche Aufgaben ohne Beispiele umzusetzen. Instruktionen müssen präzise und klar formuliert sein.

Few Shot Prompt

Bei Few Shot Prompting wird dem Prompt neben der natürlichen Sprachinstruktion, Beispiele mitgegeben, wie eine Aufgabe gelöst werden kann. Es dient dem Model als Hilfestellung die Instruktion von Benutzer:innen genauer zu verstehen, und die Aufgabe nach einem gewünschten Schema zu erledigen. Nach dem Promptguide.ai «Few-Shot Prompting kann als Technik eingesetzt werden, um das Lernen im Kontext zu ermöglichen, indem wir Demonstrationen im Prompt bereitstellen, um das Modell zu einer besseren Leistung zu lenken.» [6]

Im «DigiBot»-System wurden die folgenden Prompts verwendet.

Für das Enrichment kann der Admin, die verschiedenen Promptarten Zero Shot Prompt und Few Shot Prompt auswählen und. Beim Chatbot wurden ein Zero Shot Prompt verwendet für die Evaluation der einzelnen Antworten.

```
def evaluate_answer_with_matrix(question, answer):
    validation_prompt = (
        f"Evaluate the following answer to the question: '{question}'.\n"
        f"Provide ratings from 1 to 5 based on these criteria:\n"
        f"1. Completeness: Is the answer detailed and comprehensive?\n"
        f"2. Clarity: Is the answer clear and easy to understand?\n"
        f"3. Credibility: Does the answer seem reasonable and believable?\n\n"
        f"Answer: '{answer}'.\n\n"
        f"Return your response in the following JSON format. Include individual suggestions for each criterion and a summarization field combining the three suggestions in a concise form:\n"
        f'{{"completeness": <score>, "suggestion_completeness": "<suggestion>", '
        f'"clarity": <score>, "suggestion_clarity": "<suggestion>", '
        f'"credibility": <score>, "suggestion_credibility": "<suggestion>", '
        f'"summarization": "<A concise combination of the three suggestions as hint for the user that he can improve his answer>" '
        f'}}'
    )
```

Source Code 3 – Prompt für Chatbot Evaluation

```
prompt = (
    f"Context: {context}\nOriginal Statement: {original_statement}\n"
    "Enrich the statement while keeping its meaning intact, ensuring clarity, relevance, "
    "and appropriate difficulty based on the context. Limit the response to a maximum of "
    f"{rounded_statement_length_percent} characters without cutting off mid-sentence. "
    f"Dont make phrases which include the job profile ex. 'As a .....' and dont include the digital proficiency level. "
)
response = llm.predict(prompt)
```

Source Code 4 – Zero Shot Prompt für Enrichment der Statements

```
async def enrich_statement_with_llm_prompt_type3(context, original_statement, statement_length):
    statement_length_percent = len(original_statement) / 100 * statement_length
    rounded_statement_length_percent = round(statement_length_percent)
```

```

few_shot_examples = (
    "Example 1:\n"
    "Context: A Project Manager using collaborative tools for team efficiency.\n"
    "Original Statement: I ensure my team can work together effectively using digital tools.\n"
    "Enriched Statement: I utilize collaborative platforms to streamline team communication and ensure efficient task delegation, fostering a productive work environment.\n\n"

    "Example 2:\n"
    "Context: A Data Scientist analyzing complex datasets for business insights.\n"
    "Original Statement: I can analyze data to provide useful insights.\n"
    "Enriched Statement: I use advanced analytics tools to extract actionable insights from large datasets, enabling informed decision-making and strategic planning.\n\n"

    "Example 3:\n"
    "Context: A Teacher integrating technology into classroom learning.\n"
    "Original Statement: I use technology to make learning easier for my students.\n"
    "Enriched Statement: I incorporate interactive tools and digital platforms into my teaching methods to make lessons more engaging and accessible for students.\n\n"

    "Example 4:\n"
    "Context: A Freelance Writer using digital tools for content planning and writing.\n"
    "Original Statement: I use online tools to help me write better.\n"
    "Enriched Statement: I utilize content planning platforms and grammar-enhancing tools to produce well-structured and engaging written pieces for my clients.\n\n"

    "Example 5:\n"
    "Context: A Small Business Owner expanding their online presence.\n"
    "Original Statement: I use social media to promote my business.\n"
    "Enriched Statement: I strategically utilize social media platforms to build brand awareness, connect with customers, and drive business growth." )

prompt = (
    f"{few_shot_examples}\n\n"
    f"Context: {context}\n"
    f"Original Statement: {original_statement}\n"
    f"Enrich the statement while keeping its meaning intact, ensuring clarity, relevance, "
    f"and appropriate difficulty based on the context. Limit the response to a maximum of "
    f"{rounded_statement_length_percent} characters without cutting off mid-sentence. "
    f"Dont make phrases which include the job profile ex. 'As a .....' and dont include the digital proficiency level or start with Enriched Statement: " )

```

Source Code 5 - Few Shot Prompt für Enrichment der Statements – Shots mit generischen Beispielen

```

few_shot_examples = (
    "Example 1:\n"
    "Context: HR Specialist organizing digital employee records.\n"
    "Original Statement: I know how to organize digital content (e.g., documents, images, videos) using folders or tagging to find them back later.\n"
    "Problematic Enrichment: I possess the expertise to efficiently categorize and manage digital content such as documents, images, and videos utilizing techniques like folder organization and tagging.\n"
    "Revised Enrichment: Digital content is structured with folders and tags, ensuring quick access to employee records and improving HR efficiency.\n\n"

    "Example 3:\n"
    "Context: IT Specialist managing large-scale infrastructure systems.\n"
    "Original Statement: When I use a search engine, I can take advantage of its advanced features.\n"
    "Problematic Enrichment: When utilizing a search engine, I am adept at leveraging its sophisticated features to optimize research outcomes.\n"
    "Revised Enrichment: Advanced search features, such as Boolean operators and filters, help streamline troubleshooting and system management tasks.\n\n"

    "Example 2:\n"
    "Context: Marketing Manager analyzing campaign data to improve performance.\n"
    "Original Statement: I know which words to use in order to find what I need quickly (e.g., to search online or within a document).\n"
    "Problematic Enrichment: I am adept at utilizing appropriate terminology and keywords to efficiently search for specific information online or within a document aiding in swift data gathering and analysis for AI education rese Ch.\n"

```

```

"Revised Enrichment: Effective use of targeted keywords ensures fast and accurate retrieval of
information, essential for optimizing marketing campaigns.\n\n"

...

)

prompt = (
    f"{few_shot_examples}\n\n"
    f"Context: {context}\n"
    f"Original Statement: {original_statement}\n"
    f"Enrich the statement by integrating the context of a {context}. While keeping its meaning
    intact, ensuring clarity, relevance, "
    f"and appropriate difficulty based on the context."
    f"Avoid verbose or overly complex language. Limit the response to a maximum of "
    f"{rounded_statement_length_percent} characters without cutting off mid-sentence. "
    f"Do not include phrases like 'As a ...', 'Revised Enrichment:' or explicit digital proficiency
    levels."
)

```

Source Code 6 - Few Shot Prompt für Enrichment – Shots sind angepasst auf die Original Statements

```

async def evaluate_statement_with_llm(original_statement, enriched_statement):

    prompt = (
        f"Original Statement: {original_statement}\nEnriched Statement: {enriched_statement}\n"
        "Evaluate the enriched statement based on clarity (0-5), relevance for context (0-5), retention of
        original meaning (0-5), "          "and difficulty (0-5)."          )
    response = llm.predict(prompt)
    evaluation = response.strip()

    logger.info(f"Evaluation result: {evaluation}")
    return evaluation

```

Source Code 7 - Evaluation für Enrichment

Limitationen und Verbesserungsmöglichkeiten

Das Few-Shot Prompting funktioniert gut für viele Aufgaben, stößt jedoch an seine Grenzen, wenn komplexere Denkaufgaben gefragt sind. Wenn weder Zero-Shot noch Few-Shot Prompting ausreicht, liegt dies oft daran, dass das Modell nicht ausreichend trainiert wurde, um die Aufgabe zufriedenstellend zu lösen. In solchen Fällen ist es sinnvoll, entweder ein Fine-Tuning des Modells durchzuführen oder fortgeschrittenere Prompting-Techniken einzusetzen [6]. Konkrete Möglichkeiten die Einbettung des Kontextes durch Ansätze von Prompt Engineering zu erweitern wäre:

Chain of Thought (CoT) Prompting

Das Model löst eine Aufgabe in Teilschritten. Den gedanklichen Prozessen und Zwischenschritte werden explizit dargestellt. Die Genauigkeit kann so bei mehrstufigen Aufgaben mit komplexen Hintergründen verbessert werden.

In unserem Usecase könnte man die Erfassten «Primary Task» erst auf das Originalaussage zusätzlich evaluieren.

Fine-Tuning Model, um Kontexte einzubinden

Die internen Parameter eines Modells werden durch einen neuen, spezifischeren Datensatz angepasst. Durch das Training des Modells mit den neuen Daten soll die Leistung und Generalisierungsfähigkeit des Modells auf den benötigten Use Case optimiert werden.

Domänenspezifische und komplexere Anwendungsfälle mit spezifischen Anforderungen können dadurch bessere Ergebnisse liefern.

Im Vergleich zum Prompt-Engineering, welches die Eingabe innerhalb einer laufenden Session beeinflusst, werden beim Fine-Tuning die Modellparameter dauerhaft angepasst.

Die Nachteile des Fine-Tunings mit einem etablierten Modell wie GPT-4 sind der hohe Ressourcenbedarf (CPU, RAM, GPUs), die damit verbundenen Kosten sowie der Zeitaufwand, der sowohl für die Vorbereitung der Daten als auch für den Trainingsprozess erforderlich ist.

3.6 Qualitätsmetriken

Qualitätsmetriken dienen der Objektiven Bewertung von Texten in Bezug auf syntaktische und semantische Merkmale. Sie ermöglichen es, Unterschiede und Gemeinsamkeiten zu analysieren und die Qualität generierter Inhalte zu prüfen.

3.6.1 Syntaktische Ähnlichkeit

Die Kombination von Cosine Similarity und TF-IDF bietet eine systematische Methode zur Bewertung von syntaktischer Ähnlichkeit von Texten. Sie analysiert Wortwahl und Satzstruktur, um die syntaktische Distanz numerisch zu bewerten.

Cosine Simliarity

Die Cosine Simliarity ist ein ein Messwert, um die Ähnlichkeit von Vektoren zu berechnen. Es wird dabei der Cosinus des Winkels zwischen beiden Vektoren berechnet. Es kann so eine Aussage getroffen werden, wie stark Vektoren in die exakte Richtung zeigen. [8]

$\text{Cosine Similarity} = \cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{ \vec{A} \vec{B} } \quad \Rightarrow \quad \text{Cosine Similarity} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}}$	
Diese Darstellung zeigt die Cosine Similarity als $\cos(\theta)$, wobei θ der Winkel zwischen den Vektoren $\vec{A}$ und $\vec{B}$ im n-dimensionalen Raum ist. Sie verdeutlicht die mathematische Basis, auf der die Ähnlichkeit berechnet wird.	Das Skalarprodukt wird durch das Produkt der Beträge der beiden Vektoren A und B geteilt, wobei $A = \sqrt{\sum_{i=1}^n A_i^2}$ und $B = \sqrt{\sum_{i=1}^n B_i^2}$ und zeigt, wie die Ähnlichkeit der Vektorkomponenten berechnet wird.
Legende: $\vec{A}$: Vektor A steht für den ersten Text oder Datensatz (numerische Darstellung). $\vec{B}$: Vektor B steht für den zweiten Text oder Datensatz, mit dem der erste verglichen wird.	

Tabelle 8 - Berechnung Cosine Similarity

Messwert	Schwierigkeitsgrad des Leseniveau
1	Die Vektoren sind identisch (gleiche Richtung).
0	Die Vektoren sind orthogonal (keine Ähnlichkeit).
-1	Die Vektoren zeigen in entgegengesetzte Richtungen (maximale Unähnlichkeit).

Tabelle 9 - Cosine Similarity Leseniveau

TF-IDF (Term Frequency-Inverse Document Frequency)

Mit TF-IDF kann eine Aussage getroffen werden wie wichtig ein Wort für ein Dokument ist.

Je höher der TF-IDF-Wert, desto wichtiger ist das Wort für ein Dokument. [9]

Term Frequency (TF)	Häufigkeit des Begriffs im Dokument.
$TF(t, d) = \left(\frac{\text{Anzahl des Begriffs } t \text{ im Dokument } d}{\text{Gesamtzahl aller Begriffe in } d} \right)$	
Inverse Document Frequency (IDF)	Seltenheit des Begriffs in der gesamten Sammlung.
$IDF(t) = \log \left(\frac{\text{Gesamtzahl der Dokumente}}{\text{Anzahl der Dokumente, in denen } t \text{ vorkommt}} \right)$	
Gesamte Formel	
$TF - IDF(t, d) = TF(t, d) \times IDF(t)$	

Tabelle 10 - Verbindung von TF-IDF

Die Verbindung der beiden Formeln

Die Funktion der Cosine Similarity in Verbindung mit TF-IDF lässt eine Aussage zu wie ähnlich die Wortwahl und Syntax der beiden Statements ist. Die Skala geht von 0 bis 1.

- Werte bei 1 zeigen das die Wortstruktur und Satzbildung der beiden Vektoren sehr ähnlich
- Werte bei 0 zeigen das die Wortstruktur und Satzbildung sehr unterschiedlich ist.
- Werte von -1 repräsentieren die gegensätzliche Botschaft

Der Wert ist ideal um syntaktische Nähe zu messen. Trotz niedrigem TF-IDF-Wert kann aber die semantische Bedeutung mit alternativer Formulierung identisch sein.

3.6.2 Semantische Ähnlichkeit

Die semantische Ähnlichkeit von Texten wird mithilfe von Embeddings analysiert, um inhaltliche und kontextuelle Bedeutung zu vergleichen. Das erlaubt tiefere semantischen Beziehung zwischen Sätzen und Dokumenten zu erkennen.

Embeddings

Das Beispiel «King - Men + Women = Queen» illustriert die Grundidee von Embeddings. Wörter werden in einem Vektorraum dargestellt mit dem Ziel eine abstrakte, numerische Darstellung der Bedeutung der Worte bei gleichzeitiger Dimensionsreduktion zu erhalten. Wörter mit semantisch ähnlicher Bedeutung gehören derselben Kategorien an und sollen nahe beieinander liegen. Die numerische Vektorrepräsentation kann so verwendet werden, um mathematische Operationen durchzuführen.

Das Konzept wird in unserem Anwendungsfall auf Sätze erweitert, indem die semantische Beziehung des gesamten Satzes erfasst wird. Es versteht abstrakte Bedeutung und semantische Nuancen. Beim Beispiel mit einzelnen Worten wird jedes Wort kontextunabhängig betrachtet. [10]

Sentence Transformer

Eine Python-Bibliothek, die *Transformer-Modelle* zur Verfügung stellt. Die Bibliothek baut auf der Bibliothek «Hugging Face Transformers» auf und erweitert diese mit optimierten, speziellen Modellen für Sentence Embeddings. Dieser wird für die Berechnung von semantischen Ähnlichkeiten von Texten (Sätzen, Absätzen, Dokumenten) verwendet. [11]

Modell all-MiniLM-L6-v2

Das Modell wurde trainiert, die Bedeutung komplexer Sätze zu lernen. Es prüft, wie Worte zueinanderstehen und welchen Kontext der gesamte Satz liefert. Es verfügt über eine Vektorgrosse von 384 Dimensionen (welches den Satz repräsentiert) und zählt zu einem leichtgewichtigen Model welches sich ideal eignet um Ähnlichkeitsberechnungen durchzuführen. [12]

Zwei Satzbeispiele mit hoher semantischer Ähnlichkeit

```
from sentence_transformers import SentenceTransformer
from sklearn.metrics.pairwise import cosine_similarity

# lade vortrainiertes Model
model = SentenceTransformer('all-MiniLM-L6-v2')

original_statement = "Der Lehrer erklärt die Aufgabe den Schülern."
Nearly_original_statement = "Der Lehrer erläutert die Aufgabe den Schülern."
enriched_statement = "Der Pädagoge erläutert den Task den Schülern."

# Berechne Vektorrepräsentation (Embedding-Vektor)
original_embedding = model.encode(original_statement)
nearly_original_embedding = model.encode(nearly_original_statement)
enriched_embedding = model.encode(enriched_statement)

cosine_score = cosine_similarity([original_embedding], [enriched_embedding])[0][0]
cosine_score_high = cosine_similarity([original_embedding], [nearly_original_embedding])[0][0]

print(f"Original-Satz: {original_statement}")
print(f"Hohe Ähnlichkeit: {enriched_statement}")
print(f"Angereicherter Satz: {enriched_statement}")
print(f"Cosine Similarity High: {cosine_score_high:.4f}")
print(f"Cosine Similarity: {cosine_score:.4f}")

Original-Satz: Der Lehrer erklärt die Aufgabe den Schülern.
Hohe Ähnlichkeit: Der Lehrer erläutert die Aufgabe den Schülern.
Angereicherter Satz: Der Pädagoge erläutert den Task den Schülern.
Cosine Similarity High: 0.9503
Cosine Similarity: 0.6875
```

Source Code 8 - Die Bedeutung der Sätze ist ähnlich, obwohl unterschiedliche Worte gewählt wurden. Im Vektorraum stehen die die beiden Vektoren der beiden Sätze nahe zueinander. Das Mass der Cosine Simliarty gibt Aufschluss.

Cosine Similarity-Wert	Bedeutung
0.9 – 1.0	Sehr hohe Ähnlichkeit: Die Sätze sind fast identisch, mit minimalen Unterschieden (z. B. Synonyme).
0.8 – 0.9	Hohe Ähnlichkeit: Die Sätze haben eine sehr ähnliche Bedeutung, aber leichte Unterschiede in Wortwahl oder Struktur.
0.6 – 0.8	Moderate Ähnlichkeit: Die Sätze teilen einen gewissen Kontext, haben jedoch unterschiedliche Formulierungen oder Details.
0.4 – 0.6	Geringe Ähnlichkeit: Es gibt eine gewisse semantische Überlappung, aber die Unterschiede überwiegen.
0.2 – 0.4	Sehr geringe Ähnlichkeit: Die Sätze haben kaum gemeinsame Bedeutung.
0.0 – 0.2	Keine Ähnlichkeit: Die Sätze sind inhaltlich komplett unterschiedlich.

Tabelle 11- Bedeutung des Cosine Similarity Werts

Die Verbindung der beiden Formeln

Die Funktion der Cosine Similarity in Verbindung mit den Embeddings lässt eine Aussage zu wie ähnlich sich die Statements in der Bedeutung sind.

- Werte bei 1 vermitteln inhaltlich die gleiche Botschaft und haben die gleiche Bedeutung
- Werte bei 0 geben an das die Vektorrepräsentationen in der Botschaft nicht identisch sind.
- Werte von -1 repräsentieren die gegensätzliche Botschaft

Der Wert ist geeignet um eine Aussagen über die semantische Ähnlichkeit zu treffen.

Für unseren Usecase ist die Metrik von grosser Bedeutung, da wir so die generierten Outputs mit dem Original vergleichen können.

Conclusion

Mit beiden Qualitätsmetriken kann man nun Aussagen treffen ob die semantische Bedeutung und die Wortwahl nahe am Originalstatment liegen.

Ist die TF-IDF-basierte Cosine Similarity hoch wurde die gleiche Satzstruktur und identische Wörter verwendet. Falls die Embedding-basierte Cosine Similarity hoch ist ist die semantische Bedeutung gegeben. Semantik kann aber auch gegeben sein ohne das syntaktische Nähe besteht.

3.6.3 Lesbarkeitsindizes

Weitere Metriken sind die Lesbarkeitsindizes.[13] Sie werden verwendet um Texte für unterschiedliche Zielgruppen anzupassen und können so zur Messung der Verständlichkeit eines Textes verwendet werden.

Flesch-Reading Ease (Support für Deutsch, Englisch)

Misst mit einer Skala von 0 bis 100 wie leicht ein Text zu lesen ist.

- Hoher Wert von 70 bis 100, bedeutet der Text ist einfach verständlich (z.B. Kinder)
- Tiefer Wert von 0 bis 30, bedeutet der Text ist anspruchsvoll (z.B. Wissenschaftliche Publikationen)

Formel zur Berechnung:

$$206.835 - 1.015 \left(\frac{\text{total words}}{\text{total sentences}} - 84.6 \frac{\text{total Syllables}}{\text{total words}} \right)$$

Herkunft der Konstanten:

- **206.835** ist eine Basiskonstante. Sie sorgt dafür, dass der Score in einen Bereich von 0 bis 100 fällt. Die Wahl dieser Zahl war empirisch, basierend auf der Analyse vieler englischer Texte.
- **1.015** ist der Multiplikator für die durchschnittliche Satzlänge (Wörter pro Satz). Längere Sätze senken die Lesbarkeit, und dieser Faktor modelliert diese Auswirkung.
- **84.6** ist der Multiplikator für die durchschnittliche Anzahl der Silben pro Wort. Mehr Silben pro Wort bedeuten ein höheres Verständnisniveau.

Evaluation der Messwerte:

Messwert	Schwierigkeitsgrad des Leseniveau
90-100	Very Easy
80-89	Easy
70-79	Fairly Easy
60-69	Standard
50-59	Fairly Difficult
30-49	Difficult
0-29	Very Confusing

Tabelle 12 - Flesch Reading Ease Evaluation [14]

Flesch-Kincaid (Support English)

Misst auf welchem US-Schulniveau ein Text verständlich ist.

Das Resultat stellt die US-Klassenstufe dar, in welcher sich ein Schüler befindet. Der Index dient Eltern, Lehrer, Bibliothekaren Büchern und Texte zu klassifizieren.

Formel zur Berechnung: $(0.39(\text{durchschnittli. Satzlänge}) + 11.8(\text{durchschnittli. Silben pro Wort}) - 15.59)$

$$0.39 \left(\frac{\text{Total Wörter}}{\text{Total Sätze}} \right) + 11.8 \left(\frac{\text{Total Silben}}{\text{Total Wörter}} \right) - 15.59$$

Herkunft der Konstanten:

- 0.39 multipliziert die durchschnittliche Satzlänge und stellt dar, wie stark lange Sätze die Komplexität erhöhen.
- 11.8 multipliziert die durchschnittliche Anzahl der Silben pro Wort. Längere Wörter mit mehr Silben erhöhen die Komplexität deutlich, und dieser Faktor gibt die Stärke dieser Auswirkung an.
- 15.59 ist eine Basiskonstante, die hilft, den Score mit der Schuljahresstufe abzugleichen.

Gunning Fog Index (Support English)

Misst ebenfalls wie viele Jahre Bildung notwendig sind, um einen Text zu verstehen. Der Wert ist leicht höher als der Schulklassenindex.

- Wert von 7 bis 8 entspricht einem leicht verständlichen Text
- Wert > 12 entspricht einem komplexen Text

Formel zur Berechnung:

$$0.4 \left(\left(\frac{\text{Wörter}}{\text{Sätze}} \right) + 100 \times \left(\frac{\text{komplexe Wörter}}{\text{Wörter}} \right) \right)$$

Herkunft der Konstanten:

- 0.4 ist ein Faktor, der den Score normalisiert, damit er gut mit den Lesbarkeitsniveaus korreliert.
- Der Wert 100 in der Formel dient dazu, den Prozentsatz der komplexen Wörter auszudrücken.

Evaluation der Messwerte:

Fog Index	Leseniveau nach Stufe
17	College graduate
16	College senior
15	College junior
14	College sophomore
13	College freshman
12	High school senior
11	High school junior
10	High school sophomore
9	High school freshman
8	Eighth grade
7	Seventh grade
6	Sixth grade
<6	... grade

Tabelle 13 - Flesch Kincaid Evaluation [15]

Beispiel mit anspruchsvollem und simplem Text

```
import textstat

def calculate_readability(text: str) -> dict:
    readability_scores = {
        'flesch_reading_ease': textstat.flesch_reading_ease(text),
        'flesch_kincaid_grade': textstat.flesch_kincaid_grade(text),
        'gunning_fog': textstat.gunning_fog(text),
    }
    return readability_scores

def is_quality_acceptable(readability_scores: dict) -> bool:
    # Define thresholds for acceptable quality
    if readability_scores['flesch_reading_ease'] < 60:
        return False
    if readability_scores['gunning_fog'] > 12:
        return False
    return True

# Beispieltext zur Berechnung
difficult_text = """
Complexity is often an indicator of academic rigor, especially in subjects like philosophy,
mathematics, and linguistics. However, clear communication is essential for conveying ideas
effectively.
Simplifying language without losing depth is an art, one that requires skill and insight.
In academic writing, balancing simplicity and complexity is a constant challenge.
"""

simple_text = """
Cats are popular pets. They are small, soft, and playful. Many people like cats because they are
independent and clean.
Cats sleep a lot, but they also love to play. Some cats are friendly, while others are shy.
Taking care of a cat is easy and fun.
"""

# Lesbarkeitsbewertung berechnen
scores = calculate_readability(simple_text)
print("Readability Scores:", scores)

# Qualitätsüberprüfung
quality_acceptable = is_quality_acceptable(scores)
print("Is quality acceptable?", quality_acceptable)

# Difficult Text
Readability Scores: {'flesch_reading_ease': 16.49, 'flesch_kincaid_grade': 14.1, 'gunning_fog': 16.2}
Is quality acceptable? False

# Simple Text
Readability Scores: {'flesch_reading_ease': 88.94, 'flesch_kincaid_grade': 2.8, 'gunning_fog': 4.82}
Is quality acceptable? True
```

Source Code 9 – Lesbarkeit Indizes angewendet auf ein anspruchsvolles und simples Textbeispiel

4 Journal

Der Entwicklungsprozess der Applikation wurde im agilen Verfahren durchgeführt, wobei innerhalb von 7 der insgesamt 8 Sprints die Grundfunktionalität des «DigiBot»-Systems entwickelt wurde.

Im Gegensatz zu klassischen Softwareentwicklungsprojekten, bei denen zunächst Anforderungen gesammelt werden und die Entwicklung anschliessend weitgehend linear erfolgt, enthielt dieses Projekt eine bedeutende Forschungskomponente. Zu Beginn war nicht bekannt, welche Ansätze, Technologien, Konfigurationen und weiteren Details in den einzelnen Schritten erforderlich sein würden, um den Erfolg des nächsten Schritts zu gewährleisten.

Daher wurde die Arbeit nicht nur nach den Prinzipien der agilen Softwareentwicklung, sondern auch stark nach den Prinzipien wissenschaftlicher Experimente durchgeführt. Die Sprints können als einzelne Experimente betrachtet werden, bei denen es nicht nur um das Endergebnis, sondern auch um den zugrunde liegenden Ansatz ging.

Eine klare Dokumentation der Ergebnisse jedes Experiments war von zentraler Bedeutung. Die vollständigen Details dazu sind im Anhang am Ende dieser Arbeit aufgeführt. Eine chronologische Anordnung der Sprintziele bietet eine Gesamtübersicht über die erarbeiteten Inhalte. Diese Informationen sind wie folgt dokumentiert:

Muster Anwendungsversuch X: Titel des Anwendungsversuchs
Ziel des Anwendungsversuchs: Die spezifische Hypothese oder das Ziel des jeweiligen Experiments.
Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Bsp. PW2 angeben, gleich nach dem Setup und Konfiguration der Applikation wurde dies getestet.
Methodik: Quelle / Vorgehen
Resultat: Zusammenfassung der wichtigsten Ergebnisse mit Tabellen, Diagrammen oder Skizzen (wenn erforderlich).
Erkenntnisse und Konsequenzen für das Projekt: Was ist daraus relevant fürs Projekt.
Diskussion: Diskussion und Fazits aus dem aktuellen Sprint

Tabelle 14 - Muster Anwendungsversuch

Eine zentrale Übersicht der Experimente (Protokolle) ist in der folgenden Tabelle enthalten.

Sprintziele		
Sprint	KW	Aktivitäten / Ziele
1	38	– Organisation Die Übersicht über alle Termine wurden in einer Excel-Tabelle über das ganze Semester festgehalten. – Organisation (GitLab / Kanbanboard) Für Versionskontrolle und Issue-Tracking der Applikation wurde ein Repository eingerichtet und die Issues gemäss Sprints im Kanbanboard angelegt. – Zeitmanagement mit GitLab Zusätzlich wurde ein Python Programm geschrieben, um geplante und tatsächliche Zeit von Git Issues als Excel herunterzuladen. – Risk Assessment Um Gefahren und Risiken zu identifizieren wurde eine Risikanalyse erstellt. – Aims/Targets festlegen Ziele definieren, um den fertigen Umfang der Applikation festzulegen. – Architecture Diagram (Component-/Flowdiagramm) Visualisierung der verwendeten Komponenten – Technologien-Research Vertiefung in Literatur und Tutorials und erste Tests. – Langflow (No-Code-Plattform) – Integration von OpenAI
2	39-40	– CRUD-Webapplikation in Betrieb nehmen Das Frontend und Backend läuft Lokal und in der Cloud. – CI/CD Pipeline (Lokal/Cloud) Die CI/CD Pipeline ermöglicht automatisches Deployment Lokal und in der Cloud. – Prototyping mit Python – 1. Integration des Langchain-Framework für Interaktion mit OpenAI – 2. Prüfung des Langchain-Framework Lokal und im Cloud Deployment – 3. Integration Simple Chatbot – 4. SJT mit Kontext aus «Personal Profile»
3	41-42	– Dokumentation Konzept, um iterativen Prozess der Anwendungsversuche zu dokumentieren. – Orchestrierung, Modularer Aufbau des Quellcodes Strukturierung der Python-Prototypen
4	43-44	Orchestrierungsprototype in grundlegende Komponenten übertragen (Vue und FastAPI) Die einzelne Komponenten: – Settings – Grundeinstellungen für einzelnen Benutzer:innen – Chatbot – für die Erstellung des «Personal Profile» – Questionary – Generierung und Interpretation der Statements. Basis für Benutzertests und Testumgebung für den Administrator – Results – Auswertung der Resultate für einzelne Benutzer:innen und Administrator – Datenbank Entity-Relationship-Model (ERD) erarbeiten und implementieren. – Evaluationsmöglichkeit für generierte Statements Implementieren lationship-Model – User Experience Integration von «DigiBot» im Chatbot und in der Generierung
5	45-46	– Frontend Abstimmung der einzelnen Komponenten

		– Draft Meta Questions Erste Implementierung zur Bewertungsmöglichkeit der Statements – Datenbankanbindung für generierte Statements und Antworten vom Benutzertest erweitern ERD wurde erweitert und implementiert – Asynchroner Mechanismus um die generieren Statements ins Frontend zu streamen Abstimmung der Berechnung und Speicherung der Metriken
6	47-48	– Draft für User Test – Applikations-Flow für Respondent – Restriktionen der Views – Applikations-Flow für Admin – Control Panel für Admin Zusätzliche Features, Special Cases implementieren: – Zeige Unterschied zwischen Original und Personalized Statement – Random Anordnung von Original und Personalized Statement (Toogle for Labels) – Meta Questions anzeigen – Meta Daten (Metriken) anzeigen – Settings der Benutzer:innen wechseln – Länge des Personalized Statement festlegen (1.3x, 2x , 3x Länge des Originalstatements) – Asynchrone Funktion für Streaming fertigstellen Debugging im Cloud Deployment – Resultseiten für Auswertungen – Respondent-View: Score mit Digital Competence in jeweiligem Topic – Piechart für Personalized Statement / Original Statements – Barchart für alls Metaquestions – Admin-View: Resultate aller Benutzer:innen – Filtermöglichkeit nach Benutzer:in – Filtermöglichkeit nach Settings – Filter nach einzelner Question – Meta Question Builder Grundlegende Konfigurationsmöglichkeit der Metaquestions
7	49-50	– Konzept für User Test – Settingkombinationen für User-Test-Gruppen erstellen und Laden in Respondent-View – Prolific verknüpfen mit Applikation – Metric Overview zur Evaluation von finalen Metriken für User Test (Excel) subjektive Prognose mit Evidenz bestätigen – Anpassung der Metaquestions – Bias reduzieren in Benutzertest – Slider anstatt Chip-Buttons für bessere UX – Kompaktere Darstellung (Referenz Qualimetrix) – Wechsel der Prompttechniken im Control Board Admin – Zero-Shot oder Few-Shot Prompting – Qualitätsmetriken in Datenbank speichern – Gunning Fog, (Education Level) – Flesch Kincaid Grade (US Grade Level) – Flesch Reading Ease (Text Readability) – «Personal Profile Builder» – Validierung mit AI einfügen

Tabelle 15 - Sprint Goal Overview

5 Konzeption

Das fünfte Kapitel «Konzeption» beschreibt die Grundlagen und Anforderungen des «DigiBot»-Projekts. Es umfasst die funktionalen und nicht-funktionalen Anforderungen, die Risikoanalyse sowie die Systemarchitektur mit ihren in Modulen geteilten Komponenten. Zudem werden der CI/CD-Ablauf zur Bereitstellung und die Benutzertest vorgestellt.

5.1 Anforderungen

Die Anforderungen des «DigiBot» Projekts umfassen sowohl funktionale als nicht-funktionale Anforderungen, die sicherstellen, dass der Inhalt und Umfang der Arbeit klar definiert ist. Diese Anforderungen sind in spezifische Kategorien unterteilt, die die erwarteten Ergebnisse detailliert beschreiben.

5.1.1 Funktionelle Anforderungen

Funktionale Anforderungen (engl. «functional requirements», FR) beschreiben die konkreten Funktionen und Fähigkeiten, die das (technische) Produkt bereitstellen muss und die definierten Ziele zu erreichen. [4] Im Kontext des Projekts «DigiBot» umfassen diese die funktionellen Anforderungen die Bereitstellung einer webbasierten Umgebung (A), Anforderungen an die Generative Aspekte des Systems (B) und Anforderungen zur Verwaltung und Untersuchung von Resultaten (C).

FR	Art	Anforderung	Beschreibung
A1	Umgebung	«DigiBot» Webplattform	Eine Webbasierte Plattform die den Zugang zum Chatbot und den Fragebogen bietet. Sowie Tools zur Auswertung von erfassten Daten gibt.
A2		Benutzertest Funktionalität	Funktionalität auf der Webplattform, um repräsentative Benutzertests zur Bewertung von Generationsqualität durchführen zu können.
B1	Generative Anforderung	Generierung von validiertem Profil	Generierung von Benutzerprofilen auf Grund von Benutzereingaben. Sowie Prüfung der Eingaben auf Akzeptanz und Inhalt (Schwellwert für Antwortakzeptanz)
B2		Generierung von SAs	Erstellen von personalisieren Umfragen anhand von generierten Profilen und «DigComp» Fragebogen.
B3		Qualität, Vertrauenswürdigkeit & Reproduzierbarkeit	Präzision in der Fragegenerierung und Qualitätskontrolle.
C1	Auswertung & Statistiken	Frage- & Prompt Verwaltung	Benutzer können Fragen und die zugrundeliegenden Prompts anpassen und konfigurieren.
C2		Admin-Dashboard	Debugging-Tools, Zugriff auf Logs und Einblick in generierte Fragen und Antworten.

Tabelle 16 - Funktionelle Anforderungen

5.1.2 Nicht Funktionelle Anforderungen

Nicht funktionelle Anforderungen (engl. «non-functional requirements», NFR) definieren die Qualitätsmerkmale und Rahmenbedingungen des Systems, die sicherstellen, dass die funktionalen Anforderungen zuverlässig, effizient und benutzerfreundlich umgesetzt werden. [4]

Im «DigiBot» Projekt sind die Anforderungen die angedacht und wünschenswert sind, aber keine hohe Priorität in der Entwicklung einnehmen.

NFR	Art	Anforderung	Beschreibung
A1	Umgebung	Lokalisierung	Englische und deutsche Übersetzung auf der Webseite.
B1	Generative Anforderung	Verfügbarkeit und Antwortzeit	Möglichst kurze Antwortzeiten bei generativen Methoden; hohe Systemverfügbarkeit.
C1	Auswertung & Statistik	Datenexport	Strukturierte Datenausgabe für analytische und wissenschaftliche Zwecke.

Tabelle 17 - Nicht Funktionelle Anforderung

5.2 Risikoanalyse

Um Risiken frühzeitig zu identifizieren und um aktive Massnahmen zu ergreifen, diese zu reduzieren oder zu beseitigen, wurde eine Risikoanalyse durchgeführt. Die Risikofaktoren wurden gemäss den Kategorien Wahrscheinlichkeit und Auswirkung mit einer Likert-Skala von 1 bis 5 bewertet. Zu jeder Position ist eine konkrete Lösungsstrategie angegeben.

- **Accept:** Das Risiko wird akzeptiert muss jedoch kontinuierlich überprüft werden.
- **Reduce:** Risiko gezielt reduzieren und mit individueller Strategie behandeln
- **Transfer:** Teilschritte auslagern oder übertragen
- **Avoid:** Potenzielles Risiko stoppen, nach alternativer Lösung anwenden

5.2.1 Risikoanalyse

Nr.	Risk	Probability (1-5)	Impact (1-5)	Strategy
1	Den optimalen Techstack wählen	4	5	Reduce - Vertikaler Slice für Technologie ASAP, Research in der Anfangsphase nicht vernachlässigen. Gegenüberstellung von Frameworks und alternativen Lösungen
2	Projektidee verstehen, relevante Requirements erfassen	3	4	Avoid - Premeeting bereits vor den Sommerferien, Bei grösseren Änderungen von Requirements dies realistisch Besprechen und festhalten.
3	Sehr junge Technologie, neue Frameworks	4	2	Transfer - Tutorials, Dozenten nachfragen.
4	Applikation ist nicht kompatibel mit Frameworks (Langflow, Langchain)	4	3	Reduce - Vertikaler Slice für Technologie ASAP, Prüfe wie Langflow integriert werden kann
5	LangflowNocode-UI (für einfache Wartbarkeit) unterstützt geforderte Features für persönliche Einschätzung nicht	3	3	Transfer - Direkt Code schreiben
6	Wartbarkeit nach Beendigung des Projekts	4	3	Reduce - in wöchentlichen Meetings genau informieren, wie Applikation aufgebaut ist, welche Kenntnisse werden benötigt um die Applikation zu warten.
7	Zeitplanüberschreitung	3	5	Reduce - starte Projektmanagement in Woche 1, Frühzeitige Ressourcenplanung, Backup Ressourcen
8	Kommunikationsprobleme, Missverständnisse, falsche Erwartungen	4	4	Reduce - Bi-Weekly Meetings mit klarer Agenda definieren, Verantwortlichkeiten in Kanban definieren, Mockups
9	Technologische Änderungen (LLM) -	4	3	Accept - Evaluieren, ob Neuerung direkt einbezogen werden können

	Technologien in diesem Bereich ändern sich rasend schnell			
10	Zeitverlust durch Implementierung der Kernlogik in Webapplikation	3	5	Transfer – Basis Web Applikation (Vue-Frontend, FastApi Backend) herbeiziehen. Fokus und Ressourcen auf Kernziele ausrichten
11	Unberechenbarkeit von LLM	5	4	Reduce – Qualitätsmetriken und Testingmethoden evaluieren
12	Falsche Testmethoden der AI-Integration	5	4	Transfer – Besprechung und optimale Testingstrategie ausarbeiten

Tabelle 18 - Übersicht der potenziellen Risiken

5.2.2 Risiko-Matrix

Die Positionen aus der Übersicht 5.2.1 wurden in eine Risiko-Matrix eingebettet. Auf der X-Achse ist der Schaden und auf der Y-Achse die Eintrittswahrscheinlichkeit abgebildet.

Wahrscheinlichkeit	5					11. 12.	
	4			3.	4.	8.	1.
	3				5.	2. 9.	7. 10.
	2						
	1						
	0						
		0	1	2	3	4	5
Schaden							

Tabelle 19 - Risikomatrix

5.2.3 Evaluieren der Risiken und Massnahmen

Die Risiko-Matrix zeigt das folgende Positionen erhöhtes Risiko darstellen:

- «Position 1: Techstack»
- «Position 7: Zeitplanüberschreitung»
- «Position 10: Zeitverlust durch Implementierung der Kernlogik in Webapplikation»
- «Position 11: Testing der AI-Integration»
- «Position 12: Unberechenbarkeit von LLM»

Um Position 1 und 10 entgegenzuwirken, wurde ein bestehendes Gerüst einer Webapplikation mit Vue-Frontend, FastApi-Backend verwendet um speditiv die weiteren Technologiekomponenten und Frameworks auf die Kompatibilität zu prüfen.

Um Position 11 und 12 zu bearbeiten, wurden Quality Gates bei der Generierung von Inhalt durch LLM festgelegt und verschiedene Qualitätstest betreffend syntaktische und semantische Unterschiede eingeführt. Da die LLMs kein Determinismus garantieren, wurde neben den automatisierten Qualitätschecks auch ein Vorgehen für Benutzertests erarbeitet.

Da in kurzer Zeit mehrere Technologien recherchiert und evaluiert werden, wurden in den Sprints Anwendungsversuche gemacht, die iterativ evaluiert wurden, um Position 7 bestmöglich entgegenzuwirken.

5.3 Mockups

Um unsere Stakeholder kennenzulernen und die Projektidee vor dem effektiven Projektstart im September 2024 zu verstehen, wurden nach einem ersten Treffen die Mockups und ein Flowchart erstellt.




Abbildung 11 - Flowchart, um die Projektidee zu visualisieren

Die visuelle Darstellung der einzelnen Teilschritte dient als Diskussionsbasis und vereinfacht die Kommunikation und das gemeinsame Verständnis. Im Bezug auf unsere Risikoanalyse 5.2.1. konnten wir somit folgende Risiken reduzieren:

- «Position 2 - Projektidee verstehen, relevante Requirements erfassen»
- «Position 8 - Kommunikationsprobleme, Missverständnisse, falsche Erwartungen»

Step 1 - Personal Profile



Oh, hey! I'm Pam Beesly.



Hi! Welcome to the digital competencies assesment.
Before we start, how may I call you?



I'm the **receptionist** at Dunder Mifflin. I've been holding down this role **for about five years** now



What is your current job role or title, and how many **years of professional experience** do you have in your current field?




When it comes to digital tasks at Dunder Mifflin, I try to keep things pretty straightforward: I start my day by **checking my email and calendar in Outlook**. I prioritize tasks based on **urgency and importance**, making sure to tackle the most critical items first. **Outlook** is my go-to for



How do you typically approach digital tasks in your work? Please **describe any strategies, tools, or methods** you prefer to use to manage your digital work effectively.

Step 2 - Enrichment of Predefined Questions



Step 3 - Personal Selfassessment / Situational Judgment Test (5 rubrics)



How do you verify the accuracy of a visitor's appointment details before confirming their meeting with a manager?



☒ I check the manager's calendar in Outlook and verify the appointment details.

☐ I call the manager directly to confirm.

☐ I trust the visitor's word and proceed with the appointment.

☐ I look at the previous day's schedule for similar entries.

NEXT →

← PREVIOUS

Step 4 - Results as overview and download

Great, you are finished. Check your results.





1.1 Browsing, searching, filtering data, information and digital content

1.2 Evaluation data, information and digital content

1.3 Managing data, information and digital content



2.1 Interacting through digital technologies

2.2 Sharing throught digital technologies

2.3 Enganging in citizenship through digital technologies

2.4...

...

DOWNLOAD ↓

Abbildung 12 – Mockups der Teilschritte zum visuellen Verständnis und als Diskussionsbasis

5.4 Systemarchitektur

Die Systemarchitektur des «DigiBot»-Projekts basiert auf einer modularen Struktur, die verschiedene Komponenten und Prozesse integriert. Diese Architektur ermöglicht eine nahtlose Kommunikation zwischen den einzelnen Komponenten und externen Diensten wie dem OpenAI-Service. Die Folgenden Kapitel gehen auf den Aufbau der Architektur und der Hauptprozesse ein.

5.4.1 System Komponenten Übersicht




Abbildung 13 - Komponentenübersicht

Das «DigiBot»-System basiert auf einer modularen Architektur, die in einer Cloud-Umgebung bereitgestellt wird. Die Hauptkomponenten umfassen das Frontend (bzw. «Web Service»), das Backend, die Datenbank und den NLP-Service von OpenAI. Diese Komponenten interagieren nahtlos, um das «DigiBot»-System für Nutzer:innen über das Internet bereitzustellen.

Das Frontend der «DigiBot»-App ist eine in Vue.js implementierte Webanwendung, die über den Browser zugänglich ist. Über eine HTTP-API kommuniziert es mit dem Python Backend, es werden REST-Prinzipien befolgt. Sowohl Frontend als auch Backend werden in Docker-Containern auf der Google Cloud im Artifact Registry betrieben.

Die PostgreSQL-Datenbank, die im Google Cloud SQL Service gehostet wird, speichert alle relevanten Daten wie Nutzerprofile, Testergebnisse und generierte Inhalte. Sie ist direkt mit dem Backend verbunden, um schnellen und zuverlässigen Zugriff auf die Daten zu ermöglichen.

Der NLP-Service basiert auf GPT-4 von OpenAI und ist über die OpenAI API in das Backend integriert. Er wird genutzt, um personalisierte Inhalte zu erstellen und zu bewerten.

Das folgende Diagramm (Abbildung 32) zeigt die detaillierten Interaktionen und Verantwortlichkeiten der einzelnen Systemkomponenten innerhalb der «DigiBot»-Architektur. Es verdeutlicht, wie die Hauptbestandteile zusammenarbeiten, um die verschiedenen Funktionen des Systems bereitzustellen.




Abbildung 14 - Detail Komponentenübersicht

5.4.2 Systemfluss




Abbildung 15 - Systemfluss Übersicht

Der Systemfluss des «DigiBot»-Projekts beschreibt die logische Abfolge der Nutzerinteraktion sowie die Prozesse innerhalb des Systems. Ziel ist es, einen klaren Überblick über die Schritte von der Anmeldung bis zur Ergebnisdarstellung zu bieten. Das Diagramm oben zeigt die Benutzerpfade sowohl für reguläre Nutzer: innen (Respondents) als auch für den Administrator:innen (Admins).

Login

Der Einstiegspunkt für alle Nutzer:innen ist der Login. Je nach Nutzerrolle (Respondent oder Admin) wird zur entsprechenden Seite weitergeleitet:

- «Respondent» gelangen zu Respondent Landing- bzw. Homepage.
- «Admins» erhalten Zugriff auf alle Seiten. Sinnvoll ist für eine Durchführung bei den Settings zu starten.

Respondent Homepage

Auf der Startseite erhalten Teilnehmer:innen Informationen zum aktuellen Test sowie die Möglichkeit, ihre «Prolific-ID» einzugeben, um die Verknüpfung mit dem «Prolific»-Profil zu ermöglichen. Zudem können sie den Testvorgang starten und werden anschliessend zum «Profile Builder» weitergeleitet.

Einstellungen




Abbildung 16 - Settings Modul

Das «Settings»-Modul bietet Administratoren verschiedene Konfigurationsmöglichkeiten. Dazu gehören allgemeine Einstellungen wie die Auswahl der Nutzer, die Sprache, die Anzahl der Fragen und die Art des folgenden Fragebogens. Zudem besteht die Möglichkeit, ein Standardprofil auszuwählen und die Umfrage direkt mit diesem auszufüllen. Wird diese Option gewählt, erfolgt eine direkte Weiterleitung zur Umfrage. Andernfalls führt der nächste Schritt zum Profile Builder.

Profil Builder




Abbildung 17 - Profil Builder Modul

Der «Profil Builder» ist ein zentrales Modul, das Nutzerprofile auf Grundlage von Eingaben innerhalb eines Chatbots erstellt. Der Prozess ist in folgende Schritte unterteilt:

Nr.	Aktion	Beschreibung
1	Fragen stellen	Der Chatbot stellt gezielte Fragen anhand eines Skripts, die der Nutzer beantwortet. Die Antworten werden durch einen Validierungsprozess überprüft.
2	Quality Gate	- Antworten, die nicht den Qualitätskriterien entsprechen, lösen eine Rückfrage oder Anpassung aus. - Sollten zu viele Rückfragen pro Frage getätigt werden, wird die Bestehende Antwort weiterverarbeitet.
IF	Beendigung	Schritt 1 und 2 wiederholen sich, bis alle Fragen beantwortet wurden. Sind alle zufriedenstellend beantwortet wird mit Schritt 3 fortgefahren.
3	Profil erstellen	Die validierten Antworten werden in eine Profilvorlage eingefügt.
4	Optionale Qualitätskontrolle	Bei Bedarf werden zusätzliche Klärungsfragen gestellt, um die Datenqualität zu verbessern.
5	Speicherung und Übergang	Das erstellte Profil wird gespeichert und für den nächsten Schritt, den Umfragen, bereitgestellt.

Tabelle 20 - Porfil Builder Fluss

Das Modul ermöglicht die Generierung und Speicherung eines Qualitativen Benutzerprofils.

Umfrage




Abbildung 18 - Questionary Modul

Das «Questionary»-Modul generiert einen personalisierten Fragenbogen auf Basis des erstellten Profils und gibt diesen in einem asynchronen Verfahren den Nutzer: innen zur Verfügung.

Parallele Generation und Umfrage				
Generation			Umfrage	
Nr.	Aktion	Beschreibung	Aktion	Beschreibung
1	Aussagen-Generation	Aussagen aus dem DigComp-Framework werden durch GPT-4 angereichert.	Warten auf Nächste Frage	Das System wartet auf die nächste Frage im Generationsprozess.
2	Quality Gate	Ein Quality Gate überprüft die angereicherten Aussagen. Bei mangelhafter Qualität erfolgt eine erneute Verarbeitung.	Befragung der Nutzer: innen	Die Nutzer beantworten die Fragen.
IF	Ende	Der Generationsprozess endet, sobald alle Fragen in der Umfrage bearbeitet wurden.	Ende	Der Umfrage endet, nachdem alle Fragen im Fragebogen beantwortet wurden.
Speichern und Ergebnisse				
Aktion			Beschreibung	
3	Speichern der Ergebnisse		Die angereicherten Aussagen und Umfrageantworten werden periodisch gespeichert und für die Resultatseite und Analyse bereitgestellt.	

Tabelle 21 - Questionary Fluss

Das System erlaubt es verschiedenen Arten von Umfragen durchzuführen und diese dynamisch mit Nutzerprofilen zu bereichern.

Resultate und Statistik




Abbildung 19 - Results and Statistic Modul

Das Modul «Results and Statistics» präsentiert die Ergebnisse der Umfragen und bietet umfassende Analysemöglichkeiten. Die angezeigten Statistiken variieren je nach Art der Umfrage und der Rolle des Benutzers.

Bei der Durchführung einer SA-Umfrage werden die Ergebnisse in Kategorien des DigComp-Frameworks zusammengefasst dargestellt.

Für einen A/B-Test erhält der Respondent einen Bestätigungsschlüssel für «Prolific» sowie eine Übersicht, die den zusammengefassten Meta-Fragebogen enthält.

Administratoren haben Zugriff auf sämtliche Benutzerumfragen und deren detaillierte Auswertungen, was eine umfassende Analyse und Verwaltung ermöglichen.

5.5 Entity-Relationship Modell

Das Entity-Relationship-Diagramm (ERD) zeigt die Datenbankstruktur des «DigiBot»-Systems und die Beziehungen zwischen den zentralen Entitäten wie Benutzer: innen, Profileinstellungen, generierten Statements und Antworten. Die Entitäten und ihre Attribute sind so gestaltet, dass sie die Anforderungen an Funktionalität, Validierung und Auswertung des Systems optimal unterstützen.




Abbildung 20 – Entity-Relationship Modell

5.6 CI/CD-Ablauf

Der CI/CD-Ablauf (Continuous Integration/Continuous Deployment) dient dazu, die «DigiBot»-App einfach online bereitzustellen. Dabei werden das Google Cloud SDK und Docker genutzt, um die Backend- und Frontend-Komponenten in GitLab automatisch zu bauen, zu testen und anschliessend in einem Docker-Container auf einem Google-Cloud-Server online zugänglich zu machen.

Der Pipeline-Prozess läuft in einem Container auf Basis des *google/cloud-sdk:latest* Images, um die Kompatibilität mit dem Cloud-Server zu gewährleisten. Die Docker-Dienste werden durch Docker-in-Docker (dind) bereitgestellt, sodass Docker-Images innerhalb der Pipeline gebaut und gepusht werden können. Im GitLab werden Umgebungsvariablen für die Docker-Konfiguration und die Verbindung mit dem Google-Server bereitgestellt, um die Authentifizierung und das Deployment auf der Google Cloud zu ermöglichen. Das Google Cloud-Setup enthält zudem eine Umgebungsvariable mit dem OpenAI-API-Key, was die Integration von OpenAI-Services in die Anwendung ermöglicht. Die Pipeline durchläuft drei Hauptstages:




Abbildung 21 - CI/CD Ablauf

1. **Check-Updates:** Prüft, ob Änderungen ausserhalb der Backend- und Frontend-Ordner erfolgt sind, und gibt eine Benachrichtigung aus.
2. **Build:** Baut und pusht Docker-Images für Backend und Frontend, wenn Änderungen in den jeweiligen Ordnern festgestellt werden.
3. **Deploy:** Die gebauten Images werden anschliessend zu Google Cloud Run deployed, wodurch die neuesten Versionen von Backend und Frontend live geschaltet werden.

5.7 Benutzertest

Um erste Resultate in Bezug auf die grundlegenden Konfigurationen des Chatbots und des Generierungsmechanismus zu erhalten, haben wurden ein Benutzertest durchführt.

Der Benutzertest beinhaltet:

- **Profilerstellung mit dem Chatbot**
 - Der Chatbot enthält 5 grundlegende Fragen, welche die Jobprofil, Jobdomain, Expertise in Jahre, die Digital Proficiency sowie die Primary Tasks der Benutzer:innen erfasst.
- **Generierung von persönlichen Statements**
 - Als Datengrundlage für die Generierung der Fragen werden generische Statements des Selfassessment von Digicomp aus der Kategorie «Information and data literacy» [16, S. 154] verwendet. Das erstellte Userprofile und das Originalstatement werden in einem Few-Shot-Prompt eingebettet. Der Prompt enthält als Generierungshilfe verschiedenen Beispielen von verschiedenen Jobprofilen als Referenz.
- **Bewertung der Statements**
 - Jedes generierte Statement wird im Vergleich zum Original mit folgenden Fragen bewertet

Clarity of Statement	Which statement is easier to understand?
Readability of Statement	Which statement is easier to read?
Specificity of Statement	Which statement offers greater detail?
Relevance to Profession	Which statement fits your profession?
Helpfulness for Self-Assessment	Which statement is helpful for self-assessments?

Tabelle 22 – Meta-Fragen

Questionary

Your self-assessment is now being created and will be streamed dynamically.

For the 14 sets of statements, review the statements and select the one you prefer.

After selecting a statement, select the options that best matches your experience using the sliders provided.

1. Browsing, searching and filtering data, information and digital content

Select your preferred statement:

1/14

A

I know that different search engines may give different search results, because they are influenced by commercial factors.

B

Understanding the nature of various search engines, it's clear to see that their delivered search results can often differ. This disparity is primarily due to commercial influences that shape the algorithmic preferences of each search engine. Therefore, it's crucial to factor this in during the testing process to ensure accurate results.

Your Preference

Completely Prefer A Somewhat Prefer A Neither Somewhat Prefer B Completely Prefer B

Which statement is easier to understand?

A  B

Which statement is easier to read?

A  B

Which statement offers greater detail?

A  B

Which statement fits your profession?

A  B

Which statement is helpful for a self-assessment?

A  B

100%

Abbildung 22 – Bei der Bewertung wählen Benutzer:innen die favorisierten Statements und vergleichen anschliessend beide Statements.

– Auswertung der Daten für Benutzer:innen

- Benutzer:innen wird das aggregierte Resultat in einem persönlichen Dashboard zur Verfügung gestellt.

– Speicherung und Weiterverarbeitung der Daten

- Für jedes generierte Statement wird die Generierungshistory gespeichert mit den Metriken CosineSimilarity TFIDF und CosineSimilarity Embedding sowie mit Readability-Metriken flesch_reading_ease, flesch_kincaid_grade, gunning_fog.
- Zusammen mit den Bewertungen der Benutzer:innen können so Rückschlüsse bezüglich Qualität getroffen werden.

5.8 Prolific

«Prolific» [17] ist eine Online-Plattform, die es erlaubt Studien, Umfragen und Experimente durchzuführen. Mit Hilfe der Online-Plattform «Prolific» konnten Benutzer:innen rekrutiert und Daten gesammelt werden.




Abbildung 23 - Übersicht des laufenden Benutzertest mit 50 Benutzer:innen (www.prolific.com)

Für den Benutzertest wurden sechs verschiedene Testgruppen angelegt.

- Testgruppe 1 (Few-Shot Prompting, 1,3-fache Textlänge vom Originalstatement)
- Testgruppe 2 (Few-Shot Prompting, 2-fache Textlänge vom Originalstatement)
- Testgruppe 3 (Few-Shot Prompting, 3-fache Textlänge vom Originalstatement)
- Testgruppe 1 (Zero-Shot Prompting, 1,3-fache Textlänge vom Originalstatement)
- Testgruppe 2 (Zero-Shot Prompting, 2-fache Textlänge vom Originalstatement)
- Testgruppe 3 (Zero-Shot Prompting, 3-fache Textlänge vom Originalstatement)

Mit 20 Benutzer:innen wurden ein Pre-Test mit der Konfiguration der Testgruppe 2 gestartet und ein erster Testlauf ausgelöst.

Um anschliessend eine erste repräsentative Aussage zu machen, wurde Testgruppe 2 (Few-Shot Prompting, 2-fache Textlänge vom Originalstatement) ein zweiter Durchlauf vorgenommen mit 50 Usern.

6 Systemintegration

Das sechste Kapitel «Systemintegration» beschreibt die praktische Realisierung der Projektumgebung. Es umfasst die Einrichtung der Entwicklerumgebung, Containerisierung und die Implementierung von der CI/CD-Pipeline. Die Entwicklungsumgebung wird mit Docker und Google Cloud eingerichtet, dabei werden zentrale Komponenten containerisiert und als Artifact in der Cloud bereitgestellt.

Bitte beachten Sie: In diesem Kapitel werden zahlreiche technische Details bereitgestellt. Dies ist beabsichtigt. Es ist äusserst schwierig, die notwendigen Schritte zur Konfiguration einer Cloud-Umgebung zu erlernen. Daher ist ein zentrales Ziel dieses Kapitels, ausreichend detaillierte Informationen bereitzustellen, damit ein nachfolgendes Team die technischen Schritte nachvollziehen und die Arbeit reproduzieren kann.

6.1 Docker Containers

Die Docker-Technologie wurde verwendet, um die Anwendung zu containerisieren, um Konsistenz in den Entwicklungs-, Test- und Produktionsumgebungen zu gewährleisten. Darüber hinaus vereinfacht der Einsatz dieser Technologie die Bereitstellung erheblich (ein einzelner Container kann gestartet werden, anstatt einen Webserver zu konfigurieren) und reduziert gleichzeitig die Kosten, da Container-Umgebungen zu den kostengünstigsten Cloud-Diensten gehören.

Um einen kurzen Überblick zu geben, müssen die folgenden Schritte durchgeführt werden:

Schritt 1: Erstellung der benötigten Dockerfiles.

Um das **Backend im Docker Container** bereitzustellen und zu starten wird auf oberster Ebene «./backend/Dockerfile» ein Dockerfile erstellt:

```
# backend/Dockerfile
FROM python:3.10-slim

WORKDIR /app

COPY app/requirements.txt requirements.txt

RUN pip install --no-cache-dir -r requirements.txt

# Expose port 8080 (for Cloud Run)
EXPOSE 8080

COPY app/ /app

CMD ["uvicorn", "main:app", "--host", "0.0.0.0", "--port", "8080"]
```

Um das **Frontend im Dockercontainer** bereitzustellen und zu starten, wird auf oberster Ebene «./frontend/Dockerfile» ein Dockerfile erstellt:

```
# Use an official Node.js image as a base
FROM node:16-alpine

# Set the working directory inside the container
WORKDIR /app

# Copy package.json and package-lock.json (if present)
COPY package*.json ./

# Install dependencies
RUN npm install
```

```

# Copy the rest of the application
COPY . .

# Build the Vue.js app for production
RUN npm run build

# Install a simple HTTP server to serve the static files
RUN npm install -g serve

# Set the environment to production
ENV NODE_ENV=production

# Expose port 8080
EXPOSE 8080

# Run the app using serve, and ensure it listens on port 8080
CMD ["npm", "serve", "-s", "dist", "-l", "8080"]

```

6.2 Die Google Cloud Platform (GCP)

Obwohl das System auf jeder Cloud- oder On-Premises-Umgebung laufen kann, wurde die Google Cloud Platform (GCP) aus mehreren Gründen gewählt: Das Team hatte Erfahrung mit dieser Umgebung, die Umgebung war während der Testphase praktisch kostenfrei (was ausreichte, um diese Forschung abzudecken), und die bestehende Datenbank lief bereits als Google-SQL-Dienst.

Schritt 2: Installation der GCP-CLI und Einrichtung der Autorisierung.

Um Deployments sowie Änderungen in der Google-Cloud vorzunehmen ist eine grundlegende Authorisierung nötig.

- Installiere Google Cloud SDK
 - <https://cloud.google.com/sdk/docs/install-sdk?hl=de>
- Setze User Role und Permissions unter
 - <https://console.cloud.google.com/iam-admin/>
 - Oder folgende Commands über Kommandozeile

Die erforderlichen Kommandos sind in den nachfolgenden Abbildungen dargestellt.

Um ein Login zu tätigen, muss die folgende Kommando ausgeführt:

```
gcloud auth login
```

Nun müssen die Berechtigungen korrekt gesetzt:

```

# Allows users to view and download artifacts from repositories.
gcloud projects add-iam-policy-binding <PROJECT_ID> \
  --member="user:<USER_EMAIL>" \
  --role="roles/artifactregistry.reader"

# Allows users to read from and push to repositories.
gcloud projects add-iam-policy-binding <PROJECT_ID> \
  --member="user:<USER_EMAIL>" \
  --role="roles/artifactregistry.writer"

```

```
# Full control over repositories, including the ability to create and delete them.
gcloud projects add-iam-policy-binding <PROJECT_ID> \
  --member="user:<USER_EMAIL>" \
  --role="roles/artifactregistry.admin"
```

Schritt 3: Konfiguration der Docker-Umgebung mit der richtigen GCP-Region.

Die Region wird mit der folgenden Kommandozeile konfiguriert:

```
# here with example region
gcloud auth configure-docker europe-west6-docker.pkg.dev
```

Um zu bestätigen, dass die Einstellung richtig gesetzt ist soll die Web-Ansicht so aussehen, wie in der folgenden Abbildung dargestellt:

The screenshot shows the Google Cloud IAM console for the 'DigiBot' project. The left sidebar contains navigation links for IAM, PAM, and various organizational settings. The main content area is titled 'Berechtigungen für das Projekt "DigiBot"' and shows a list of users and their roles. The table has columns for 'Typ', 'Hauptkonto', 'Name', 'Rolle', and 'Sicherheitsinformationen'. The users listed include service accounts for Compute Engine, Cloud Build, App Engine, and GitLab Runner, as well as a human user 'Roman Schneller'.

Typ	Hauptkonto	Name	Rolle	Sicherheitsinformationen
	351127941853-compute@developer.gserviceaccount.com	Compute Engine default service account	Bearbeiter	9131 / 9131 nicht erforderliche Berechtigungen
	chs191991@gmail.com	Artifact Registry Writer Inhaber	Artifact Registry Writer Inhaber	10053 / 10371 nicht erforderliche Berechtigungen
	cloudbuild@digi-bot-437412.iam.gserviceaccount.com	Cloud Build Service Account	Cloud Domains-Administrator, Cloud Run-Administrator, Dienstkontonutzer, Storage-Administrator	
	digi-bot-437412@appspot.gserviceaccount.com	App Engine default service account	Bearbeiter	9131 / 9131 nicht erforderliche Berechtigungen
	gitlab-runner-sa@digi-bot-437412.iam.gserviceaccount.com	GitLab Runner Service Account	Artifact Registry Writer, Cloud Run-Administrator, Dienstkontonutzer	
	romanschneider@gmail.com	Roman Schneller	Artifact Registry Writer, Bearbeiter	8972 / 9131 nicht erforderliche Berechtigungen

Abbildung 24 - Google Cloud Verwaltung

Schritt 4: Erstellen der Container und Hochladen in die GCP

Da die GCP-Umgebung ordnungsgemäss konfiguriert wurde und die Container erstellt werden können, betreffen die nächsten Schritte das Erstellen der Container und deren Übertragung in die GCP.

Es wird immer empfohlen, den Container lokal auszuführen, bevor er in die Cloud-Umgebung hochgeladen wird, da es auf diese Weise wesentlich einfacher ist, sicherzustellen, dass die Funktionalität wie erwartet funktioniert.

```
# Build
docker buildx build --platform linux/amd64 -t backend-app
```

```
# Test
docker run -it -p 8000:8000 backend-app
```

Angenommen, die Tests waren erfolgreich, sind zwei weitere Schritte erforderlich, um den Container in die GCP-Umgebung zu übertragen und dort zu starten:

```
# Tag
docker tag backend-app europe-west6-docker.pkg.dev/digibot-437412/digibot/backend-app

# Push
docker push europe-west6-docker.pkg.dev/digibot-437412/digibot/backend-app

# Run
gcloud run deploy backend-app --image europe-west6-docker.pkg.dev/digibot-437412/digibot/backend-app
--platform managed --region europe-west3 --allow-unauthenticated
```

Der Vollständigkeit halber listen wir hier die erforderlichen Schritte für das Frontend auf:

```
# Build
docker buildx build --platform linux/amd64 -t vue-app --load .

# Test
docker run -it -p 8080:8080 vue-app

# Tag
docker tag vue-app europe-west6-docker.pkg.dev/digibot-437412/digibot/vue-app

# Push
docker push europe-west6-docker.pkg.dev/digibot-437412/digibot/vue-app

# Run
gcloud run deploy vue-app --image europe-west6-docker.pkg.dev/digibot-437412/digibot/vue-app
--platform managed --region europe-west3 --allow-unauthenticated
```

Als letzter Schritt kann die GCP-Webkonsole verwendet werden, um sicherzustellen, dass der gesamte Prozess erfolgreich war, wie im folgenden Diagramm dargestellt.

	Name	Art der Bereitstellung	Anfragen/Sekunde	Region	Authentifizierung	Ingress	Empfehlung	Zuletzt bereitgestellt	Bereitgestellt von
☐	backend-app	Container	0,01	europe-west3	Nicht authentifiziert zulassen	Alle	SICHERHEIT	vor 7 Tagen	gitlab-runner-sa@digibot-437412.iam.gserviceaccount.com
☐	vue-app	Container	0	europe-west3	Nicht authentifiziert zulassen	Alle	SICHERHEIT	vor 11 Tagen	gitlab-runner-sa@digibot-437412.iam.gserviceaccount.com

Abbildung 25 - Google Cloud Run

6.3 Einrichten eines CI/CD-Pipelines in GitLab

Die CI/CD-Pipeline automatisiert die Schritte die einzelnen Container lokal zu builden und einzeln in via Command-Line in der Cloud zu veröffentlichen. Neben der Zeitersparnis, reduziert sich durch die Automatisierung, die Fehlerquelle und vereinfacht die Zusammenarbeit im Team und mit den Stakeholdern.

Dazu wird im Gitlab der folgende Code als gitlab-ci.yml hinterlegt.

```
image: google/cloud-sdk:latest
```

```

services:
  - docker:dind

variables:
  DOCKER_DRIVER: overlay2
  DOCKER_HOST: tcp://docker:2375/
  GOOGLE_APPLICATION_CREDENTIALS: /root/google-key.json
  BACKEND_IMAGE: "europe-west6-docker.pkg.dev/digibot-437412/digibot/backend-app"
  FRONTEND_IMAGE: "europe-west6-docker.pkg.dev/digibot-437412/digibot/vue-app"

before_script:
  # Write the expanded JSON content into the key file
  - echo "$GOOGLE_APPLICATION_CREDENTIALS" > /root/google-key.json
  # Authenticate with Google Cloud using the service account key
  - gcloud auth activate-service-account --key-file=/root/google-key.json
  - gcloud config set project digibot-437412
  - gcloud auth configure-docker europe-west6-docker.pkg.dev
  # Docker Hub login to avoid rate limiting
  - echo "$DOCKER_HUB_TOKEN" | docker login -u "$DOCKER_HUB_USERNAME" --password-stdin

stages:
  - check-updates
  - build
  - deploy

# Notify if changes are outside backend and frontend folders
notify-outside-changes:
  stage: check-updates
  script:
    - echo "Changes were detected outside of the backend and frontend folders."
  only:
    changes:
      - "/*"
  except:
    changes:
      - "backend/**"
      - "frontend/**"

# Backend: Build the Docker image
build-backend:
  stage: build
  script:
    - echo "Building and pushing Backend Docker image for Google Cloud Run..."
    - docker buildx build --platform linux/amd64 -t $BACKEND_IMAGE -f backend/Dockerfile ./backend --push
  only:
    changes:
      - backend/**

# Frontend: Build the Docker image
build-frontend:
  stage: build
  script:
    - echo "Building and pushing Frontend Docker image for Google Cloud Run..."
    - docker buildx build --platform linux/amd64 -t $FRONTEND_IMAGE -f frontend/Dockerfile ./frontend --push
  only:
    changes:
      - frontend/**

# Backend: Deploy to Google Cloud Run
deploy-backend:
  stage: deploy
  script:
    - echo "Deploying Backend to Google Cloud Run..."
    - gcloud run deploy backend-app --image $BACKEND_IMAGE --platform managed --region europe-west3 --allow-unauthenticated
  only:
    changes:
      - backend/**

```

```
# Frontend: Deploy to Google Cloud Run

deploy-frontend:
  stage: deploy
  script:
    - echo "Deploying Frontend to Google Cloud Run..."
    - gcloud run deploy vue-app --image $FRONTEND_IMAGE --platform managed --region europe-west3 --allow-unauthenticated
  only:
    changes:
      - frontend/**
```

Um eine CI/CD-Pipeline einzurichten, welche Docker-Images in die Artifact Registry von Google Cloud hochlädt und auf Cloud Run zu deployen werden die folgen Rollen zusätzlich benötigt, die einem User zugewiesen werden müssen:

- **Artifact Registry Admin (roles/artifactregistry.admin)**
Ermöglicht das Erstellen, Lesen und Verwalten von Repositories in der Artifact Registry.
- **Cloud Run Admin (roles/run.admin)**
Ermöglicht das Verwalten von Cloud Run-Diensten, z. B. das Erstellen, Aktualisieren und Löschen.
- **Service Account User (roles/iam.serviceAccountUser)**
Erlaubt der CI/CD-Pipeline, Service Accounts zu nutzen, z. B. für das Deployment.

Die Einstellungen werden unter IAM und Verwaltung/Dienstkontonutzer hinterlegt, wie in dem folgenden Screenshot dargestellt.

CI/CD Variables </> 5		Reveal values Add variable	
Key ↑	Value	Environments	Actions
DOCKER_HUB_TOKEN Masked	*****	All (default)	
DOCKER_HUB_USERNAME	*****	All (default)	
GCP_PRIVATE_KEY Masked	*****	All (default)	
GCP_PRIVATE_KEY_ID Masked	*****	All (default)	
GOOGLE_APPLICATION_CREDENTIALS Expanded	*****	All (default)	

Abbildung 26 - CI/CD Variablen

Weiter wird im Untermenü IAM und Verwaltungen/Dienstkontonutzer ein JSON-Schlüssel generiert, welcher in Gitlab unter CI/CD/Variabeln hinterlegt wird, wie in dem folgenden Screenshot dargestellt:

The screenshot shows the Google Cloud IAM Admin console for project "CloudWebApp". The left sidebar contains navigation links for IAM, PAM, and various organizational settings. The main content area is titled "Dienstkonten für Projekt 'CloudWebApp'" and includes explanatory text about service accounts. Below this is a table of service accounts with columns for selection, email, status, name, description, key ID, and creation date. Two service accounts are listed: "ci-cd-pipeline" and "416460003265-compute". A context menu is open for the second account, showing options like "Details verwalten", "Berechtigungen verwalten", and "Schlüssel verwalten".

☐	E-Mail	Status	Name ↑	Beschreibung	Schlüssel-ID	Datum der Schlüsselerstellu	Aktionen
☐	ci-cd-pipeline@cloudwebapp-437612.iam.gserviceaccount.com	Aktiviert	ci-cd-pipeline	Pipeline von Git zu Google Cloud	Kein Schlüssel vorhanden		⋮
☐	416460003265-compute@developer.gserviceaccount.com	Aktiviert	Default compute service account		Kein Schlüssel vorhanden		- Details verwalten - Berechtigungen verwalten - Schlüssel verwalten - Messwerte aufrufen - Logs ansehen - Deaktivieren - Löschen

Abbildung 27 - Google Cloud Berechtigungen



7 DigiBot-App

Die «DigiBot»-App wurde als umfassendes Tool zur Erstellung, Durchführung und Analyse von Umfragen entwickelt. Im folgenden Kapitel «9.1 «DigiBot»-App» werden die einzelnen Bausteine und Funktionalitäten, die die App bietet, genauer beschrieben.

Sie bietet eine vielseitige Plattform für die Erstellung, Durchführung und Analyse von Umfragen. Mit einer klaren Trennung der Benutzerrollen und einem umfangreichen Funktionsumfang ermöglicht sie die Verwaltung von Umfragen und die Anpassung auf individuelle Bedürfnisse. Admins können Benutzer verwalten, Umfragen gestalten und Analysen durchführen, während Umfrageteilnehmer:innen («Respondents») einfach und intuitiv an Umfragen teilnehmen können.

Durch die Integration eines interaktiven Profilerstellungschatbot, dem «Profile Builder», flexible Einstellungsoptionen für Testmethoden bietet die App alles, was für eine Datenerhebung und Auswertung benötigt wird.

In den folgenden Abschnitten ist eine Aufreihung der wichtigsten Funktionen der «DigiBot»-App:

Benutzermanagement	Beschreibung
	Die Seite passt sich dynamisch an, je nach Benutzerrolle: - Admin: Verfügt über erweiterte Rechte. Dieser kann Benutzer hinzufügen und Umfragen erstellen. - Respondent: Kann Umfrage durchführen.
Einstellungen	Beschreibung
	Führe Umfragen mit individuellen Einstellungen durch. Optionen umfassen: Sprache, Standardprofil, Umfragetyp, Anzahl der Fragen, Frage typ und Antwortlänge.

Profile Builder Home About My Account Our Users Our Feedback Meta Survey Builder Our Tests Settings Profile Builder Questionnaire Results Enrichment Logout Profile Builder Progress: 0 / 5 questions answered 1 Welcome! Let's build your profile. 2 What is your job description? 3 One moment please, I am thinking... I am a scientist Save	Beschreibung Ein Tool zur Profilerstellung durch einen interaktiven Chatbot. - Stellt klar definierte Fragen anhand eines Skripts. - Klärt Unklarheiten mit gezieltem Nachfragen. Generiert schliesslich ein Profil des Benutzers.
Questionnaire Thank you for creating your personal profile. The next step is to start the self-assessment. It includes 14 sets of statements to compare, followed by related questions. You can start your assessment now. Start Self Assessment Control Panel General Settings Choose Language en User Settings Setting 894 - Junior Marketing Statement-Survey Settings Statement Visibility Show Original and Personalize Statement Selection Selectable Statements ☐ Show Statement Labels ☒ Randomize Statement Positions ☐ Show Difference Between Original and Personalized Statements Response Settings Answer Visibility Hide Answers Meta-Survey Settings ☒ Activate Meta Questions Meta Survey Visibility Show After Statement Select Save Requirement for Meta Questions Must Answer Meta Questions Display Meta Data ☐ Show Meta Data Execute Settings Apply Settings	Beschreibung Eine Seite, auf der angereicherte Umfragen angezeigt werden. Das «Control Panel» ist eine Option für Admins zur Verwaltung von Umfragen: - Konfiguration der Interaktionsmöglichkeiten, Inhalte und Darstellung. - Einstellungsoptionen für A/B-Tests, SA-Umfragen und Analyseansicht.
Select your preferred statement. 1/1 A I know that different search engines may give different search results, because they are influenced by commercial factors. B Understanding how search engines' commercial factors affect results is crucial for effective marketing strategies. Your Preference Completely Prefer A Somewhat Prefer A Neither Somewhat Prefer B Completely Prefer B Which statement is easier to understand? A Which statement is easier to read? A Which statement offers greater detail? A Which statement fits your profession? A Which statement is helpful for a self-assessment? A 60%	Die Umfrage kann als A/B-Test konfiguriert werden, mit folgenden Optionen: - Auswahl zwischen A- und B-Aussagen. - Zufällige Anordnung der Aussagen (links oder rechts). Sie enthält weiter eine Meat-Umfrage mit: - Kontrollfragen an spezifischen Positionen. - Bipolare Slider-Auswahl. - Optionen für Fragen mit beliebiger Anzahl von Antwortmöglichkeiten.
2/2 I know which words to use in order to find what I need quickly (e.g. to search online or within a document). Answer according to your selection above: ☐ I have no knowledge of this / I never heard of this ☐ I have only a limited understanding of this and need more explanations ☒ I have a good understanding of this ☐ I fully master this topic/issue and I could explain it to others	Die Umfrage kann als SA-Test konfiguriert werden, mit folgenden Optionen: - Originale oder angereicherte SA-Tests mit jeweils vier Antwortmöglichkeiten.




	Die Umfrage kann als Analyseansicht konfiguriert werden, zur Ergebnisbewertung: - Zeigt Unterschiede in der Generierung zwischen Original- und personalisierten Aussagen. - Enthält Bewertungsmetriken.
	Beschreibung Eine Seite zur Anzeige der Ergebnisse und Zusammenfassung für A/B – und SA-Tests. Admins erhalten Zugriff auf alle Resultate.
	Beschreibung Admin-Seiten mit Zugriff auf verschiedene Entwicklungs- und Testseiten.

Tabelle 23 – «DigiBot», Umgesetzte Funktionalität

8 Benutzertests und Ergebnisse

Im Rahmen des «DigiBot»-Projekts wurden zwei Benutzertests durchgeführt, um die «DigiBot»-App in verschiedenen Szenarien zu evaluieren. Der erste Test prüfte den Testprozess und die Funktionalität der App selbst. Der zweite Test wurde mit einer repräsentativen Anzahl von Nutzer:innen durchgeführt, um die Qualität der generierten Inhalte und deren Auswirkungen zu bewerten.

8.1 Prozess Test

Im Rahmen des «DigiBot»-Projekts wurde ein erster kleiner Benutzertest über die Plattform «Prolific» durchgeführt, um das Testsystem zu evaluieren und erste Erkenntnisse zu gewinnen. Ziel des Tests war es, die Funktionalität, Benutzerfreundlichkeit und Aussagekraft des Systems zu überprüfen.

Logins Provided	Not Started	Logged in	Finished Chatbot	Finished Overall	Control Question Correct	Median Overall
42	17	25	15	10	6	17 min

Tabelle 24- «Prolific» Zahlen

Insgesamt wurden 42 Logins in «Prolific» bereitgestellt, von denen sich 25 Teilnehmer tatsächlich einloggten. 15 Teilnehmer schlossen den «Profile Builder» Teil mit dem Chatbot ab, und 10 vollendeten die darauf folgende Umfrage. Die Bearbeitungszeit mit einem Median von 17 Minuten lag im geplanten Rahmen.




Abbildung 28 - Embedding und TF-IDF Resultate

Die Ergebnisse lieferten wertvolle Einblicke. Die semantische Ähnlichkeit der generierten Aussagen, gemessen durch Cosine Embedding, lag bei 0.7 ± 0.1 und zeigt eine starke inhaltliche Nähe zu den Originalaussagen. Gleichzeitig betrug die syntaktische Ähnlichkeit, gemessen durch Cosine TF-IDF, 0.2 ± 0.1 , was eine ausreichende Variabilität in der Formulierung der generierten Aussagen widerspiegelt. Diese Ergebnisse bestätigen, dass das System in der Lage ist relevante und kontextuell angepasste Inhalte zu erstellen.




Abbildung 29 - Kontrollfrage Statistik

Allerdings traten auch einige Herausforderungen auf. Die Anzahl der vollständig abgeschlossenen Tests war mit nur 10 Teilnehmern und Teilnehmerinnen gering. Zudem zeigte sich, dass die Resultat-Seite mit dem Bestätigungscode bis zur Hälfte des Tests zugänglich war, was potenziell die Integrität der Ergebnisse beeinflusst hat. Dieses Problem wurde im weiteren Verlauf mit einem Hotfix behoben. Ein weiteres Problem war die geringe Quote korrekter Antworten auf die Kontrollfrage, was auf Unachtsamkeit oder Missverständnisse beim Ausfüllen der Frage hinweisen könnte




Abbildung 30 - Statistik: Original vs. Personalisiert und Metaresultate Verteilung

In der Meta-Umfrage, die die Aussagen auf verschiedene Qualitäten untersucht, zeigte sich keine klare Präferenz zwischen den Personalisierten und Originalausgaben. Es war jedoch eine Tendenz von 20% zu zugunsten der Originalaussagen zu beobachten, was auf ein Verbesserungspotenzial bei den generierten Inhalten hinweist.

Basic Prompting	Few Shot Prompting
A Aware of the intricacies of search engines, I understand that varying results can be produced due to influences from commercial elements. This knowledge aids in navigating research. B I know that different search engines may give different search results, because they are influenced by commercial factors. Select your preferred statement: 2/14 A I am adept at utilizing appropriate terminology and keywords to efficiently search for specific information online or within a document, aiding in swift data gathering and analysis for AI education research. B I know which words to use in order to find what I need quickly (e.g. to search online or within a document).	Select your preferred statement: 1/10 A In the process of navigating research and guiding students, understanding the commercial factors influencing search engine results is critical for accurate data analysis. B I know that different search engines may give different search results, because they are influenced by commercial factors. Select your preferred statement: 2/10 A I know which words to use in order to find what I need quickly (e.g. to search online or within a document). B Utilizing precise keywords enhances efficient online research and data analysis, crucial for guiding students in AI research projects.

Abbildung 31 - Basic Prompt vs. Few Shot Prompt

Diese Resultate sind jedoch mit Vorsicht zu genießen, da die Anzahl Teilnehmer und Teilnehmerinnen nicht repräsentativ sind. Trotzdem lassen sich basierend auf diesen Erkenntnissen Massnahmen den Nächsten Test umsetzen. Dazu gehört Anpassungen am Layout und der Benutzerführung, sowie der Wechsel zu Few Shot Prompting, um den generierten Aussagen mehr Kontext und Präzision zu verleihen.

8.2 Repräsentativer Test

Aufbauend auf den Erkenntnissen aus dem Prozess-Test (Kapitel 9.3.1) wurde ein repräsentativer Test durchgeführt, um die Wirksamkeit der personalisierten Aussagen unter realistischen Bedingungen zu überprüfen. Der Fokus war darauf zu messen, wie gut der individuelle Kontext der Aussagen unter Berücksichtigung des Profils der Teilnehmer zugeschnitten wurde. Dabei wurde analysiert, wie unterschiedliche digitale Kompetenzniveaus die Präferenz beeinflussen. Auch wurden weitere Kriterien zur Bewertung des Nutzerempfindens berücksichtigt, diese umfassen: Klarheit der Aussagen (A), Detailliertheit der Aussagen (B), Lesbarkeit der Aussagen (C), Relevanz für den Beruf (D) und Nützlichkeit für Selbsteinschätzungen (E).

Der Test folgte einem A/B-Test-Ansatz, bei dem die Teilnehmer Aussagen in der ursprünglichen und der personalisierten Version bewerteten. Zusätzlich wurde folgende Meta-Umfrage mit einer bipolaren Skala (Completely Prefer A - Somewhat Prefer A – Neither - Somewhat Prefer B - Completely Prefer B) pro Aussage durchgeführt:

Titel		Frage
A	Clarity of Statement	Which statement is easier to understand?
B	Readability of Statement	Which statement is easier to read?
C	Specificity of Statement	Which statement offers greater detail?
D	Relevance to Profession	Which statement fits your profession?
E	Helpfulness for Self-Assessment	Which statement is helpful for self-assessments?

Tabelle 25 - Meta Fragen

Zur Durchführung des Tests standen folgende drei Szenarien zur Auswahl:

Szenario	Generations Einstellung	Nutzeranzahl	Testgruppe	Ziel
1	Few-Shot Prompting, 2-fache Textlänge des Originals	50	B	Generelle repräsentative Aussage
2	Few-Shot Prompting, 1,3-fache Textlänge des Originals	30	A	Generelle Aussage und Vergleich
	Few-Shot Prompting, 2-fache Textlänge des Originals	30	B	
	Few-Shot Prompting, 3-fache Textlänge des Originals	30	C	
3	Few-Shot Prompting, 1,3-fache Textlänge des Originals	50	A	Generelle repräsentative Aussage und Vergleich
	Few-Shot Prompting, 2-fache Textlänge des Originals	50	B	
	Few-Shot Prompting, 3-fache Textlänge des Originals	50	C	

Tabelle 26 - Umfrage Szenarien

Für die Durchführung wurde schliesslich das erste Szenario (1) ausgewählt, um erste repräsentative Aussagen zu erhalten, ohne grössere finanzielle Mittel einsetzen zu müssen.

Der repräsentative Test zielte in erster Linie darauf ab:

- Präferenzen für originale und personalisierte Aussagen zu messen.
- Qualitätsmetriken der generierten Aussagen zu bewerten.
- Unterschiede in der Wahrnehmung je nach digitaler Kompetenz der Teilnehmer zu analysieren.

Logins Provided	Not Started	Logged in	Finished Chatbot	Finished Overall	Control Question Correct	Median Overall
150	20	130	94	54	44	19 min

Tabelle 27 - Prolific Nutzer: innen Statistik

Für die Untersuchung wurden 150 Logins über die «Prolific»-Plattform bereitgestellt, von denen sich 130 Teilnehmer tatsächlich einloggten. Von diesen Schlossen 94 Teilnehmer den «Profile Builder» Teil mit dem Chatbot, und 54 vollendeten die darauffolgende Umfrage. Die Bearbeitungszeit betrug im Median 19 Minuten, was leicht über dem Geplanten Rahmen von 15 Minuten lag. Die Kontrollfrage wurde von 44 Teilnehmern korrekt beantwortet, was einer Quote von etwa 81% unter den abgeschlossenen Tests entspricht.




Abbildung 32 - Grafik Verteilung Digitale Kompetenz

Der Test wurde mit einer Benutzergruppe aus den USA durchgeführt, um kulturell einheitliche und grosse Gruppe zu erhalten. Insgesamt nahmen 50 Teilnehmer an der Untersuchung teil, wobei sie gemäss ihrer eigenen Aussage zur digitalen Kompetenz in die Kategorien Beginner (17.6%), Intermediate (52.8%) und Advanced (29.6%) fallen.

8.3 Ergebnisse Repräsentativer Test




Abbildung 33- Vergleich: Original vs. Personalisiert und Verteilung Meta Antworten

Die Repräsentative Auswertung der Teilnehmerpräferenz zeigt, dass 54.5% der Teilnehmer und Teilnehmerinnen die originalen Aussagen bevorzugen, während 45.5% die personalisierten Aussagen als vorteilhafter empfanden. Diese nahezu ausgeglichene Verteilung deutet darauf hin, dass personalisierte Aussagen bei einem signifikanten Anteil der Teilnehmer auf Akzeptanz stossen, jedoch die originalen Aussagen aufgrund ihrer allgemeinen Verständlichkeit weiterhin leichte Mehrheit favorisieren.

8.3.1 Ergebnisse Digitale Kompetenz und Meta-Umfrage




Abbildung 34 - Verteilung Digitale Kompetenz und Meta-Antworten

Unterscheidet man die Präferenzen nach digitaler Kompetenz, zeigt sich eine klare Variation in den Ergebnissen. Besonders auffällig ist die starke Neigung der Teilnehmer: innen, eine klare Position

zwischen den Polen "Original" und "Personalisiert" einzunehmen, während neutrale Positionen nur selten gewählt wurden.

Anfänger: innen (Beginner) stechen besonders hervor, da sie mit überwältigenden 64.5% die originalen Aussagen bevorzugten. Dieses Ergebnis deutet darauf hin, dass die Originalaussagen für diese Gruppe verständlicher und zugänglicher sind. Teilnehmer: innen mit mittlerem digitalem Wissen (Intermediate) zeigen ein ausgewogenes Bild. Hier verteilen sich die Präferenzen fast gleichmässig auf originale und personalisierte Aussagen, was darauf hinweist, dass beide Formate für diese Gruppe gleichermaßen geeignet erscheinen. Fortgeschrittene Nutzer: innen (Advanced) folgen diesem Trend und zeigen ebenfalls eine ausgeglichene Verteilung der Präferenzen, wobei der Unterschied zwischen den Extremen weiter abnimmt. Dies deutet darauf hin, dass diese Gruppe die Ergebnisse beider Varianten ähnlich wertschätzt und gleichwertig behandelt.

8.3.2 Ergebnisse Meta-Umfrage

Die Meta-Umfrage wurde durchgeführt, um die Präferenzen der Benutzer: innen in Bezug auf fünf Aspekte der generierten und originalen Aussagen zu bewerten:

Metrik	Resultat
Aussagenklarheit	Die Mehrheit der Teilnehmer: innen bevorzugte die originalen Aussagen. Dies deutet darauf hin, dass die originalen Aussagen als klarer und einfacher zu verstehen sind.
Nützlichkeit für SAs	Teilnehmer: innen bevorzugten leicht die personalisierten Aussagen, da sie als hilfreich für Selbsteinschätzung wahrgenommen wurden. Dennoch bleibt die Präferenz für die originalen Aussagen insgesamt stärker ausgeprägt.
Aussagenlesbarkeit	Eine Präferenz für die originalen Aussagen. Ein signifikanter Anteil der Benutzer: innen empfand jedoch auch die personalisierten Aussagen als lesbar, was darauf hinweist, dass die generierten Inhalte nicht grundlegend schwerer zu verstehen sind.
Berufsrelevanz	In dieser Kategorie zeigte sich eine ausgeglichene Verteilung der Präferenzen. Sowohl die originalen als auch die personalisierten Aussagen wurden als relevant empfunden.
Aussagendetailliertheit	Im Gegensatz zu Klarheit und Lesbarkeit zeigt die Detailliertheit ein Umgekehrtes Bild. Hier wurden die personalisierten Aussagen als spezifischer empfunden.

Tabelle 28 - Resultate Meta-Umfrage

Die grafische Veranschaulichung zeigt die Verteilung der Präferenzen in den verschiedenen Bewertungskategorien und verdeutlicht die Unterschiede zwischen den originalen und personalisierten Aussagen:




Abbildung 35 - Verteilung Meta-Antworten

Die Ergebnisse der Meta-Umfrage zeigen, dass die Nutzer: innen klare Unterschiede in den Präferenzen für bestimmte Kategorien aufzeigen. Während Klarheit und Lesbarkeit überwiegend den originalen Aussagen zugeschrieben werden, zeigen die personalisierten Aussagen insbesondere bei Detailliertheit und Nützlichkeit eine klare Tendenz. Die Berufsrelevanz bleibt bei beiden Varianten ähnlich hoch, was auf eine solide Qualität bei den Originalaussagen als auch den personalisierten Inhalten hinweist.

8.3.3 Ergebnisse Digitale Kompetenz und Meta-Umfrage

Die Analyse der verschiedenen Qualitätskriterien untermauern die Tendenzen im Kapitel «7.1.2.2 Ergebnisse Digitale Kompetenz und Meta-Umfrage».

Anfänger: innen bevorzugen mit 83% die Originalen Aussagen hinsichtlich Klarheit und Lesbarkeit, was die Verständlichkeit der Originale für weniger digital-affine Nutzer: innen bestätigt. Auch im Bezug auf die Relevanz zur beruflichen Situation und die Nützlichkeit für die Selbsteinschätzung zeigt diese Gruppe eine starke Neigung zu den originalen Aussagen.

Teilnehmer: innen mittlerer digitaler Kompetenz weisen ein deutlich ausgeglicheneres Muster auf. Hier ist hat Verteilung der Präferenz in den Kategorien Klarheit und Lesbarkeit weiter eine Neigung zur originalen Aussage, jedoch schwächer als bei der Gruppe der Anfänger: innen. Im Bezug zur Relevanz zum Beruf und der Nützlichkeit für Selbsteinschätzungen sehen Benutzer: innen mit durchschnittlicher digitaler Kompetenz die personalisierten Aussagen im Vorteil.

Die fortgeschrittenen Nutzer: innen zeigen schliesslich eine noch Ausgewogenere Beurteilung der aussagen. Hier setzt sich der Trend fort das die Klarheit und Lesbarkeit der personalisierten Aussagen akzeptierter sind, die Originalen jedoch weiterhin bevorzugt werden. Die Metrik zur Relevanz zum Beruf und der Nützlichkeit für Selbsteinschätzungen ist hingegen beachtlich ausgewogen, da hier die Resultate gleichmässig aufteilen.

Zusammenfassend unterstreicht die Analyse, dass der Grad der digitalen Kompetenz die Wahrnehmung und Bewertung der Aussagen beeinflusst. Während Anfänger: innen stärker von der Klarheit und Einfachheit der Originale profitieren, erkennen durchschnittliche und fortgeschrittene Nutzer: innen einen grösseren Mehrwert der personalisierten Anpassungen.




Abbildung 36 - Digitale Kompetenz hat keine Auswirkung von TF-IDF und Embeddings

Keinen merklichen Einfluss hat die digitale Kompetenz auf die semantische Ähnlichkeit der generierten Aussagen, gemessen durch Cosine Embedding und der syntaktischen Ähnlichkeit, gemessen durch Cosine TF-IDF. Hier sind die durchschnittlichen Ergebnisse der Nutzer: innen durchmischt und zeigen keine deutliche Trennung. Vermutlich sind die erstellten Profile ausschlaggebender in der Kontextanreicherung und damit der durchschnittlichen Bewertung.




Abbildung 37 - Vergleich Digitale Kompetenz und Meta-Kriterien im Detail

8.3.4 Semantische und Syntaktische Ähnlichkeit

Zur Bewertung der generierten Aussagen wurden zwei Metriken herangezogen: die semantische Ähnlichkeit, gemessen durch Cosine Embedding, und die syntaktische Ähnlichkeit, gemessen durch Cosine TF-IDF. Diese Kennzahlen ermöglichen eine fundierte Analyse, inwieweit die personalisierten Aussagen sowohl inhaltlich als auch sprachlich von den Originalaussagen abweichen.




Abbildung 38 - Werte Embedding und TF-IDF

Cosine Embedding-Analyse

Die Cosine Embedding-Analyse zeigt eine Normalverteilung mit einem Mittelwert von etwa 0.6, was auf eine starke inhaltliche Nähe der generierten Aussagen hinweist. Das bestätigt, dass das generative Modell in der Lage ist, kontextbezogene Aussagen zu formulieren, die die ursprüngliche Intention der Originalaussagen beibehalten. Die gleichmässige Verteilung deutet darauf hin, dass keine extremen Abweichungen auftreten, was auf die Konsistenz der Generierung deutet.

Betrachtet man die Cosine-Embedding-Werte in Verbindung mit den Ergebnissen der Meta-Umfrage zeigt sich Folgendes: Die Werte in den Bereichen 0.0–0.2 sowie 0.8–1.0 besitzen wenig Resultate, daher liegt der relevante Bereich für die Analyse zwischen 0.2 und 0.8. Hier wird deutlich, dass mit steigenden Embedding-Werten die Bewertungen von Klarheit, Lesbarkeit und Detailliertheit für personalisierte Aussagen leicht zunehmen. Dies könnte darauf hindeuten, dass eine Semantische Nähe klarer und präziser wahrgenommen wird.

Im Gegensatz dazu zeigen die Kategorien Relevanz und Nützlichkeit keine signifikanten Unterschiede in den Bewertungen in Abhängigkeit von den Cosine-Embedding-Werten. Dies deutet darauf hin, dass die Relevanz und Nützlichkeit durch andere Faktoren beeinflusst werden.

Cosine TF-IDF-Analyse

Die Cosine TF-IDF-Analyse zeigt eine breitere Verteilung mit einem Mittelwert von etwa 0.2. Diese Ergebnisse verdeutlichen, dass die generierten Aussagen syntaktisch ausreichend variieren, um sie von den Originalaussagen zu unterscheiden. Eine solche Variation ist essenziell, da eine zu starke textuelle Ähnlichkeit den wahrgenommenen Mehrwert der personalisierten Inhalte einschränken könnte.

Die Analyse der Bewertungskategorien wie Klarheit, Detailliertheit, Lesbarkeit, Relevanz und Nützlichkeit zeigt jedoch, dass steigende TF-IDF-Werte die Präferenzen der Benutzer: innen nicht signifikant beeinflussen. Dies könnte darauf hinweisen, dass die syntaktische Variation allein keine spürbare Auswirkung auf die Benutzer: innen hat oder dass der Einfluss erst bei grösseren Variationen erkennbar wird.

Bedeutung

Zusammenfassend lässt sich sagen, dass die generativen Modelle sowohl semantisch als auch syntaktisch solide Ergebnisse liefern. Die Aussagen sind kontextualisiert und bewahren die ursprüngliche Intention, ohne zu stark von den Originalen abzuweichen. Gleichzeitig bieten sie ausreichend sprachliche Variationen, um die personalisierten Inhalte individuell und passend zu gestalten.




Abbildung 39 - Vergleich Cosine Embedding mit Meta-Kriterien




Abbildung 40 - Vergleich Cosine TF-IDF mit Meta-Kriterien

9 Diskussion

Die Diskussion analysiert die Ergebnisse im Kontext der Hypothese und vergleicht diese mit aktuellen Erkenntnissen der Literatur.

9.1 Ergebnisse im Kontext der Hypothese

Der Ergebnisse des Benutzertests lieferten erste wertvolle Einblicke im Bezug zu unserer Hypothese: «Mit generativer KI ist es möglich, personalisierte Selbsteinschätzungstests zu erstellen, deren Aussagen den persönlichen Hintergrund der Nutzer einbetten und als relevanter und verständlicher wahrgenommen werden.»



Abbildung 41 – Antwortübersicht des Benutzertests

9.2 Verständlichkeit und Lesbarkeit

Die Ergebnisse zeigten eine klare Tendenz zugunsten der Originalaussagen. Nutzer bewerteten diese als einfacher zu verstehen und zu lesen, unabhängig von ihrem digitalen Kompetenzniveau (Beginner, Intermediate, Advanced). Bereits vor dem Benutzertest wurde beobachtet, dass die generierten Statements häufig unnötig komplex formuliert wurden.

Der Vergleich verdeutlicht, dass eine einfache und klare Kommunikation von der Mehrheit der Benutzer bevorzugt wird. Dieses Ergebnis war nicht überraschend und entsprach unseren Erwartungen, da die DigComp-Aussagen von Experten sorgfältig entwickelt wurden. Anhand dieser durchdachten Basis kann man erklären, warum sie als verständlicher wahrgenommen wurden. Die Qualität und der Umfang der Eingabedaten beeinflusst zusätzlich für die Modellgenauigkeit.

Bei Nutzern mit berufsfremden Profilen kann es im Vergleich zu Nutzern mit tätigkeitsnahen Profilen Unterschiede in der Wahrnehmung der Originalaussage geben. Generierte Statements erscheinen für tätigkeitsnahe Profile oft sinnvoller, da die Verbindung zwischen «Personal Profile» und Originalaussage bei diesen Nutzern stärker zur Geltung kommt.

Diese Erkenntnisse unterstreichen die Bedeutung einer optimierten technischen Umsetzung und einer präzisen Konfiguration des «DigiBot»-Systems. Insbesondere die AI-Validierung muss in diesem Punkt verbessert werden, um unnötige Komplexität in den generierten Statements zu reduzieren und die Lesbarkeit zu erhöhen.

9.3 Detaillierungsgrad, Relevanz und Nutzen für Selfassessment

In Bezug auf die weiteren Fragen des Benutzertests:

- «Which statements offers greater detail?» zeigt sich eine klare Tendenz zum generierten Statement.
- «Which statements fits your profession?» zeigten sich eine Tendenz zum generierten Statement.
- - «Which statement is helpful for a self-assessment?» zeigt ebenfalls eine leicht Tendenz zur Generierung.

Dies Ergebnisse deuten darauf hin, dass Nutzer den Einbezug ihres persönlichen Kontextes schätzen, insbesondere wenn dieser sinnvoll und relevant integriert wurde. Dies spricht für die Fähigkeit generativer KI, auf spezifische Bedürfnisse einzugehen und die Individualität der Benutzer zu berücksichtigen.

Überraschend war, dass Benutzerinnen trotz der höheren Komplexität der generierten Statements den Kontextbezug für Berufsrelevanz und Nutzen bevorzugten. Dies unterstreicht die Bedeutung der inhaltlichen Relevanz, selbst wenn dies zu Lasten der Lesbarkeit geht. Die Hypothese kann somit im Bezug auf Detaillierungsgrad die Relevanz und den Nutzen bestätigt werden.

Beobachtungen und persönliche Feedbacks zeigen aber Verbesserungspotential beim generativen Mechanismus zur Einbettung des Benutzerkontext. Die generierten Aussagen waren oft nicht konsistent, besonders bei Berufsprofilen mit geringer Relevanz zum Originalstatement. Eine Optimierung könnte die Akzeptanz und den wahrgenommenen Nutzen steigern.

9.4 Vergleiche mit aktueller Literatur

Die Evaluierung von Large Language Models (LLMs) ist ein aktuelles und offenes Forschungsgebiet, für das es noch keinen standardisierten Ansatz gibt. Es existiert eine grosse Bandbreite an

Evaluationsmetriken, die ebenfalls nicht standardisiert sind.




Abbildung 42 - Trend zur Erscheinung von neuen Papers zum Thema Evaluation von Large Language Models [18]

In einer Neuerscheinung des Buches *AI Engineering* (Januar 2025) wird ein Subkapitel behandelt, das sich mit dem Thema «AI as Judge» beschäftigt. Diese Methode ist derzeit eine der häufigsten in der praktischen Anwendung, wenn nicht sogar die am weitesten verbreitete. Studien haben gezeigt, dass bestimmte KI-Richter stark mit menschlichen Bewertenden korrelieren. Im Jahr 2023 fanden Zheng et al. heraus, dass auf ihrem Evaluierungsbenchmark MT-Bench die Übereinstimmung zwischen GPT-4 und Menschen 85 % erreichte – sogar höher als die Übereinstimmung zwischen Menschen (81 %). Die Autoren von AlpacaEval (Dubois et al., 2023) stellten ebenfalls fest, dass ihre KI-Richter eine nahezu perfekte (0,98) Korrelation mit der LMSYS Chat Arena Leaderboard haben, die von Menschen bewertet wird. KI kann nicht nur eine Antwort bewerten, sondern auch ihre Entscheidung erklären, was besonders nützlich sein kann, wenn Sie Ihre Evaluierungsergebnisse überprüfen möchten. [18]

9.5 Übereinstimmungen und Widersprüche

Diese Ansätze wurden in der vorliegenden Arbeit untersucht und im «Digibot»-System unterschiedliche Implementationsvarianten zur AI-Validierung in verschiedenen Szenarien realisiert. Übereinstimmungen mit der aktuellen Literatur zeigen sich beispielsweise im Verhalten des Chatbots. Der Chatbot ist in der Lage, Benutzerantworten anhand bestimmter Kriterien zu validieren und unangemessene Inhalte herauszufiltern. Darüber hinaus kann er auf Basis seiner eigenen Evaluierungen gezielte Feedbacks generieren, um die Präzision der Antworten zu verbessern. Eine Herausforderung – ein Balanceakt – besteht jedoch darin, Antworten so zu bewerten, dass sie einerseits hilfreiche Tipps für die Präzisierung liefern und andererseits Benutzer: innen nicht bevormunden, sondern unterstützen.

Widersprüche traten vor allem im nicht-deterministischen Verhalten der Bewertungen auf. Insbesondere die Vergabe von Punktzahlen wies Inkonsistenzen auf. Diese Inkonsistenzen müssen bei der Gestaltung des Bewertungsrasters berücksichtigt werden, da sie die Zuverlässigkeit der Ergebnisse beeinträchtigen können.

9.6 Stärken des Systems

Ein wesentliches Plus des Systems ist die hohe Flexibilität durch die konfigurierbaren Parameter. Anpassungen am Quellcode können aufgrund des modularen Aufbaus schnell vorgenommen und getestet werden. Dies erleichtert die kontinuierliche Optimierung des Systems.

Eine weitere Stärke ist die universelle Lösung, die es ermöglicht, den Kontext unterschiedlichster Benutzer: innen in beliebige Statements zu integrieren. Diese Flexibilität macht das System in verschiedenen Szenarien anwendbar und eröffnet ein grosses Potenzial für den Einsatz in unterschiedlichen Anwendungsbereichen.

9.7 Schwächen des Systems

Der universelle Ansatz, der eine hohe Flexibilität bietet, stellt gleichzeitig eine Schwäche dar. Die persönlichen Hintergründe der Benutzer: innen und ihre Erwartungen an die Aussagen sind sehr unterschiedlich. Der universelle Ansatz führt daher zu variierenden Ergebnissen, je nachdem, wie der Kontext des Benutzers mit dem Inhalt des Original-Statements kombiniert wird. Dies führt zu potenziellen Unstimmigkeiten in den Ergebnissen.

Darüber hinaus besteht eine starke Abhängigkeit von der aktuellen Version des LLM-Modells. Jede neue Version des Modells könnte das Verhalten des Systems verändern, was die Konsistenz der Evaluierungen beeinträchtigen könnte.




Abbildung 43 - Einflussgrößen im Bezug auf das Resultat eines generierten Statements im «DigiBot»-System, welche viel manuelle Feinjustierung erfordern.

9.8 Einflussgrößen auf die Qualität - Die perfekte Aussage

Die Qualität der generierten Aussagen hängt nicht nur von der Evaluationsmetrik der Generierung ab, sondern auch von mehreren Einflussgrößen. Diese beinhalten unter anderem die vorgegebene Länge des Statements, den variierenden Inhalt des Original-Statements, den Kontext des Benutzerprofils, das verwendete Promptverfahren sowie die Trainingsversion des LLM-Modells und die damit verbundenen unbekannten Trainingsparameter. Ein Vorteil des Systems ist, dass Anpassungen an diesen Einflussgrößen schnell umgesetzt werden können. Um jedoch eine aussagekräftige und repräsentative Einschätzung der Qualität der generierten Statements zu erhalten, muss das Verfahren mit unterschiedlichen Benutzerprofilen getestet werden. Nur so lässt sich die Leistungsfähigkeit des Systems unter verschiedenen Bedingungen valide beurteilen.

9.9 Interpretation Resultate

Die folgende Übersicht fasst die wichtigsten Erkenntnisse der Arbeit, insbesondere der Nutzertests zusammen:

Resultate im Überblick		
Thema	Kriterium	Ergebnis
Personalisierte vs. Originalaussage	Präferenz Original vs. Personalisiert	54.5% bevorzugen originale Aussagen, 45.5% bevorzugen personalisierte Aussagen.
	Interpretation der Ergebnisse	Personalisierung steigert Relevanz, aber keine klare Präferenz erkennbar. Anfänger bevorzugen klare Originale.
Auswirkung der digitalen Kompetenz	Digitale Kompetenz & Präferenz	Beginner bevorzugen Originale (64.5%), Intermediate und Advanced zeigen ausgeglichene Präferenzen.
Meta-Umfrage	Meta-Umfrage Ergebnisse	- Klarheit: Originale bevorzugt. - Lesbarkeit: Originale bevorzugt. - Detailliertheit: Personalisierte bevorzugt. - Relevanz: Gleichmässig verteilt. - Nützlichkeit für SAs: Gleichmässig verteilt.
	Verständlichkeit & Lesbarkeit	Originale Aussagen werden klarer und leichter verständlich bewertet, unabhängig vom Kompetenzniveau.
	Detailierungsgrad & Relevanz	Personalisierte Aussagen bieten mehr Details und höhere Relevanz für Berufe, trotz erhöhter Komplexität.
Generierung	Semantische Ähnlichkeit (Embedding)	Mittelwert ~0.6, starke inhaltliche Nähe zwischen Original und personalisierten Aussagen.
	Syntaktische Ähnlichkeit (TF-IDF)	Mittelwert ~0.2, ausreichend Variation ohne übermässige Abweichungen vom Original.
	Einfluss digitaler Kompetenz	Keine signifikanten Unterschiede in semantischer und syntaktischer Ähnlichkeit festgestellt.
Allgemein	Vergleich mit Literatur	Studien zeigen, dass KI-gestützte Evaluierungen zunehmend mit menschlichen Bewertungen korrelieren.
	Übereinstimmungen & Widersprüche	Konsistenzprobleme bei Bewertungsskalen, Herausforderung bei Balance zwischen Unterstützung und Bevormundung.
	Einflussgrössen auf Qualität	Statement-Länge, Benutzerprofil, LLM-Version und Prompt-Verfahren sind entscheidend für Qualität.
	Schwächen des Systems	Hohe Abhängigkeit von LLM-Versionen, mangelnde Konsistenz bei individuellen Erwartungen und Kontextanpassungen.

Tabelle 29 - Resultate im Überblick

Die Ergebnisse des «DigiBot»-Projekts zeigen, dass die Nutzung von GPT-4 zur Erstellung personalisierter Selbsteinschätzungstests das Potenzial hat, deren Relevanz signifikant zu steigern. Personalisierte Inhalte bieten insbesondere bei Detailliertheit und beruflicher Relevanz Vorteile, während die Klarheit und Lesbarkeit der originalen Aussagen für viele Nutzer:innen weiterhin überzeugend bleiben.

Fortgeschrittene Nutzer:innen schätzen die Individualisierung, da diese gezielt auf ihre Erfahrungen eingeht, während Anfänger:innen die klareren und leichter verständlichen Originalaussagen bevorzugen. Diese Unterschiede verdeutlichen die Notwendigkeit, Inhalte an unterschiedliche Kompetenzniveaus anzupassen.

Semantische und syntaktische Analysen zeigen, dass personalisierte Inhalte die Intention der Originale bewahren, zugleich aber sprachliche Vielfalt und kontextspezifische Anpassung ermöglichen. Dies unterstreicht das Potenzial des Systems, die Selbsteinschätzung durch individuell zugeschnittene Inhalte zu unterstützen.

Das Projekt liefert wertvolle Einblicke in die Anwendung generativer LLMs zur Individualisierung von SA-Tests und bietet eine Grundlage für zukünftige Forschung sowie Weiterentwicklungen im Bereich der digitalen Kompetenzbewertung. Es zeigt, dass personalisierte Inhalte die Nützlichkeit solcher Tests insbesondere für Nutzer:innen mit mittlerer bis hoher digitaler Kompetenz erhöhen können. Die Präferenzverteilung bleibt jedoch ausgeglichen, was auf eine fehlende klare Bevorzugung personalisierter Aussagen hinweist. Um den Mehrwert der Personalisierung überzeugender nachzuweisen, wären deutlichere Präferenzwerte zugunsten der personalisierten Inhalte erforderlich.

Gleichzeitig bestehen Herausforderungen, insbesondere in der Zugänglichkeit für Anfänger:innen. Adaptive Methoden und vereinfachte Formulierungen könnten dazu beitragen, Inhalte für alle Zielgruppen besser verständlich zu machen. Zukünftige Arbeiten sollten sich auf die Integration weiterer Test- und Textarten sowie auf die Optimierung der Systemflexibilität konzentrieren, um eine breitere Zielgruppe anzusprechen und schnellere Feinabstimmungen im Personalisierungsprozess durchführen zu können.

Das «DigiBot»-System bestätigt sein Potenzial, Selbsteinschätzungstests relevanter und nutzerorientierter zu gestalten, während es noch Verbesserungspotenzial bei der Ansprache weniger erfahrener Nutzer:innen gibt.

10 Fazit

10.1 Persönliches Fazit

Die Arbeit an diesem Projekt war für uns als Team eine spannende Erfahrung, die uns sowohl technisch als auch persönlich gefordert hat. Die Evaluation von Large Language Models (LLMs) ist ein sehr aktuelles Thema und bot uns die Gelegenheit mit jungen Technologien wie Langflow, LangChain, LangGraph im laufenden Entwicklungsprozess zu arbeiten. Neu waren für uns auch der Technology Stack, aus Vue.js, FastAPI, Cloud-Integration und CI/CD-Prozessen. Dabei konnten wir zusätzlich unsere technischen Fähigkeiten erweitern.

10.2 Herausforderungen

Ein zentralen Herausforderungen war die hohe Dynamik. Wöchentliche und teils tägliche Updates bei den jungen Tools, wie LangChain und LangGraph, hatten spürbare Auswirkungen auf den Entwicklungsprozess. Die laufenden Aktualisierungen an den Technologien, in Kombination mit unvollständiger Dokumentation, führten uns oft in die sogenannte Dependency Hell. Dies erforderte viel Flexibilität und Geduld. Die fehlenden Standards/Best Practices, resultierten in viel Prototypings. Ein weiteres Hindernis war die Diskrepanz zwischen lokal funktionierenden Lösungen und dem Deployment in der Cloud. Dies führten regelmässig zu technischen Hürden.

Das Zeitmanagement war weiter eine Herausforderung. Die Balance zwischen klar definierten Zielen (Wasserfall-Ansatz) und der agilen Arbeit innerhalb der Sprints erforderte zusätzlich ein hohes Mass an Koordination und Flexibilität.

10.3 Entwicklung

Ein wertvollen Erfahrungen war die intensive Phase des Prototypings. In kürzester Zeit haben wir viele verschiedene Ansätze ausprobiert. Durch das Cloud Deployment haben wir in sehr frühem Stadium getestet, ob diese realistisch und skalierbar sind. Dieses iterative Vorgehen hat uns nicht nur technische Einblicke verschafft, sondern auch gezeigt, wie wichtig persönliche Flexibilität in solchen dynamischen Projekten ist.

Eine weitere Erkenntnis war, dass die Analyse der generierten Inhalte sehr zeitaufwändig ist und viel manuelle Arbeit erfordert. Besonders die Bewertung der Qualität. Paraphrasen und Redundanzen erschweren den Prozess enorm.

10.4 Fazit

Die Teamarbeit, Flexibilität und kontinuierliches Lernen waren im schnelllebigen Umfeld von zentraler Bedeutung. Die Arbeit an einem hochaktuellen Forschungsthema war besonders spannend, da es von laufenden neuen Erkenntnissen geprägt war. Dies ermöglichte es uns, moderne Technologien gezielt zu testen und einzusetzen und gleichzeitig unsere Fähigkeiten im Umgang mit neuen Herausforderungen zu stärken.

Der Ansatz des Prototypings war dabei nicht nur ein wertvolles Werkzeug, sondern auch ein entscheidendes Learning für zukünftige Projekte. Es hat uns gezeigt, dass schnelles Testen und Evaluieren von zentraler Bedeutung sind in einem Umfeld ohne etablierten Standard.

Wir freuen uns über das Resultat das wir als Team erreicht haben, und nehmen die Erfahrungen aus diesem Projekt als wertvolle Grundlage für zukünftige Herausforderungen.

10.5 Nächste Schritte

Im Rahmen der weiteren Entwicklung des «DigiBot»-Systems wurden konkrete Massnahmen und Erweiterungen identifiziert, die sich in zwei Kategorien unterteilen lassen: Verbesserungen mit moderatem Aufwand, die kurzfristig umsetzbar sind, und langfristige Schritte, die mit grösserem Aufwand verbunden sind.

Diese Massnahmen und Erläuterungen werden in den nachfolgenden Tabellen in Detail aufgelistet und erklärt.

Kurzfristige Massnahmen (moderater Aufwand)

Chatbot	
Genauere Erfassung des Benutzerkontext	Der Chatbot sollte mehr Rückfragen stellen, um den Benutzerkontext genauer zu erfassen. Ergänzend könnte ein zusätzlicher API-Aufruf implementiert werden, um Benutzerantworten zu analysieren und zentrale Merkmale zusammenzufassen. Das Verhalten in Bezug auf die Generierung muss mit weiteren Parametern wieder geprüft werden.

Optimierungen in der Generierung	
Lockerung formaler Vorgaben	Die Länge der generierten Statements könnte zugunsten einer besseren semantischen Qualität flexibel angepasst werden.
Regulierung der Komplexität	Komplexität stärker über Prompt reguliert werden kann. Negativ-Beispiele in Few-Shot-Prompt verstärken.
	Neuer Threshold für Komplexität ausprobieren. «Flesch Reading Ease»-Metrik verwenden, um die Lesbarkeit der generierten Statements an die Originalaussagen anzupassen (innerhalb eines Bereichs von ± 10). Zusätzlich sollte in der History geprüft werden, wie häufig ein Statement neu generiert werden muss, und die damit verbundenen Kosten sollten überwacht werden.
Prompt-Techniken	Examples für Few-Shot-Prompting anpassen.
	Weitere Prompt-Techniken (wie bspw. Chain-Of-Thoughts) integrieren und evaluieren.
Evaluationsmetriken	Der Parameter-Mix der Evaluationsmetrik könnte angepasst werden (weiter Parameter prüfen), um gezielt die Relevanz und den Nutzen für spezifische

Benutzertest	
Formulierung Verbessern	Die Formulierung der Frage „Which statement do you prefer?“ sollte klarer und spezifischer gestaltet werden, um Missverständnisse zu vermeiden. Es sollte beispielsweise hervorgehoben werden, dass keine Kontextpräferenz erwartet wird.

Langfristige Massnahmen (grösserer Aufwand)

Finetuning eines Modells	
Finetuning eines Modells	Ein speziell trainiertes Modell könnte entwickelt werden, das Benutzerkontexte besser in Statements integriert.
	Dies erfordert die Erstellung einer umfangreichen, gelabelten Datenbasis mit verschiedenen Berufsprofilen und Kontexten.

Kontinuierliche Optimierung	
Statements von Benutzer: innen	Statements welche von Benutzer: innen Favorit wurden als Referenz verwenden.
Feedbacks von Benutzer: innen	Durch regelmässiges Feedback von Endnutzern könnten generierte Inhalte iterativ verbessert und an reale Bedürfnisse angepasst werden.

Caching-Mechanismen zur Effizienzsteigerung	
Geschwindigkeits- und Kostensenkung	Generierte Statements, welche favorisiert wurden könnten in einer Vektordatenbank gespeichert werden. Vor einer neuen Generierung würde eine Überprüfung der vorhandenen Inhalte erfolgen.
Modelkombinationen, um Kosten zu minimieren, Geschwindigkeit zu steigern	Für die Generierung könnten leistungsstarke Modelle wie GPT-4 (langsamere, teurere) verwendet werden, während kleinere und schnellere Modelle(günstiger) die Validierung übernehmen.
Derzeit wird das ChatGPT-4-Modell sowohl für die Generierung als auch für die Bewertung der Statements eingesetzt. Im Chatbot übernimmt das Modell ausserdem die Validierung der Antworten sowie die Generierung von Feedback. Beide Mechanismen erfordern jeweils zwei API-Aufrufe pro Interaktion, was zu einem erhöhten Ressourcenverbrauch führt. Zusätzlich tragen die evaluierten Parameter zu einer weiteren Steigerung der Kosten bei. In AI-Engineering wird die Frage aufgeworfen, ob ein Modell, das für die Bewertung eingesetzt wird, weniger leistungsstark sein darf als das Modell, das die Ergebnisse generiert. Es wird argumentiert, dass das Bewerten eine weniger komplexe Aufgabe darstellt als das Generieren. Jeder kann beurteilen, ob ein Lied gut ist, aber nicht jeder ist in der Lage, ein Lied zu komponieren. Daher könnten schwächere, kostengünstigere Modelle die Ergebnisse leistungsstärkerer Modelle bewerten, ohne die Qualität der Bewertungen zu beeinträchtigen. [5]	

Adaptive Kontextintegration	
Verschiedene Prompts für verschiedene Benutzergruppen	Dynamische Anpassung der generativen Modelle an spezifische Benutzerprofile könnte die Relevanz und Präzision der Aussagen weiter erhöhen.

Die vorgeschlagenen nächsten Schritte bieten eine perspektive zur Weiterentwicklung des «DigiBot»-Systems. Die kurzfristigen Massnahmen zielen darauf ab, die Benutzerfreundlichkeit und Akzeptanz zu verbessern, während die langfristigen Schritte das Potenzial zur Weiterentwicklung der generativen KI-Technologien aufzeigen.

11 Danksagung

Besonderer Dank gilt Ken Ritley und Roman Rietsche für ihre wertvolle Unterstützung während des Projekts. Ihre Fachkompetenz, ihr Engagement und ihre Bereitschaft, ihr Wissen zu teilen, haben wesentlich zum Erfolg beigetragen. Vielen Dank für euren unermüdlichen Einsatz und eure inspirierende Zusammenarbeit!

Christian Schmidhalter & Roman Schneiter

12 Quellen

12.1 Abbildungsverzeichnis

Abbildung 1 - Ein mit Flux generierter Roboter. Dieser füllt eine Umfrage aus. eine Umfrage aus.	1
Abbildung 2 - Projektplan	10
Abbildung 3 - Issueboard am Ende des Sprint 4	11
Abbildung 4 - GIT Task Time Tracking Transfer Tool	12
Abbildung 5 - Die Methodik des «DigiBot»-Systems in vier Schritten.	13
Abbildung 6 - Miro Board	14
Abbildung 7 - Teams Kommunikation	15
Abbildung 8 - Star History Grafik des Techstack; Erstellt mit star-history.com	16
Abbildung 9 - Star History Grafik von Orchestrierungsframeworks; Erstellt mit star-history.com	18
Abbildung 10 - DigComp Themengebiete und Testresultate	21
Abbildung 11 - Flowchart, um die Projektidee zu visualisieren	43
Abbildung 12 - Mockups der Teilschritte zum visuellen Verständnis und als Diskussionsbasis	44
Abbildung 13 - Komponentenübersicht	45
Abbildung 14 - Detail Komponentenübersicht	46
Abbildung 15 - Systemfluss Übersicht	46
Abbildung 16 - Settings Modul	47
Abbildung 17 - Profil Builder Modul	48
Abbildung 18 - Questionary Modul	49
Abbildung 19 - Results and Statistic Modul	50
Abbildung 20 - Entity-Relationship Modell	51
Abbildung 21 - CI/CD Ablauf	52
Abbildung 22 - Bei der Bewertung wählen Benutzer:innen die favorisierten Statements und vergleichen anschliessend beide Statements.	54
Abbildung 23 - Übersicht des laufenden Benutzertest mit 50 Benutzer:innen (www.prolific.com)	55
Abbildung 24 - Google Cloud Verwaltung	58
Abbildung 25 - Google Cloud Run	59
Abbildung 26 - CI/CD Variablen	61
Abbildung 27 - Google Cloud Berechtigungen	62
Abbildung 28 - Embedding und TF-IDF Resultate	66
Abbildung 29 - Kontrollfrage Statistik	66
Abbildung 30 - Statistik: Original vs. Personalisiert und Metaresultate Verteilung	67
Abbildung 31 - Basic Prompt vs. Few Shot Prompt	67
Abbildung 32 - Grafik Verteilung Digitale Kompetenz	69
Abbildung 33- Vergleich: Original vs. Personalisiert und Verteilung Meta Antworten	70
Abbildung 34 - Verteilung Digitale Kompetenz und Meta-Antworten	70
Abbildung 35 - Verteilung Meta-Antworten	72
Abbildung 36 - Digitale Kompetenz hat keine Auswirkung von TF-IDF und Embeddings	73
Abbildung 37 - Vergleich Digitale Kompetenz und Meta-Kriterien im Detail	74
Abbildung 38 - Werte Embedding und TF-IDF	75
Abbildung 39 - Vergleich Cosine Embedding mit Meta-Kriterien	76
Abbildung 40 - Vergleich Cosine TF-IDF mit Meta-Kriterien	77
Abbildung 41 - Antwortübersicht des Benutzertests	78

Abbildung 42 - Trend zur Erscheinung von neuen Papers zum Thema Evaluation von Large Language Models [18]	80
Abbildung 43 - Einflussgrößen im Bezug auf das Resultat eines generierten Statements im «DigiBot»-System, welche viel manuelle Feinjustierung erfordern.	81
Abbildung 44 - Transformer-Modell-Architektur im Überblick. [19] (Encoder) Verarbeitet eine Eingabesequenz (Tokens) und erzeugt eine numerische Repräsentation den Embedding Vektor des Tokens. (Decoder) Generiert basierend auf der Repräsentation die Ausgabe (bspw. Übersetzung von Texten)	94
Abbildung 45 - (links) Scaled Dot-Product Attention. (rechts) Multi-Head Attention basierend aus Self-Attention-Layers [19]	95
Abbildung 46 - Berechnung eines einzelnen Self Attention Layer, welchen den kontextuellen Zusammenhang von «fluffy», «blue» und zu «creature» erfasst und einen normalisierten Wahrscheinlichkeitwert ausgibt. [20]	96
Abbildung 47 - Das Resultat eines Attention-Blocks: Ein neues Embedding für jedes Wort (Token). Die Self-Attention-Layers werden für die einzeln Wörter (Token) summiert und enthalten die kontextuelle Information zu den anderen Wörtern. [20]	97
Abbildung 48 - Visualisiert eine Transformer-Modellarchitektur. Die Grösse eines Transformatormodells wird durch die Abmessungen seiner Bausteine bestimmt. Schlüsselwerte sind: Die Anzahl der Transformatorblöcke, Die Dimension der Feed-Forward-Schicht.[22]	98
Abbildung 49 - Langflow - Chat-Flow mit Datenbankanbindung	100
Abbildung 50 - Kontextbasierte Multiple-Choice Fragen mit OpenAI	101
Abbildung 51 - statische Kontexterfassung über die Applikation	104
Abbildung 52 - Multiplechoice-Fragen basierend auf dem Kontext erstellt mit der LLM-Chain	104
Abbildung 53 - Beispiel wie ein Modell eine Antwort im Bezug auf die Frage bewertet. In unserem Anwendungsfall wurden Parameter «Clarity, Relevance, Original Meaning, Difficulty» bewertet.	115
Abbildung 54 - Regulierung der Anreicherung durch Thresholds auf Basis der Parameter der Evaluationsmatrix	116
Abbildung 55 - Enrichment von Random Statement mit Difficulty Level 3, welches den Threshold nach 3 Versuchen erreicht hat.	118
Abbildung 56 - Control Panel für den Administrator mit Konfigurationsmöglichkeiten	124
Abbildung 57 - Anpassung der Meta Questions für den Benutzertest	124
Abbildung 58 - Analysemöglichkeit der der generierten Statements	125
Abbildung 59 - «Resultpage» für Benutzer: innen und aggregierte Ansicht mit Filtermöglichkeit für Admin. In diesem Stadium wurde zusätzlich noch die Selbsteinschätzung zur «Digitalen Kompetenz» der Benutzer: innen erfasst – dies wurde für den aktuellen Prototypen vorerst ausgeblendet.	127
Abbildung 60 - Durch die Validierung werden Antworten im Bezug auf die Frage geprüft und Benutzer: innen Feedback erstattet.	130
Abbildung 61 - Durch die Validierung werden Informationen welche nicht zum persönlichen «Personal Profile» passen (im Beispiel Marketing Assistant), kritisch geprüft. «Primary Tasks» welche nicht zum angegebenen Job Profil passen werden hier gefiltert. Es wird eine Verbesserung der Antwort erwartet.	131

12.2 Tabellenverzeichnis

Tabelle 1 - Projektplan	10
Tabelle 2 - Techstack Frontend	17
Tabelle 3 - Techstack Backend	17
Tabelle 4 - Techstack Database	18
Tabelle 5 - Techstack Webintegration	19
Tabelle 6 - Techstack Entwicklungsumgebung	20
Tabelle 7 - DigComp Kompetenzen	21
Tabelle 8 - Berechnung Cosine Similarity	28
Tabelle 9 - Cosine Similarity Leseniveau	28
Tabelle 10 - Verbindung von TF-IDF	29
Tabelle 11 - Bedeutung des Cosine Similarity Werts	31
Tabelle 12 - Flesch Reading Ease Evaluation [14]	32
Tabelle 13 - Flesch Kincaid Evaluation [15]	33
Tabelle 14 - Muster Anwendungsversuch	35
Tabelle 15 - Sprint Goal Overview	37
Tabelle 16 - Funktionelle Anforderungen	38
Tabelle 17 - Nicht Funktionelle Anforderung	39
Tabelle 18 - Übersicht der potenziellen Risiken	41
Tabelle 19 - Risikomatrix	41
Tabelle 20 - Porfil Builder Fluss	48
Tabelle 21 - Questionary Fluss	49
Tabelle 22 - Meta-Fragen	53
Tabelle 23 - «DigiBot», Umgesetzte Funktionalität	65
Tabelle 24- «Prolific» Zahlen	66
Tabelle 25 - Meta Fragen	68
Tabelle 26 - Umfrage Szenarien	68
Tabelle 27 - Prolific Nutzer: innen Statistik	69
Tabelle 28 - Resultate Meta-Umfrage	71
Tabelle 29 - Resultate im Überblick	82
Tabelle 30 - Formel, Erläuterung und Beispiel zur Berechnung des Attention-Blocks. [19]	96
Tabelle 31 - Formel, Erläuterung und Beispiel zur Berechnung der Multi-Layer Perceptorn (MLP), auch Feed-Forward-Netzwerk genannt. [19]	98

12.3 Codeverzeichnis

Source Code 1 – «Prompt Template» enthalten die effektive Anweisung für das LLM mit Platzhalter für die Inputvariablen.	23
Source Code 2 – Die LLM Chain dient dazu, die Interaktion mit einem Language Model wie GPT strukturiert und effizient zu gestalten.	23
Source Code 3 – Prompt für Chatbot Evaluation	24
Source Code 4 – Zero Shot Prompt für Enrichment der Statements	24
Source Code 5 – Few Shot Prompt für Enrichment der Statements – Shots mit generischen Beispielen	25
Source Code 6 – Few Shot Prompt für Enrichment – Shots sind angepasst auf die Original Statements	26
Source Code 7 – Evaluation für Enrichment	26
Source Code 8 – Die Bedeutung der Sätze ist ähnlich, obwohl unterschiedliche Worte gewählt wurden. Im Vektorraum stehen die die beiden Vektoren der beiden Sätze nahe zueinander. Das Mass der Cosine Simliarty gibt Aufschluss.	30
Source Code 9 – Lesbarkeit Indizes angewendet auf ein anspruchsvolles und simples Textbeispiel	34
Source Code 10 – Die LLM-Chain Inputs umfasst die Verbindung zum LLM, und integriert ein «Prompt Template» mit individuellen Input Variablen.	103
Source Code 11 – Kontext- und Originalinhalt des DigComp-SA Aussage (2/21)	106
Source Code 12 – Der Kontext des «Personal Profile» wir nicht sinnvoll in das originale Statement eingebunden. Die Informationsdichte des Originals ist bereits sehr hoch. Der zusätzliche Kontext fügt zusätzlich Komplexität hinzu.	107
Source Code 13 – Schritte Orchestrierung	109
Source Code 14 – Test im Terminal	110
Source Code 15 – Beispiel Resultat	110
Source Code 16 – Agent Tools	111
Source Code 17 – Auszug Thought Chain	112
Source Code 18 – Anreicherung mit Profil	117
Source Code 19 – Code Asynchrone Generation	121
Source Code 20 – Das «Personal Profile» wird mit folgenden Fragen gebildet	129
Source Code 21 – Log's zeigen die Evaluierung der Antwort «Content creation for social media, going out with friends». Für die Parameter <i>completeness</i> , <i>credibility</i> wird der Threshold von 3 nicht erreicht und das Feedback für Benutzer: innen aufbereitet und in den Dialog eingefügt.	131

12.4 Literaturverzeichnis

- [1] „Situational Judgement Test“, *Wikipedia*. 24. März 2024. Zugegriffen: 13. Januar 2025. [Online]. Verfügbar unter: https://de.wikipedia.org/w/index.php?title=Situational_Judgement_Test&oldid=243400895
- [2] European Commission. Joint Research Centre., *DigCompSat: a self reflection tool for the European digital framework for citizens*. LU: Publications Office, 2020. Zugegriffen: 10. Oktober 2024. [Online]. Verfügbar unter: <https://data.europa.eu/doi/10.2760/77437>
- [3] „Berner Fachhochschule“. Zugegriffen: 13. Januar 2025. [Online]. Verfügbar unter: <https://www.bfh.ch/de/>
- [4] K. Pohl und C. Rupp, *Basiswissen Requirements Engineering: Aus- und Weiterbildung nach IREB-Standard zum Certified Professional for Requirements Engineering Foundation Level*. Heidelberg: dpunkt.verlag, 2015.
- [5] „DigComp Framework - European Commission“. Zugegriffen: 8. Januar 2025. [Online]. Verfügbar unter: https://joint-research-centre.ec.europa.eu/scientific-activities-z/education-and-training/digital-transformation-education/digital-competence-framework-citizens-digcomp/digcomp-framework_en
- [6] „Few-Shot Prompting – Nextra“. Zugegriffen: 7. Januar 2025. [Online]. Verfügbar unter: <https://www.promptingguide.ai/de/techniques/fewshot>
- [7] S. M. Bsharat, A. Myrzakhan, und Z. Shen, „Principled Instructions Are All You Need for Questioning LLaMA-1/2, GPT-3.5/4“, 18. Januar 2024, *arXiv*: arXiv:2312.16171. doi: 10.48550/arXiv.2312.16171.
- [8] „Kosinus-Ähnlichkeit“, *Wikipedia*. 6. Juli 2023. Zugegriffen: 6. November 2024. [Online]. Verfügbar unter: <https://de.wikipedia.org/w/index.php?title=Kosinus-%C3%84hnlichkeit&oldid=235241956>
- [9] „TF-IDF — Term Frequency-Inverse Document Frequency – LearnDataSci“. Zugegriffen: 6. November 2024. [Online]. Verfügbar unter: <https://www.learndatasci.com/glossary/tf-idf-term-frequency-inverse-document-frequency/>
- [10] „Worteinbettung“, *Wikipedia*. 8. Dezember 2024. Zugegriffen: 3. Januar 2025. [Online]. Verfügbar unter: <https://de.wikipedia.org/w/index.php?title=Worteinbettung&oldid=251056536>
- [11] „SentenceTransformers Documentation — Sentence Transformers documentation“. Zugegriffen: 3. Januar 2025. [Online]. Verfügbar unter: <https://www.sbert.net/>
- [12] „Getting Started With Embeddings“. Zugegriffen: 3. Januar 2025. [Online]. Verfügbar unter: <https://huggingface.co/blog/getting-started-with-embeddings>
- [13] „Flesch-Kincaid readability tests“, *Wikipedia*. 15. Oktober 2024. Zugegriffen: 6. November 2024. [Online]. Verfügbar unter: https://en.wikipedia.org/w/index.php?title=Flesch%E2%80%93Kincaid_readability_tests&oldid=1251290642
- [14] *textstat: Calculate statistical features from text*. Python. Zugegriffen: 6. November 2024. [Online]. Verfügbar unter: <https://github.com/textstat/textstat>
- [15] „Gunning fog index“, *Wikipedia*. 29. Juni 2024. Zugegriffen: 6. November 2024. [Online]. Verfügbar unter: https://en.wikipedia.org/w/index.php?title=Gunning_fog_index&oldid=1231671496
- [16] European Commission. Joint Research Centre., *DigCompSat: a self reflection tool for the European digital framework for citizens*. LU: Publications Office, 2020. Zugegriffen: 10. Oktober 2024. [Online]. Verfügbar unter: <https://data.europa.eu/doi/10.2760/77437>
- [17] „Prolific | Quickly find research participants you can trust“, Prolific. Zugegriffen: 13. Januar 2025. [Online]. Verfügbar unter: <https://www.prolific.com>
- [18] 3. *Evaluation Methodology*. Zugegriffen: 10. Januar 2025. [Online]. Verfügbar unter: <https://learning.oreilly.com/library/view/ai-engineering/9781098166298/ch03.html>
- [19] A. Vaswani u. a., „Attention Is All You Need“, 2. August 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
- [20] Grant Sanderson, *Visualizing transformers and attention | Talk for TNG Big Tech Day '24*, (20. November 2024). Zugegriffen: 8. Januar 2025. [Online Video]. Verfügbar unter: <https://www.youtube.com/watch?v=KJtZARuO3JY>
- [21] 3Blue1Brown, *How might LLMs store facts | DL7*, (31. August 2024). Zugegriffen: 8. Januar 2025. [Online Video]. Verfügbar unter: <https://www.youtube.com/watch?v=9-Jl0dxWQs8>
- [22] 2. *Understanding Foundation Models*. Zugegriffen: 8. Januar 2025. [Online]. Verfügbar unter: <https://learning.oreilly.com/library/view/ai-engineering/9781098166298/ch02.html>

- [23] Leon van Zyl, *LangFlow Tutorial #1: Build AI-Powered Apps without Coding!*, (16. Juli 2023). Zugriffen: 9. Oktober 2024. [Online Video]. Verfügbar unter: <https://www.youtube.com/watch?v=sC9SV06gsDM>
- [24] Leon van Zyl, *How to Create an AI Chatbot with Memory - Langflow Tutorial #2*, (27. Mai 2024). Zugriffen: 9. Oktober 2024. [Online Video]. Verfügbar unter: <https://www.youtube.com/watch?v=hXuobZkbrYM>
- [25] A. Skov, „DigComp SelfAssessment - Competences (SA)“. Zugriffen: 10. Oktober 2024. [Online]. Verfügbar unter: <https://digcomp.digital-competence.eu/digcomp/en/>
- [26] „Tutorials | 🦜🔗 LangChain“. Zugriffen: 10. Oktober 2024. [Online]. Verfügbar unter: <https://python.langchain.com/docs/tutorials/>
- [27] A. de U. P. de Extremadura, „MyDigiSkills“, MyDigiSkills. Zugriffen: 11. Oktober 2024. [Online]. Verfügbar unter: <https://mydigiskills.aupeix.org>
- [28] H. Bakshi, „Agents In LangChain“, Medium. Zugriffen: 6. November 2024. [Online]. Verfügbar unter: <https://bakshiharsh55.medium.com/agents-in-langchain-3eb92f206a5f>
- [29] „LLMs_ways_of_seeing_User_Personas“.
- [30] A. Innocent, „FastAPI Streaming Response: Unlocking Real-Time API Power“. Zugriffen: 31. Dezember 2024. [Online]. Verfügbar unter: <https://apidog.com/blog/fastapi-streaming-response/>
- [31] „Chart.js | Chart.js“. Zugriffen: 31. Dezember 2024. [Online]. Verfügbar unter: <https://www.chartjs.org/docs/latest/>

13Anhang

13.1 Funktionsweise von Large Language Models

Die vollständigen technischen Details und das genaue Architekturdisein von ChatGPT-4-Modell ist nicht öffentlich einsehbar. Die zugrunde liegende Architektur basiert jedoch auf dem Transformer-Modell, wie es in Paper «Attention Is All You Need» beschrieben ist.

Das Modell basiert vollständig auf Attention-Mechanismen. Im Gegensatz zu Convolutional Neural Networks (CNNs), die auf räumliche Beziehungen fokussieren, wird durch den Attention Mechanisms die Interaktion zwischen allen Eingabeelementen (Tokens) ermöglicht. Die Architektur erzielt sehr gute Ergebnisse in der natürlichen Sprachverarbeitung (NLP) und ermöglicht effiziente Verarbeitung von sequentiellen Daten (Texten).[19]

Um zu verstehen, wie das Modell funktioniert müssen die grundlegenden Kernschritte des Trainingsprozesses aufgezeigt werden:

- Self-Attention (Self-Attention Layer, Multi-Head Attention)
- Multi-Layer Perceptron (MLP), Feed-Forward-Netzwerk
- Positional Encoding




Abbildung 44 – Transformer-Modell-Architektur im Überblick. [19] (Encoder) Verarbeitet eine Eingabesequenz (Tokens) und erzeugt eine numerische Repräsentation den Embedding Vektor des Tokens. (Decoder) Generiert basierend auf der Repräsentation die Ausgabe (bspw. Übersetzung von Texten)

Self-Attention (Self-Attention Layer zu Multi-Head Attention = Attention-Block)

Self-Attention ermöglicht es, kontextuelle Beziehungen zwischen Wörtern zu erfassen, während Multi-Head Attention diese Beziehungen durch parallele Berechnungen verfeinert.

Von Self-Attention Layer zu Multi-Head Attention

- Die **Self-Attention** ist der Mechanismus in welchem für Wörter (Tokens) die kontextuelle Beziehung zueinander erfasst wird. Berechnet wird die Scaled Dot-Product Attention (Abbildung 5, links). Die genauer Erklärung und ein Beispiel ist in der Tabelle aufgeführt.
- Die **Multi-Head Attention** (Abbildung 5, rechts) definiert die Parallelberechnung der Self-Attention-Layers. Mehrere Querys erfassen somit verschiedenen Zusammenhänge gleichzeitig. Bei GPT3 96 Self-Attention-Layer parallel berechnet. Für jedes Wort (Token) wird die Summe der parallel berechneten Self-Attention-Layers berechnet. Dies ergibt eine neue Darstellung des aktuellen Wortes (Token). Diese Darstellung berücksichtigt die Beziehungen zu den anderen Wörtern. Dies ergibt ein neues Embedding als Output eines Attention-Block.[20]




Abbildung 45 - (links) Scaled Dot-Product Attention. (rechts) Multi-Head Attention basierend aus Self-Attention-Layers [19]

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Legende:

(Q), Query: Das aktuelle Wort, das analysiert wird.

(K), Key: Die anderen Wörter im Satz, mit denen die Verbindung geprüft wird.

(V), Value: Die Bedeutung der Wörter, die das Modell als wichtig herausstellen soll.

($\sqrt{d_k}$), Dimension: Eine Skalierung, um numerische Stabilität bei Softmax zu erhalten. (Die Teilung durch die Dimension hilft sehr grosse Zahlen zu vermeiden)

(Softmax): Normalisiert die Verbindung, sodass die Berechneten Ähnlichkeiten als Wahrscheinlichkeiten interpretiert werden können (zwischen 0 und 1)

(T), Temperature: Mass für die Flexibilität des Modells (Höherer Wert hat Einfluss auf die Kreativität der Generierung – durch höheren Wert)

Erläuterung:

– (QK^T): Das Modell berechnet die Ähnlichkeit des aktuellen Wortes (Q) im Bezug zu allen anderen Wörtern (K). Eine Query (Q) erfasst ein bestimmtes Merkmal im Bezug auf alle Wörter (K) und ergibt ein Self-Attention-Layer. (Abbildung 12)

– Mit Softmax werden die berechneten Ähnlichkeiten normalisiert und in Wahrscheinlichkeiten umgewandelt. (Abbildung 12)

– Multi-Head-Attention: die Berechnung der Self-Attention-Layer wird parallel durchgeführt.

– (V), Value: Resultat der Multi-Head-Attention: Die Summe aller Self-Attention-Layers, im Bezug auf das Wort (Token), ergibt ein neues Embedding. Im neuen Embedding sind nun die kontextuellen Informationen aller Self-Attentions-Layers gespeichert. (Abbildung 13)

Beispiel:

– «Michael Jordan ist ein berühmter Basketballspieler.», [21] Self-Attention versteht das «Michael» einen grossen Zusammenhang zu «Jordan» hat weil die Wörter oft zusammen auftreten und als gemeinsame Person auftreten. Eine weitere Query eines Self-Attention-Layer erfasst das «Basketballspieler» ebenfalls eine enge Beziehung zu «Michael Jordan» darstellt. Das Wort «berühmt» wir nur eine mittlere Gewichtung und der Value ist mittelmässig hoch. So werden die kontextuellen Verbindung nach Relevanz gewichtet. Jedes Wort (Token) erfasst welche Wörter für die eigene Bedeutung wichtig sind.[3]die kontextuellen Verbindungen

Tabelle 30 – Formel, Erläuterung und Beispiel zur Berechnung des Attention-Blocks. [19]




Abbildung 46 – Berechnung eines einzelnen Self Attention Layer, welchen den kontextuellen Zusammenhang von «fluffy», «blue» und zu «creature» erfasst und einen normalisierten Wahrscheinlichkeitwert ausgibt. [20]




Abbildung 47 – Das Resultat eines Attention-Blocks: Ein neues Embedding für jedes Wort (Token). Die Self-Attention-Layers werden für die einzelnen Wörter (Token) summiert und enthalten die kontextuelle Information zu den anderen Wörtern. [20]

Multi-Layer Perceptron (MLP)

- Nach einem Attention-Block folgt in jeder Schicht ein Multi-Layer Perceptron. Es handelt sich dabei um zwei vollständig verbundene (fully connected) Schichten mit einer Aktivierungsfunktion (ReLU) dazwischen. Das Ziel ist es die gewonnenen Features aus der Attention weiter zu verarbeiten und nicht-lineare Muster zu erkennen.

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Legende:

(x) , Eingabevektor: Der Eingabevektor, der durch den Self-Attention-Block generiert wurde. Dieser Vektor enthält die Verbindungen zwischen den Wörtern und den Kontext des Tokens (z. B. für "Michael").

(W_1, W_2) , Gewichtungsmatrizen: Die Gewichtungen wurden während des Trainings gelernt.

(b_1, b_2) , Bias-Vektoren: Bias-Vektoren, die ebenfalls trainierbar sind.

$(ReLU(max))$, Aktivierungsfunktion: Die nichtlineare Aktivierung, die negative Werte auf 0 setzt.

Erläuterung:

Schritt 1: Lineare Transformation und Aktivierung

$$z_1 = xW_1 + b_1$$

- (xW_1) Projiziert den Vektor x auf eine höhere Dimension (2048), sodass das Modell komplexere Muster erfassen kann.
- (b_1) : Verschiebt den Vektor leicht, um flexible Anpassungen zu ermöglichen.
- Anwendung von $(ReLU(max))$ - Negative Werte in (z_1) werden auf 0 gesetzt, damit nur relevante Informationen weitergegeben werden.

Schritt 2: Zweite Transformation

$$z_3 = z_2W_2 + b_2$$

- Der reduzierte Vektor (z_2) wird wieder auf die ursprüngliche Dimension (z. B. 512) zurückgeführt.

Beispiel:

Ausgangslage ist «Michael Jordan ist ein berühmter Basketballspieler.» [21] «Michael Jordan» ist unser Fokus Token. Durch Self-Attention enthält der Vektor (x) für «Michael» bereits Informationen:

- Starke Verbindung zu «Jordan»..
- Bezug zu «Basketballspieler».
- Eigenschaft «berühmt».

Das FFN nimmt diesen Eingabevektor (x) und verarbeitet ihn in zwei Schritten:

- **Schritt 1:** Informationen, die nicht mit «Basketball» oder «Jordan» zusammenhängen, werden herausgefiltert.
- **Schritt 2:** Wichtige Merkmale werden kombiniert und zu einem finalen Vektor für «Michael Jordan» verarbeitet.

Tabelle 31 – Formel, Erläuterung und Beispiel zur Berechnung der Multi-Layer Perceptronn (MLP), auch Feed-Forward-Netzwerk genannt. [19]




Abbildung 48 - Visualisiert eine Transformer-Modellarchitektur. Die Grösse eines Transformatormodells wird durch die Abmessungen seiner Bausteine bestimmt. Schlüsselwerte sind: Die Anzahl der Transformatorblöcke, Die Dimension der Feed-Forward-Schicht.[22]

Positional Encoding

- Da der Transformer keine Reihenfolge der Eingabe kennt, werden durch sinusförmige Funktionen Positionsinformationen hinzugefügt.

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

Legende:

(pos): Die Position des Tokens in der Sequenz.

($2i, 2i+1$), sdf : Die Indizes der Dimensionen (gerade und ungerade).

(d_{model}), sdf : Die Dimension der Eingabe-Embeddings.

Sinus- und Cosinusfunktionen: Definieren unterschiedliche Frequenzen, die für jede Dimension einzigartig sind.

($10000^{2i/d_{model}}$): Eine geometrisch progressive Skalierung, die sicherstellt, dass die Wellenlängen für verschiedene Dimensionen unterschiedlich sind.

Erläuterung:

- Transformer-Modelle nutzen keine rekurrenten (RNN) oder konvolutionalen Mechanismen(CNN). Somit fehlt die Information über die Reihenfolge der Tokens.
- Positional Encoding fügt diese Reihenfolge der Eingabewörter hinzu durch hinzufügen der Positionsinformation.
- Die Sinus- und Cosinusfunktion erlauben dem Modell die absolute und relative Position eines Tokens zu lernen und zu verarbeiten.

Training

GPT-4 wird mit riesigen Textmengen (1.76 Billionen Parameter) trainiert, um kontextuelles Sprachverständnis zu entwickeln.

13.2 Journal 1

Kalenderwoche (KW) 38, Projektwoche (PW) 1, 16.09 bis 22.09.24

Im ersten Sprint stand die Organisation und der Technologie-Research im Zentrum.

Anwendungsversuche

- Anwendungsversuch 1 – Langflow (No-Code-Plattform welches LangChain-Framework einbindet um Chatbot zu erstellen)
- Anwendungsversuch 2 – Chatbot mit OpenAI um Kontext zu erfragen und generieren von Multiple-Choice Fragen

Anwendungsversuch 1: Langflow (No-Code-Plattform, welches LangChain-Framework einbindet, um Chatbot zu erstellen)

Ziel des Anwendungsversuchs: Langflow ist eine No-Code-Plattform welches das LangChain-Framework einbindet. Ziel ist es zu prüfen, ob Langflow die Möglichkeiten bietet einen Chatbot-Flow zu erstellen, in einer Datenbank zu speichern und auszuwerten. Es wird zusätzlich geprüft, ob dies in einer Web-Applikation eingebunden werden kann.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Geprüft wurde Langflow in Projektwoche 1, parallel zum Setup der Applikation.

Methodik: Auf Basis von folgenden Tutorials wurde Langflow installiert und Chat-Flows erstellt.

- Tutorial: Langflow Tutorial #1: Build AI-Powered Apps without Coding [23]
- Tutorial: How to Create an AI Chatbot with Memory - Langflow Tutorial #2 [24]

Resultat:




Abbildung 49 - Langflow - Chat-Flow mit Datenbankanbindung

Erkenntnisse und Konsequenzen für das Projekt:

- Langflow bietet die Möglichkeit Individuelle Chat-Flows ohne Coding zu erstellen
- LLM's können direkt eingebunden werden
- Datenbankverbindungen können hinzugefügt werden um Chat-Flow zu speichern.
- Für das Erreichen unserer primären Ziele im Hinblick auf die qualitative Auswertungen (Kontexterfassung / SA / SJT) ist es sehr zeitintensiv robuste GUI-Bausteine zu konfigurieren. Bei angepassten Requirements ist dies ein hoher Risikofaktor.


Anwendungsversuch 2: Chatbot mit OpenAI Anbindung für Kontexterfassung und generieren von Multiple-Choice Fragen.

Ziel des Anwendungsversuchs: Es wird geprüft wie der Chatbot ohne Frameworks mit direkter OpenAI Anbindung funktioniert. Diese Alternative, ohne Langflow, soll zeigen ob der Chatbot direkt mit Python umgesetzt werden kann und Flexibilität bei Anpassungen bietet. In diesem Anwendungsversuch war die Qualitätsprüfung der generierten Antworten sekundär.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Nach Erstellung der Langflow-Chat-Flows, in Projektwoche 1, wurde dieser Anwendungsversuch umgesetzt.

Methodik: Der Kontext «Personal Profile» wurde mit den Fragen (hardcoded) erstellt und daraus mit OpenAI Multiple-Choice Fragen für die Rubriken «Information and data literacy», «Communication and collaboration», «Digital content creation», «Safety», «Problem Solving» erstellt.

Resultat:



```
What is your age?30
What is your profession or current field of work?receptionist
What are your main hobbies or interests?sports
What is your educational background?university
What is your primary goal for personal development or learning?pass university

Category: Problem-Solving
1. 1. As a receptionist, how would you handle a situation where you have multiple tasks to complete simultaneously?
2. 2. Reflecting on your university coursework, can you share an example of a complex problem you faced and how you addressed it?
3. 3. In your profession as a receptionist, if you encounter a guest who is unhappy with the services and starts complaining, how would you handle it?
4. 4. If you had a sports event to attend, but you also needed to study for an important university exam, how would you manage your time to ensure success in both a
reas?
5. 5. Can you describe a time when you faced a significant problem at work and how you resolved it?
6. 6. How would you approach studying for a university exam for which you feel unprepared?
7. 7. As a sports enthusiast, how would you resolve a dispute over the rules of a game?
8. 8. Can you share an example of how you have used problem-solving skills to achieve a development goal?
9. 9. How would you handle a situation where a colleague or classmate is not contributing equally to a shared task or project?
10. 10. If you were faced with a difficult customer who was not satisfied no matter what you did, how would you handle the situation to ensure a positive outcome?

Category: Creativity
1. 1. As a receptionist, how have you applied creativity to improve the efficiency and effectiveness of your work?
2. 2. Can you describe a situation where you had to use your creativity to solve a problem related to your profession as a receptionist?
3. 3. How would you incorporate your interest in sports into a creative project or presentation for your university coursework?
4. 4. Can you provide an example of a creative solution you've developed to meet your primary development goal of passing university?
5. 5. In what ways do you use your creativity to keep yourself engaged and motivated in your studies at university?
6. 6. How have you utilized creativity in order to balance your professional commitments, personal interests, and educational goals?
7. 7. Can you describe a time when you applied your creativity to engage better with your peers or colleagues at the university or workplace?
8. 8. How would you use your creative thinking skills to promote a sports event at your university?
9. 9. Can you give an example of how you have used creativity to improve your communication skills as a receptionist?
10. 10. How do you apply your creativity to understand and grasp complex concepts in your university studies?
```

Abbildung 50 - Kontextbasierte Multiple-Choice Fragen mit OpenAI

Erkenntnisse und Konsequenzen für das Projekt:

- Ohne Langflow-GUI ist der Chatbot schnell erstellt. Anpassungen können im Code flexibel umgesetzt werden. Konfigurationslimitationen, welche mit Langflow (NoCode-Variante) einschränken, wurden keine gefunden.
- Die Speicherung der Daten kann über REST umgesetzt werden.

Diskussion

- Die grösste Gefahr, die aus dem RiskAssessment hervorgeht, ist die Definition des Techstack.
- Um den Überblick über die Termine zu halten wurde eine Semesterübersicht in Excel erstellt.
- Die Issues sind im GitLab in einem Issueboard organisiert.
- Time Tracking wird mittels Git-Issues gemacht.
- Experiment 1-2:
Langflow mit GUI bietet uns nicht die nötige Flexibilität um den Chatbot umzusetzen. Die Variante mit Python schnell erstellt und robuster im Bezug auf Änderungen und angepasste Requirements.
- In einem nächsten Schritt wird das Framework LangChain, für die Interaktion mit OpenAI, in Python eingebunden und evaluiert.

13.3 Journal 2

Kalenderwoche (KW) 39–40, Projektwoche (PW) 2–3, 22.9 bis 8.10.24

Im zweiten Sprint wurde eine CRUD-Webapplikation mit Vue (Frontend) und FastApi (Backend) aufgesetzt. Es wurde eine CI/CD Pipeline eingerichtet (Lokal/Google Cloud)

In diesem Sprint wurde ausführliche Prototypen in der lokal Entwicklungsumgebung erstellt und im Cloud Deployment getestet und evaluiert. Framework Bausteine von LangChain wurden ebenfalls getestet.

Anwendungsversuche

- Anwendungsversuch 3 – Integration Langchain-Framework für Interaktion mit OpenAI
- Anwendungsversuch 4 – Subjektive Qualitätsprüfung: DigComp Self-Assessment [25] angereichert mit «Personal Profile»

Anwendungsversuch 3: Integration Langchain-Framework für Interaktion mit OpenAI

Ziel des Anwendungsversuchs: Evaluieren ob Integration des LangChain-Framework die Struktur des Quellcodes vereinfacht und einen Einfluss auf den Output hat.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Nach Prüfung der No-Code-Plattform Langflow und der Erstellung von ersten Chat-Flows mit Python wurde ein Projektwoche 2 das LangChain-Framework in Python eingebunden.

Methodik: Auf Basis der offiziellen Langchain-Tutorials[26] wurden die Framework-Komponenten *PromptTemplates*, für die Strukturierung der Prompts, und die *LLM-Chain*, für die Verarbeitung der Antworten des LLM's geprüft.

Resultat:

```
assessment_prompt_template = """
Based on the following user information:
Age: {age}, Profession: {profession}, Digital Proficiency: {digital_proficiency}, Responsibilities:
{responsibilities}, Strategies: {strategies}, Skill Improvement: {skill_improvement}

Generate 2 personalized multiple-choice questions for the category: {category}. Provide 4 answer
options for each question, with one clearly being the best, another as second-best, and so on."""

chain = LLMChain(
    llm=llm,
    prompt=PromptTemplate(
        input_variables=["age", "profession", "digital_proficiency",
            "responsibilities", "strategies", "skill_improvement", "category"],
        template=assessment_prompt_template
    ))
assessment_input = {
    "age": user_answers[0],
    "profession": user_answers[1],
    "digital_proficiency": user_answers[2],
    "responsibilities": user_answers[3],
    "strategies": user_answers[4],
    "skill_improvement": user_answers[5],
    "category": category
}
# Generate multiple-choice questions
generated_questions = chain.run(assessment_input)
```

Source Code 10 - Die LLM-Chain Inputs umfasst die Verbindung zum LLM, und integriert ein «Prompt Template» mit individuellen Input Variablen.

Digital Competency Assessment

User: hello

System: What is your age?

User: 33

System: What is your current job role or title, and how many years of professional experience do you have?

User: receptionist, 6 years

System: How would you rate your digital proficiency (Beginner, Intermediate, Advanced)?

User: advanced

System: Please describe 3 to 5 primary tasks in your current role that involve digital skills.

User: accounting, responsible for bookings, social media for the hotel

System: How do you approach digital tasks in your work? Please describe any strategies or tools you use.

Type your message here...

Send

Abbildung 51 - statische Kontexterfassung über die Applikation

Assessment Questions

Information and Data Literacy

Question 1: As a receptionist handling customer experience, which of the following is the most effective way to utilize your digital proficiency for improving the customer's experience?

- ☐ A) Implementing an automated booking system using your excel vba coding skills
- ☐ B) Googling for customer's personal information
- ☐ C) Asking colleagues to handle all digital tasks
- ☐ D) Avoid using digital tools and stick to traditional methods

Question 2: Given your responsibility for bookings and accounting, which digital tool would be most beneficial for you to improve your skills in?

- ☐ A) Social media platforms
- ☐ B) Excel vba coding for data analysis
- ☐ C) Website design
- ☐ D) Graphic design software

Communication and Collaboration

Question 1:

- ☐ As a receptionist with responsibilities for customer experience, which of the following communication strategies would best enable you to handle a frustrated client?
- ☐ A. Speak in a calm and friendly tone, empathize with their issue, and ensure them that you will do everything you can to resolve it.
- ☐ B. Quickly apologize and hand over the issue to your manager.
- ☐ C. Tell the client that you cannot help them and they should contact customer support.

Question 2:

- ☐ In your role, you have responsibilities for

Abbildung 52 - Multiplechoice-Fragen basierend auf dem Kontext erstellt mit der LLM-Chain

Erkenntnisse und Konsequenzen für das Projekt:

- Die Interaktion mit OpenAI kann über die offizielle OpenAI-Schnittstelle oder mit dem LangChain-Framework umgesetzt werden. Die Integration des LangChain-Frameworks erleichtert jedoch die Interaktion mit OpenAI. Inputvariablen können direkt in die «Prompt Templates» übergeben und eingebunden werden. Dieses vereinfachte Verfahren ermöglicht es verschiedene Prompt Techniken umzusetzen und effizient zu testen. Die Framework-Bausteine funktionieren Lokal und im Cloud-Deployment.
 - Im aktuellen Anwendungsversuch werden die Kontexterfassung durch den Chatbot und die Generierung der persönlichen Multiple-Choice Fragen im selben Python-Skript iterativ abgearbeitet. Bei der Interaktion mit OpenAI kam es sowohl über die offizielle OpenAI-Schnittstelle als auch über die LangChain-Bausteine zu Fehlern. Fragen wurden teilweise übersprungen, oder einzelne Antwortoptionen vergessen.
-

Anwendungsversuch 4: Subjektive Qualitätsprüfung: DigComp Self-Assessment [25] angereichert mit «Personal Profile»

Ziel des Anwendungsversuchs: Ziel ist eine subjektive Qualitätsprüfung der angereicherten DigComp-Self-Assessments-Statements. Es wird ein Statement für die Rubriken «Information and data literacy», «Communication and collaboration», «Digital content creation», «Safety», «Problem Solving» erstellt und mit dem «Personal Profile» kombiniert.

Das originale Statement wird aus verschiedenen Skills der Rubrik zusammengesetzt.

Beispiel «Information and data literacy»:

Browsing searching and filtering data, information and digital content

- To articulate information needs
- To search for data, information and content in digital environments
- To access them and to navigate between them
- To create and update personal search strategies
- To analyse, compare and critically evaluate the credibility and reliability of sources of data, information and digital content

Evaluating data, information and digital content

- ...

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Nach Erstellung eines simplen Chatbots in Projektwoche 2, wird in Woche 3 die Anreicherung der eigentlichen DigComp-Inhalte geprüft.

Methodik: Mit Zero-Shot Prompting werden die DigComp-Self-Assessment-Statements und das «Personal Profile» kombiniert. Die Codebasis wird aus Anwendungsversuch 3 übernommen.

Resultat:

```
"context": [
  {
    "age": "40",
    "profession": "receptionist, 6 yers of experience",
    "digital proficiency": "intermediate",
    "responsabilities": "accounting, frontdesek, responsible for bookings",
    "digital strategies": "google, asking sollegues",
    "skill improvement": "excel vba coding"
  },
]

"competencies": [
  {
    "title": "Browsing, searching and filtering data, information and digital content",
    "description": "To articulate information needs, to search for data, information and content in digital environments, to access and navigate between them. To create and update personal search strategies.",
    "rubric": "Information and Data Literacy"
  },
  {
    "title": "Evaluating data, information and digital content",
    "description": "To analyse, compare and critically evaluate the credibility and reliability of sources of data, information and digital content. To analyse, interpret and critically evaluate the data, information and digital content.",
    "rubric": "Information and Data Literacy"
  },
]
```

Source Code 11 – Kontext- und Originalinhalt des DigComp-SA Aussage (2/21)

```

"response": [
  {
    "title": "Browsing, searching and filtering data, information and digital content",
    "description": "with six years of experience as a receptionist, the user proficiently navigates digital environments to fetch data, manage reservations, and enhance customer experience, but seeks to enhance their skills in Excel and VBA coding to better manage, filter, and search digital content, leveraging Google and colleague assistance for task completion and strategizing personal search approaches."
  },
  {
    "title": "Evaluating data, information and digital content",
    "description": "In order to optimize her receptionist duties, which include front desk management, reservations, customer experience, and accounting, this 40-year-old professional with an intermediate level of digital proficiency, seeks to enhance her skills in Excel and VBA coding to better evaluate, analyze, compare, and critically assess the reliability and credibility of data, information, and digital content."
  },
]

```

Source Code 12 – Der Kontext des «Personal Profile» wird nicht sinnvoll in das originale Statement eingebunden. Die Informationsdichte des Originals ist bereits sehr hoch. Der zusätzliche Kontext fügt zusätzlich Komplexität hinzu.

Erkenntnisse und Konsequenzen für das Projekt:

- Die Informationsdichte der Statements ist sehr hoch und muss reduziert werden.
- Für die Kombination von «Personal Profile» und der Statements müssen Prompting-Techniken geprüft werden.

Diskussion

- Die Einbindung des LangChain-Frameworks für die Interaktion mit OpenAI funktioniert Lokal und im Cloud-Deployment. Prompts können effizient und übersichtlich strukturiert werden. Das Framework bietet zudem weitere integrierte Möglichkeiten für die Qualitätsmessung und Speicherung der Konversation (Memory-Management).
- Die einzelnen Arbeitsschritte (Chatbot, Generierung der Statements) benötigen einen modularen Aufbau und einen Orchestrierungsmechanismus, um die Übersicht im Quellcode zu gewährleisten und um Fehlerquellen zu minimieren.
- Die Response-Time für das Self-Assessment ist im iterativen Verfahren zu lang und benötigt einen Asynchronen Mechanismus.
- Die Informationsdichte der Statements aus dem DigComp-SA ist zu hoch. [5, S. 137]
Die daraus abgeleiteten Statements des erweiterten SA «Mydigiskills-Test» [16, S. 154], [27] dienen neu als Basis für die weiteren Tests.
Die Statements sind wesentlich kürzer und haben eine kleinere Informationsdichte.
- In einem nächsten Schritt, um signifikante Unterschiede zu ermitteln, und genauere Aussagen in Bezug auf Qualität zu machen, werden die Metriken *'flesch_reading_ease'*, *'flesch_kincaid_grade'*, *'gunning_fog'* gemessen.

13.4 Journal 3

Kalenderwoche (KW) 41 - 42, Projektwoche (PW) 4 - 5, 8.10 bis 22.10.24

Im dritten Sprint lag der Fokus auf der Orchestrierung des Quellcodes. Der grundlegende Aufbau der Dokumentation wurde in diesem Sprint erarbeitet. Weiter wurde ein Prototyp für ein Orchestrierung System mit «Agents» erarbeitet und evaluiert.

Anwendungsversuche

- Anwendungsversuch 5 – Orchestrierung, Anreicherung und Qualitätsbewertung von DigCompSat-Statements
 - Anwendungsversuch 6 – Einsatz von Agents im Orchestrierungssystem
-

Anwendungsversuch 5: Orchestrierung Anreicherung und Qualitätsbewertung von DigCompSat-Statements

Ziel des Anwendungsversuchs:

Entwicklung eines einfachen Orchestrierungssystems zur Anreicherung von DigCompSat-Statements basierend auf Nutzerprofilen. Zudem die Qualitätssicherung der Fragen durch ein Quality Gate. Das System soll modular aufgebaut sein, um die Integration und den Austausch bestehender Codes zu erleichtern.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs:

Dieser Versuch ist eine Fortsetzung von bisherigen Anwendungsversuchen zur Fragenanpassung anhand Personas.

Methodik:

Der Prozess umfasst die folgenden Schritte:

1. Persona Erfassung und -prüfung: Sammeln und Verifizieren eines einfachen Nutzerformulars mit dem User Service und Assessment Service.
2. Personenzuordnung: Erstellen eines profilorientierten Personas mithilfe des Persona Service.
3. Anreicherungsprozess: Anpassung und Anreicherung der DigiComp SA-Statements durch den Question Service, bewertet nach Lesbarkeit, Klarheit und Persona-Übereinstimmung.
4. Qualitätsbewertung: Wiederholtes Anreichern bis zur Erfüllung der Quality-Gate-Anforderungen mit abschliessender Auswahl (Ranking) der besten Fragen.

Resultat:

Eine Beispielstruktur zur Ausführung des gesamten Prozesses.

```
# Load language preference
# Initialize services
  (a) UserService()
  (b) AssessmentService()
  (c) PersonaService()
  (d) QuestionService()
# Step 1: Get user information (a)
# Step 2: Verify information (b)
# Step 3: Map to persona (c)
# Step 4: Load questions
  # Ask user how many questions they want to answer
  # Randomly select the specified number of questions
# Step 5: Enrich the selected questions (d)
  # 5.1
    # Prepare previous versions per question
    # Enrich question, include previous tries with quality judgement
    # Collect all enriched versions
    # Check if all enriched questions meet the quality gate
    # If acceptable, break the loop
  # 5.2
```

```

# After enrichment, select the best enriched questions
# Rank and select the best enriched question per original question
# If no versions are available, use the original question
# Step 6: Present the enriched questions to the user and collect responses
# Display the enriched possible answers
# Extract keys from enriched answers (assuming they start with '0:', '1:', etc.)
# Get user input
# Step 7: Display user responses

```

Source Code 13 - Schritte Orchestrierung

Einen funktionierenden Code als Terminal-Prozess zum Anreichern von Fragen.

```

Welcome to DigiBot!
What is your name? Chris
What are your interests? penguins
What is your professional background? zoo keeper

User mapped to persona: Chris is a passionate animal lover with a particular interest in penguins.
They have a strong background in caring for animals, having worked as a zoo keeper for several
years. Chris is dedicated to educating others about the importance of conservation and is always
looking for ways to improve the lives of the animals they work with.

How many questions would you like to answer? (1-82): 1
Attempt 1: Enriching questions...

LLM Response:
Question: How comfortable are you with utilizing communication services and social media to promote
conservation and educate others about animal welfare?
Answers:
0: I have no experience with this.
1: I know the basics but may need assistance.
2: I am confident in using them independently.
3: I am very confident and can even assist others if needed.
Quality not sufficient, redoing personalization.

[...]

Attempt 3: Enriching questions...
LLM Response:
Question: How confident are you in utilizing communication services and social media to raise
awareness and educate others about penguin conservation and animal welfare?
Answers:
0: I have little to no experience in this area.
1: I have some knowledge but may need assistance.
2: I am proficient in using these platforms independently.
3: I am highly skilled and can also guide others if needed.
Quality not sufficient, redoing personalization.
Quality gate not reached after 3 attempts. Displaying the best enriched questions.

Question 1/1:
How familiar are you with using communication services and social media to advocate for penguin
conservation and educate others about animal welfare?
Readability Scores: {'flesch_reading_ease': 15.31, 'flesch_kincaid_grade': 16.6, 'gunning_fog':
17.89}
Persona Fit Score: 8/10
Total Quality Score: 38.81

Please select your answer:
0: I have no experience in this area.
1: I have some knowledge but may require guidance.
2: I am skilled in using these platforms independently.
3: I am highly proficient and can also mentor others if needed.
Your answer (0/1/2/3):
2

Thank you for completing the assessment. Here are your responses:

```

```
Q14: How familiar are you with using communication services and social media to advocate for penguin conservation and educate others about animal welfare?  
Your answer: 2 - 2: I am skilled in using these platforms independently.
```

```
Process finished with exit code 0
```

Source Code 14 - Test im Terminal

Drei Beispiele von DigiComp-SA-Statements, die durch ein Profil angereichert wurden, inklusive Qualitätsmetriken und eines gesamthaften Qualitätswertungen.

```
[  
  {  
    "original_question": "How do you feel about using technology in your daily life?",  
    "enriched_question": "Enriched Question: As a passionate animal lover and former zoo keeper, how do you leverage technology in your daily life to improve the lives of the animals in your care and educate others about conservation? \nQuality Score: 45.73",  
    "readability_scores": {  
      "flesch_reading_ease": 52.19,  
      "flesch_kincaid_grade": 10.7,  
      "gunning_fog": 13.92  
    },  
    "quality_score": 38.35699999999999  
  },  
  {  
    "original_question": "What challenges do you face at work?",  
    "enriched_question": "Enriched Question: As a passionate animal lover and experienced zoo keeper, how do you strive to improve the lives of penguins and educate others about conservation? \nQuality Score: 45.22",  
    "readability_scores": {  
      "flesch_reading_ease": 48.3,  
      "flesch_kincaid_grade": 10.1,  
      "gunning_fog": 12.7  
    },  
    "quality_score": 35.99999999999999  
  },  
  {  
    "original_question": "What hobbies do you enjoy?",  
    "enriched_question": "How would you describe your interests and passions, particularly in regards to animals?",  
    "readability_scores": {  
      "flesch_reading_ease": 41.36,  
      "flesch_kincaid_grade": 10.7,  
      "gunning_fog": 14.43  
    },  
    "quality_score": 30.622999999999998  
  }  
]
```

Source Code 15 - Beispiel Resultat

Erkenntnisse und Konsequenzen für das Projekt:

Der Prozess bietet einen guten technischen Überblick über alle Komponenten, die für DigiBot erforderlich sind. Dies erleichtert den folgenden Entwicklungsprozess mit Frontend, Backend und Datenbankgestaltung. Insgesamt bedeutet das, dass wir zeitnah einen solchen Prozess mit Benutzeroberfläche für das Projekt umsetzen können. Zudem zeigt sich, dass die einfache Anfrage an OpenAI gute Reaktionszeiten bietet und auch bei mehrfacher Anwendung für das Enrichment in einer akzeptablen Zeit abgeschlossen wird.

Problematisch waren in diesem Beispiel die verwendeten Qualitätsmetriken zur Bewertung der Ergebnisse. Diese waren oft sehr streng und führten dazu, dass in der Regel die maximale Anzahl von Anfragen für die Anreicherung der Self-Assessment-Fragen benötigt wurde. Die Aufgabe besteht nun darin, geeignete und sinnvolle Metriken zu finden, um den Prozess weiter zu optimieren.

Anwendungsversuch 6 – Einsatz von Agents im Orchestrierungssystem

Ziel des Anwendungsversuchs: Testen eines agentenbasierten Orchestrierungssystems, das analog zu Anwendungsversuch 5 funktioniert.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs:

Aufbauend auf Anwendungsversuch 5.

Methodik:

Der Prozess folgt den im Anwendungsversuch 5 beschriebenen Schritten. Es werden jedoch zwei Komponenten ausgetauscht, die die Agentenlogik enthalten:

- Der Orchestration Service, der für das Zusammenspiel der Komponenten verantwortlich ist.
- Der Question Service, der das Anreichern der Self-Assessment-Fragen (SA-Fragen) übernimmt.

Der Question Service nutzt einen Zero-Shot-React-Agent [28], der verschiedene Werkzeuge (Tools) wie Question Enrichment, Quality Evaluation und Persona Fit Evaluation einsetzt. Der Agent erstellt angereicherte Versionen der Fragen und passt mögliche Antworten an die Persona an. Die Anreicherung erfolgt iterativ und wird bei Nichterreichen der Qualitätskriterien wiederholt. Die Qualität der Fragen wird anhand von Lesbarkeitsmetriken und Persona-Fit-Scores bewertet. Der Agent stoppt, wenn die gewünschte Qualität erreicht ist oder die maximale Anzahl an Versuchen erreicht wurde.

Resultat:

Codeausschnitte, die die Definition der Werkzeuge zeigen, welche dem Agenten zur Verarbeitung der SA-Statements zur Verfügung stehen.

```
self.tools = [  
    Tool(  
        name="QuestionEnrichment",  
        func=self.question_enrichment_tool,  
        description="Enriches a question and possible answers based on the persona and question  
type."  
    ),  
    Tool(  
        name="QualityEvaluation",  
        func=self.quality_evaluation_tool,  
        description="Evaluates the readability and quality of the enriched question."  
    ),  
    Tool(  
        name="PersonaFitEvaluation",  
        func=self.persona_fit_evaluation_tool,  
        description="Evaluates how well the question fits the persona."  
    )  
]
```

Source Code 16 - Agent Tools

Auszug aus dem Thought Chain des Agenten, die den Denkprozess veranschaulichen.

```
> Entering new AgentExecutor chain...
It's important to consider the persona and question type when enriching a question.
Action: QuestionEnrichment
Action Input: Question: I know which different types of licenses apply to the use of digital
content (e.g. Creative Commons licenses).
Question Type: S
Possible Answers: 0: I don't know how to do it
1: I can do it with help
2: I can do it on my own
3: I can do it with confidence and, if needed, I can support/guide others
Observation:
Question: How confident are you in identifying the different types of licenses that apply to the
use of digital content, such as Creative Commons licenses?
Possible Answers:
0: I don't know how to do it.
1: I can do it with help.
2: I can do it on my own.
3: I can do it with confidence and, if needed, I can support/guide others.
Thought: Now that the question has been enriched, it is important to evaluate its quality and
readability.
Action: QualityEvaluation
Action Input: Enriched Question: How confident are you in identifying the different types of
licenses that apply to the use of digital content, such as Creative Commons licenses?
Observation: Quality Score: 26.676000000000002
Thought: The quality score is a good indicator of how well the question is constructed for the
persona and question type.
Action: PersonaFitEvaluation
Action Input: Enriched Question: How confident are you in identifying the different types of
licenses that apply to the use of digital content, such as Creative Commons licenses?
Persona: Chris is a passionate animal lover with a particular interest in penguins. They have a
strong background in caring for animals, having worked as a zoo keeper for several years. Chris is
dedicated to educating others about the importance of conservation and is always looking for ways
to improve the lives of the animals in their care.
Observation: Persona Fit Score: 8
Thought: I now know the final answer.
Final Answer: The enriched question is well-tailored for Chris, with a high persona fit score and a
good quality score.

> Finished chain.
```

Source Code 17 - Auszug Thought Chain

Erkenntnisse und Konsequenzen für das Projekt:

Agents bieten eine interessante Möglichkeit, den Anreicherungsprozess zu strukturieren und eine modulare Anpassung durch die Nutzung von Tools zu gewährleisten. Ausserdem lässt sich dieser Prozess unabhängig programmieren und in das übergeordnete DigiBot-System integrieren. Allerdings ist die Integration in diesem Beispiel nicht vollständig gelungen, da im Denkprozess ein Fehler auftritt, der zu einem unerwünschten Ergebnis im finalen Output führt. Für das Projekt bedeutet dies, dass wir kurzfristig noch direkte Anfragemethoden für das Enrichment bevorzugen sollten, um die Gesamtintegration mit Frontend und Backend sicherzustellen.

Diskussion

Im dritten Sprint lag der Fokus auf der Orchestrierung und Modularisierung des Codes sowie dem Erstellen einer Gesamtstruktur für die Dokumentation, was gut vonstattenging. Anwendungsversuch 5 bestätigte, dass ein modularer Anreicherungsprozess mit Qualitätsmechanismen gut möglich, flexibel erweiterbar und relativ intuitiv sowie schnell aufsetzbar ist. Im Vergleich dazu bot Anwendungsversuch 6 einen Einblick in die Arbeitsweise mit Agents und deren Vorteile, insbesondere die Möglichkeit, flexibel Tools einzusetzen. Allerdings führten die Agentenprozesse zu unerwarteten Resultaten. Beide Ansätze liefern wertvolle Erkenntnisse und zeigen Potenzial für den Einsatz in «DigiBot». Für den kurzfristigen Einsatz bietet sich jedoch eine klassische LangChain-Implementierung an, da dieser einen schnellen und einfacheren Fortschritt im Projekt ermöglicht.

13.5 Journal 4

Kalenderwoche (KW) 43 – 44, Projektwoche (PW) 6 – 7, 22.10 bis 5.11.24

Im vierten Sprint wurde die Orchestrierung aus Sprint 3 auf die Webapplikation übertragen.

Die Generierung der Statements wurde ebenfalls in den eigenen Vue-Komponenten umgesetzt.

Für die Evaluation der generierten Statements wurde eine Evaluationsmethode zur Qualitätsprüfung implementiert.

Anwendungsversuche

- Anwendungsversuch 7 – Orchestrierungssystem in einzelnen Komponenten (Vue und FastAPI)
 - Anwendungsversuch 8 – Anreicherung von DigCompSat-Statements [16, S. 154] mit Default «Personal Profile» und Evaluationsmethode zur Qualitätsprüfung.
-

Anwendungsversuch 7: Orchestrierungssystem und Umsetzung einzelner Komponenten (Vue und FastAPI)

Ziel des Anwendungsversuchs: Orchestrierung aus Anwendungsversuch 5 (Python Basis) in Komponenten im Frontend und Backend umsetzen.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs:
Aufbauend auf Anwendungsversuch 5.

Methodik:

Die Teilschritte aus dem Orchestrierungsprototyp (Anwendungsversuch 5) wurden in vier grundlegenden Komponenten (Frontend und Backend) implementiert. Die einzelnen Komponenten:

- **Settings** – Grundeinstellungen für einzelnen Benutzer: innen
- **Chatbot** – für die Erstellung des «Personal Profile»
- **«Questionary»** – Ein Begriff in diesem Projekt für die Generierung sowie Interpretation der Statements (Questionnaire + Dictionary). Basis für Benutzertests und Testumgebung für den Administrator
- **Results** – Auswertung der Resultate für einzelne Benutzer: innen und Administrator

Die Komponenten im Backend stellen die HTTP-Endpunkte für die jeweiligen Frontend-Komponenten zur Verfügung und sind mit einem eigenen CRUD-File für die Datenbankinteraktion gekoppelt.

Resultat:

- **Komponente: Settings**
Es können Sprache, Anzahl Fragen, Assessmenttyp in der Datenbank gespeichert werden. Weiter kann man entscheiden, ob man ein «Personal Profile» über den Chatbot anlegen möchte, oder ein Default Profile auswählt und den Chatbot überspringt.
- **Komponente: Chatbot «Personal Profile»**
Erfassung des persönlichen Kontextes über den Chatbot und Speicherung in der Datenbank als JSON. Die Integration von AI, zur Validierung der Antworten, wurde in diesem Zeitpunkt deaktiviert, um alle weiteren Features zu implementieren.
- **Komponente: «Questionary»**
Implementation zu späterem Zeitpunkt in Anwendungsversuch 8.
- **Komponente: Results**
Implementation zu späterem Zeitpunkt in Anwendungsversuch 11.
- **Datenbank**
Entity-Relationship-Model (ERD) wurde im aktuellen Anwendungsversuch für Komponenten Settings, «Personal Profile» umgesetzt.

Erkenntnisse und Konsequenzen für das Projekt:

Der Aufbau erlaubt es Anpassungen gezielt und strukturiert vorzunehmen. Features können isoliert entwickelt und angepasst werden.

Anwendungsversuch 8: Anreicherung von DigCompSat-Statements [16, S. 154] mit Default «Personal Profile» und Evaluationsmethode zur Qualitätsprüfung.

Ziel des Anwendungsversuchs: Methodik um DigCompSat-Statements mit dem «Personal Profile» anzureichern. Definition und Implementierung einer Evaluationsmöglichkeit zur Qualitätsprüfung.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Fortsetzung des Anwendungsversuch 4 in Projektwoche 3. Wir beschränken uns auf die DigCompSat-Statements [16, S. 154].

Methodik: Adaption der Evaluationsmetrik [29, S. 5] auf unser Anwendungsfall und Implementation als Quality Gate. Der Mechanismus «AI Judge» wird zur Qualitätsprüfung eingesetzt.[22]




Abbildung 53 – Beispiel wie ein Modell eine Antwort im Bezug auf die Frage bewertet. In unserem Anwendungsfall wurden Parameter «Clarity, Relevance, Original Meaning, Difficulty» bewertet.

Resultat: Die Evaluationsmetrik wird mit einem fixen Threshold versehen und dient als Quality Gate für die angereicherten Aussage und grundlegenden Qualitätsüberprüfung. Die Metrik besteht aus den Parameter *Clarity, Relevance, Original Meaning, Difficulty*. Mit einer Likert Skala von 0 bis 5 wird das angereicherte Statement auf jeden Parameter durch OpenAI evaluiert. Für die Parameter *Clarity, Relevance, Original Meaning* muss Threshold ≥ 3 erreicht werden und für *Difficulty* variiert der Threshold auf Basis des «Personal Profile».




Abbildung 54 - Regulierung der Anreicherung durch Thresholds auf Basis der Parameter der Evaluationsmatrix

- Um syntaktische Unterschiede von Originalstatement und dem angereicherten Statement zu messen, wird die Cosine Similitarity in Verbindung mit TF-IDF (Term Frequency-Inverse Document Frequency) verwendet. Es ermöglicht die Ähnlichkeit der Texte in Bezug auf die Häufigkeit der Wörter in den Dokumenten zu berechnen.
- Um die semantische Ähnlichkeit von Original Statement und angereichertem Statement zu vergleichen wird die Cosine Similarity des Embeddings gemessen.

```
# RATE STATEMENT WITH CURRENT PARAMETERS
async def evaluate_statement_with_llm(original_statement, enriched_statement):
    prompt = (
        f"Original Statement: {original_statement}\nEnriched Statement: {enriched_statement}\n"
        "Evaluate the enriched statement based on clarity (0-5), relevance for context (0-5), "
        "retention of original meaning (0-5), ""and difficulty (0-5).")
    response = llm.predict(prompt)
    evaluation = response.strip()
    return evaluation

# HELPER FUNCTION
def extract_scores(evaluation):
    lines = evaluation.split("\n")
    scores = {"clarity": 0, "relevance_for_context": 0, "original_meaning": 0, "difficulty": 0}
    patterns = {
        "clarity": r'clarity\s*:\s*(\d)',
        "relevance_for_context": r'relevance for context\s*:\s*(\d)',
        "original_meaning": r'original meaning\s*:\s*(\d)',
        "difficulty": r'difficulty\s*:\s*(\d)'
    }

    for line in lines:
        for key, pattern in patterns.items():
            match = re.search(pattern, line, re.IGNORECASE)
            if match:
                scores[key] = int(match.group(1))
    return scores

# DIFFICULTY OF STATEMENT IN RELATION OF USERS PROFICIENCY
async def check_difficulty_threshold(proficiency, difficulty):
    thresholds = {
        "Beginner": (1, 2),
        "Intermediate": (2, 3),
    }
```

```

        "Advanced": (3, 5)
    }
    min_difficulty, max_difficulty = thresholds.get(proficiency, (0, 5))
    result = min_difficulty <= difficulty <= max_difficulty
    return result

# ENTRYPOINT WITH PARAMETERS FOR ENRICHMENT
async def regenerate_until_threshold(context, original_statement, proficiency, user_id, settings_id,
question_id, statement_length, prompt_type):
    attempt_count = 0
    enriched_statement = None
    enriched_statement_history = []

    # LOOP UNTIL STATEMENT MEETS NEEDED CONDITIONS
    while True:
        attempt_count += 1

        # POSSIBILITY TO USE DIFFERENT PROMPTS
        if prompt_type==1:
            enriched_statement = await enrich_statement_with_llm_prompt_type1(
                context, original_statement, statement_length)

        if prompt_type==2:
            enriched_statement = await enrich_statement_with_llm_prompt_type2(
                context, original_statement, statement_length)

        # EVALUATE THE STATEMENT WITH LLM
        evaluation = await evaluate_statement_with_llm(original_statement, enriched_statement)
        scores = extract_scores(evaluation)

        # CALCULATE QUALITY METRICS
        readability_metric = await calculate_readability(enriched_statement)
        cosine_tfidf = await cosine_similarity_tfidf(question_id, original_statement,
            enriched_statement)
        cosine_embedding = await cosine_similarity_embedding(question_id, original_statement,
            enriched_statement)

        enriched_statement_history.append({
            "cosine_tfidf": cosine_tfidf,
            "cosine_embedding": cosine_embedding,
            "readability_metric": readability_metric,
            "question_id": question_id,
            "original_statement": original_statement,
            "enriched_statement": enriched_statement,
            "evaluation": evaluation,
            "attempt_count": attempt_count})

        # CHECK THRESHOLDS - RETURN OR CONTINUE
        if (scores['clarity'] >= 3 and scores['relevance_for_context'] >= 3 and
            scores['original_meaning'] >= 3 and
            await check_difficulty_threshold(proficiency, scores['difficulty'])):
            return original_statement, enriched_statement, evaluation,
                attempt_count, enriched_statement_history

        # RETURN THE STATEMENT AFTER 10 ROUNDS
        if attempt_count >= 10:
            logger.warning(f"Exceeded maximum attempts ({attempt_count},
                with {enriched_statement_history}). Returning current enriched statement.")
            return original_statement, enriched_statement, evaluation, attempt_count,
                enriched_statement_history

```

Source Code 18 - Anreicherung mit Profil

Results

Select a Job Role:

Senior Software Engineer

Profile Details:

Job Role: Senior Software Engineer

Age: 40

Years of Experience: 15

Digital Proficiency: Advanced

Primary Tasks: Software Architecture Design, Mentoring Junior Developers, Full-Stack Development

Improvement Areas: AI/ML Integration, Cloud Security

Education: Master's Degree in Computer Science

Hobbies: Mountain Biking, Video Game Development

Career Goals: To transition into a CTO role in a tech startup.

Challenges: Keeping up with the latest trends in AI and machine learning.

Learning Style: Reading documentation and hands-on coding challenges

Enrich Self-Assessment

Question Id:

18

Random Statement:

I know how to use cloud services (e.g. Google Drive, Dropbox, and OneDrive) to share my files.

Enriched Statement:

As a Senior Software Engineer, I adeptly employ cloud platforms like Google Drive, Dropbox, and OneDrive for effective file sharing.

Cosine TfIdf:

0.20906411339484124

Cosine Embedding:

0.782850980758667

Evaluation:

Clarity: 5 Relevance: 5 Retention of Original Meaning: 5 Difficulty: 3

Attempts to reach threshold: 3

Abbildung 55 - Enrichment von Random Statement mit Difficulty Level 3, welches den Threshold nach 3 Versuchen erreicht hat.

Erkenntnisse und Konsequenzen für das Projekt:

- Die subjektive Qualitätsprüfung ist positiv und die Methodik mit der Evaluationsmetrik liefert eine Basis für das Enrichment.
 - Die Cosine Simliarity in Verbindung mit Embeddings, Mass für die semantischen Ähnlichkeit, erzielt moderate Werte im Bereich von 0.50, bis zu Werten von 0.90, welche eine starke semantische Übereinstimmung bestätigen.
 - Cosine Simliarity in Verbindung mit TF-IDF, Mass für syntaktische Unterschiede, erzielt durch die geringe Textlänge ein niedriges Resultat. Die syntaktischen Unterschiede haben kleiner Priorität als die semantischen Unterschiede.
 - Die Evaluationsmetrik ermöglicht es Vergleiche zu erstellen innerhalb einzelner Statements und zwischen verschiedenen «Personal Profils».
-

Diskussion

- Um eine repräsentative Aussage über die Qualität der generierten Statements zu erhalten, muss das Verfahren mit verschiedenen «Personal Profils» getestet werden und die verschiedenen Einflussgrößen aufeinander abgestimmt werden.
 - Die Qualität der Statements ist nicht allein von der Evaluationsmetrik der Generierung abhängig. Einflussgrößen in Bezug auf die Qualität ist die vorgegebene Länge des generierten Statements, der Inhalt des Originalstatement, der Kontext des «Personal Profil», das Prompt Verfahren, die trainierte Version des LLM-Models (mit unbekannten Trainingsparametern) und zuletzt der subjektiven Interpretation von Benutzer: innen.
 - Die Aufteilung auf die Vue-Komponenten erlaubt es strukturiert zu arbeiten und Anpassungen gezielt vorzunehmen.
-

13.6 Journal 5

Kalenderwoche (KW) 45 – 46, Projektwoche (PW) 8 – 9, 5.11 bis 18.11.24

Im fünften Sprint wurde das Frontend überarbeitet und Komponenten abgestimmt.

Die erhobenen Qualitätsmetriken der Generierung wurden ins Frontend übertragen, zusammen mit der History der generierten Statements. Für den Benutzertest wurde eine erste Variante für die Integration der Meta Questions erarbeitet. Weiter wurde die Basis für die asynchrone Generierung der Statements implementiert.

Anwendungsversuche

- Anwendungsversuch 9 – Asynchrones Generieren der Statements und Streaming ins Frontend

Anwendungsversuch 9: Asynchrones generieren der Statements und Streaming ins Frontend.

Ziel des Anwendungsversuchs: Um Benutzer: innen fortlaufend Statements zu liefern, muss der Mechanismus asynchron funktionieren.

Einflussgrößen der Generierungszeit sind die Interaktion mit OpenAI mit der Prompt Verarbeitung, die Berechnung der Qualitätsmetriken und das Speichern in der Datenbank.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs:

In Sprint 4 im Anwendungsversuch 8 wurde der Generierungsmechanismus implementiert und auf einzelne Statements angewendet. Der Mechanismus muss sowohl lokal wie auch auf dem Cloud-Deployment fehlerfrei funktionieren und in Resultate in adäquater Zeit liefern.

Methodik:

Die Streaming Response[30] in FastAPI ermöglicht das asynchrone Streamen von Daten an den Client. Anstatt die gesamte Antwort auf einmal zu generieren, wird die Antwort in kleineren Teilen (Chunks) geliefert. Die Funktion besteht aus einer asynchronen Generatorfunktion, die in einer Streaming Response eingebettet ist. Die Streaming Response verwendet die Generatorfunktion, um Daten schrittweise zu senden. Mit jedem Aufruf von yield wird ein einzelnes Datenstück erzeugt und unmittelbar an den Client übertragen.

Weitere Anpassungen an der Datenbank und Refactoring am Code, um Enrichment mit History zu speichern.

Resultat:

```
questions = await get_all_questions_with_translations(lang)

amount_of_questions = user_settings['amount_of_questions']
first_n_statements = questions[:amount_of_questions]

# OPEN ASYNC GENERATOR FUNCTION
async def result_stream():
    try:
        # GENERATE THE NEEDED AMOUNT
        for question_data in first_n_statements:
            statement = question_data["item"]
            question_id = question_data["question_id"]

            try:
                # ENRICH STATEMENT AND DELIVER HISTORY
                original_statement, enriched_statement, evaluation,
                attempt_count, enriched_statement_history = await regenerate_until_threshold(
                    context, statement, profile['digital_proficiency'], user_id, settings_id, question_id,
                    statement_length, prompt_type
```

```

    )

    # CALCULATE QUALITYMETRICS FOR FINAL STATEMENT
    readability_metric = await calculate_readability(enriched_statement)
    cosine_tfidf = await cosine_similarity_tfidf(question_id, original_statement,
    enriched_statement)
    cosine_embedding = await cosine_similarity_embedding(question_id, original_statement,
    enriched_statement)

    # SAVE TO DATABASE WITH HISTORY
    try:
        enriched_statement_obj = EnrichedStatement(
            cosine_tfidf=cosine_tfidf,
            cosine_embedding=cosine_embedding,
            readability_metric=readability_metric,
            question_id=question_id,
            original_statement=original_statement,
            enriched_statement=enriched_statement,
            evaluation=evaluation,
            attempt_count=attempt_count,
            enriched_statement_history=enriched_statement_history,
            user_id=user_id,
            settings_id=settings_id
        )
        saved_id = await save_enriched_statements(enriched_statement_obj)
        logger.info(f"Enriched statement saved successfully with ID: {saved_id}")
    except Exception as db_error:
        logger.error(f"Database save failed for question ID: {question_id} |
        Error: {db_error}", exc_info=True)
        raise

    # PREAPARE JSONL FOR STREAMING
    result = {
        "cosine_tfidf": cosine_tfidf,
        "cosine_embedding": cosine_embedding,
        "readability_metric": readability_metric,
        "question_id": question_id,
        "original_statement": original_statement,
        "enriched_statement": enriched_statement,
        "evaluation": evaluation,
        "attempt_count": attempt_count,
        "enriched_statement_history": enriched_statement_history,
        "settings_id": settings_id,
        "user_id": user_id,
    }

    # YIELD PAUSES THE GENERATOR AND TRIGGER THE STREAMINGRESPONSE
    yield f"{json.dumps(result)}\n"
    logger.info(f"Successfully streamed question ID: {question_id}")

    except Exception as enrichment_error:
        logger.error(f"Error processing question ID: {question_id} |
        Error: {enrichment_error}", exc_info=True)
        yield f"{json.dumps({'error': str(enrichment_error)})}\n"

    except Exception as stream_error:
        logger.error(f"Error in the result streaming process: {stream_error}", exc_info=True)
        raise

    finally:
        logger.info("Streaming process completed.")

# STREAM AS STREAMING RESPONSE AS JSONL
return StreamingResponse(result_stream(), media_type="application/jsonl")

```

Source Code 19 - Code Asynchrone Generation

Erkenntnisse und Konsequenzen für das Projekt:

- Mit Streaming Response in FastAPI ist es möglich fertig generierte Statements weiter zu verarbeiten.
 - Die Weiterverarbeitung im Frontend wird nicht blockiert und die Statements können parallel zur Generierung bereits hinsichtlich Qualität von Benutzerinnen bewertet werden.
-

Diskussion

- Das Streaming funktioniert lokal einwandfrei. Im Cloud-Deployment wird jedoch nicht immer die erwartete Anzahl an Statements zurückgegeben. Dieses unvorhersehbare Verhalten muss weiter analysiert werden.
 - Die parallele Kombination aus Generierung durch das LLM und die Bewertung (Survey) durch Benutzer: innen im Frontend benötigt viel Ressourcen – dies erfordert genaues Monitoring unseres Cloud Environments in Bezug auf Fehler.
-

13.7 Journal 6

Kalenderwoche (KW) 47 – 48, Projektwoche (PW) 10 – 11, 18.11. bis 4.12.24

Der Fokus im sechsten Sprint lag auf der Erstellung eines Drafts für User Tests, der Trennung des Applikations-Flows für Respondent und Admin sowie der Implementierung von Features wie der Anzeige von Unterschieden zwischen Original- und Personalized Statements, Meta-Questions und dynamischen Benutzer: innen-Einstellungen. Bugfixes umfassten Verbesserungen des Streamings. Die Resultatseiten wurden grundlegend für Benutzer: innen und für Administratoren mit Filtermöglichkeiten implementiert.

Anwendungsversuche

- Anwendungsversuch 10 – Testumgebung und Auswertungsmöglichkeit für Administrator
 - Anwendungsversuch 11 – Resultatseite für Benutzer: innen und Admin
-

Anwendungsversuch 10: Testumgebung und Auswertungsmöglichkeit für Administrator

Ziel des Anwendungsversuchs: Benutzer: innen erstellen ihr «Personal Profile», generieren und bewerten die persönlichen Statements und die die Resultate werden geliefert.

Der Administrator benötigt eine zusätzlich Testumgebung mit individuellen Konfigurationsmöglichkeit für eigene Experiment und Einsicht in die Qualitätsmetriken.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: Zum Zeitpunkt nach Anwendungsversuch 9 wurden die Funktionalitäten weitgehend implementiert, aber noch nicht zentral zusammengeführt.

Methodik:

in Control Panel für den Administrator wird die grundlegende Bearbeitung der Settings implementiert, die Einsicht in Qualitätsmetriken gesteuert und bietet Konfigurationsmöglichkeiten die Statements als für ein SA zu verwenden oder in einem Benutzertest zu bewerten.

Resultat:

Die Testumgebung für den Administrator erlaubt es den Ablauf des Benutzertests zu durchlaufen. Weiter sind folgende Möglichkeiten implementiert, um eigene Tests durchzuführen:

- **Konfiguration der Settings**
 - Verwendung von Default Profilen oder Verwendung des Chatbots
 - Anpassung der Aussagenlänge mit 3 Optionen (1,3x, 2x, 3x Aussagenlänge)
 - Prompttype auswählen (Zero-Shot-Prompt oder Few-Shot-Prompt)
- **Konfigurationsmöglichkeiten für Benutzertest**
 - Anpassung und Zusammenstellung der Meta Questions für die Bewertung der Statements
 - Randomisierung der Statements im Benutzertest
 - Ein-/Ausblendungen von Statement Labels
 - Ein-/Ausblendung der Meta Questions
 - Wechsel zu Antwortmöglichkeiten für ein SA
- **Analysemöglichkeiten**
 - Visuelle Anzeige/Überprüfung von Unterschieden von Original und generiertem Statement
 - Einblendung der Qualitätsmetriken Cosine Simliarity TF-IDF, Cosine Similarity Embedding, Flesch Reading Ease, Flesch Kincaid Grade, Gunning Fog

Control Panel

General Settings

Choose Language

en

User Settings

Setting 805 - Senior Softw

Enrichment Settings

Choose Statement Length

Short (1.3x characters length)

Choose Prompt Type

Basic Prompt

Start Self Assessment

Statement-Survey Settings

Statement Visibility

Show Original and Person

Statement Selection

Selectable Statements

☐ Show Statement Labels
 ☒ Randomize Statement Positions
 ☐ Show Difference Between Original and Personalized Statements

Response Settings

Answer Visibility

Hide Answers

Meta-Survey Settings

☒ Activate Meta Questions

Meta Survey Visibility

Show After Statement Selc

Save Requirement for Meta Questions

Must Answer Meta Questic

Display Meta Data

☐ Show Meta Data

Execute Settings

Apply Settings

Abbildung 56 - Control Panel für den Administrator mit Konfigurationsmöglichkeiten

DigiBot Meta Survey Builder

+ Add New Question

1. Which statement is easier to understand?

Edit Delete

Details

2. Which statement is easier to read?

Edit Delete

Details

3. Which statement offers greater detail?

Edit Delete

Details

4. Which statement fits your profession?

Edit Delete

Details

5. Which statement is helpful for a self-assessment?

Edit Delete

Details

6. Please select the option on the furthest right. (B)

Edit Delete

Details

Save to File

Abbildung 57 - Anpassung der Meta Questions für den Benutzertest

1. Browsing, searching and filtering data, information and digital content

Select your preferred statement:

1/1

A

B

Enriched Statement

Aware that **various** search engines **yield diverse** results, influenced by commercial **elements**, **impacting the data's integrity**.

Original Statement

I know that different search engines may give different search results, because they are influenced by commercial factors.

Meta Data

Question ID: 1

Original Statement: I know that different search engines may give different search results, because they are influenced by commercial factors.

Enriched Statement: Aware that various search engines yield diverse results, influenced by commercial elements, impacting the data's integrity.

Evaluation:

Clarity: 4

Relevance for Context: 5

Retention of Original Meaning: 5

Difficulty: 3

Cosine Embedding: 0.7016000151634216

Cosine TF-IDF: 0.2853

GunningFog Index, Education Level, : 21.4, (7–8: Easy for teenagers, 9–12: Standard, 13–15: Difficult, 16+: Very Difficult)

Flesch_kincaid_grade, (U.S. Grade Level): 13.1, (Grade 5–8: Easy, Grade 9–12: Moderate, Grade 13–14: Difficult, 15+: Very Hard)

flesch_reading_ease, (Text Readability 0-100): 29.86, (90–100: Very Easy, 60–89: Standard, 30–59: Difficult, 0–29: Very Hard)

Attempt Count: 1

Abbildung 58 - Analysemöglichkeit der der generierten Statements

Erkenntnisse und Konsequenzen für das Projekt:

- Es können eigene Konfigurationen vorgenommen werden und Tests durchgeführt werden.
- Die Umsetzung der Testumgebung ermöglicht es dem Administrator die grundlegende Funktionalität während der Entwicklungsphase zu prüfen, und selbst auszuprobieren.
- Während laufenden Benutzertests können parallel die Antworten der Benutzer:innen interpretiert werden.

Anwendungsversuch 11: Resultatseite für Benutzer: innen und Admin

Ziel des Anwendungsversuchs: Benutzer: innen bewertet die persönlichen Statements sowohl durch die Meta Fragen und markieren die Expertise in Bezug auf das Statement.

Nach abschliessen des Fragebogens soll die Benutzer: innen eine Übersicht über die Antworten erhalten.

Der Admin benötigt dieselbe Oberfläche um sowohl die Resultate der einzelnen Benutzer: innen sowie die aggregierten Antworten zu analysieren.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs:

Im Sprint 5 wurden die Meta Fragen des Benutzertest mit dem Streaming der Statements verbunden.

Nach Abschluss des Tests werden Benutzer: innen auf die Resultat Seite weitergeleitet, und erhalten eine visuelle Darstellung der Resultate.

Methodik:

Datenbankerweiterungen um die Antworten der Benutzer: innen zu speichern.

Einbinden von Chart.js[31]. Chart.js ist eine JavaScript-Bibliothek und bietet flexible Möglichkeiten um interaktive, ansprechende Charts zu erstellen.

Resultat:

«Resultpage» für Benutzer:innen

Benutzer:innen erhalten eine Übersicht über die «Digitale Kompetenz» gemäss der Selbsteinschätzung.

Die weiteren Diagramme enthalten eine Übersicht über die Antworten der Metaquestions sowie den Average über alle Fragen.

Thank you for your participation!

Enter your completion code on Prolific to show that they've completed your study:

C1F0KO0Z

Survey Results

Below, you will find your results.

- Original (orig.): The original DigComp statement.
- Personalized (pers.): The DigComp statement personalized with your profile.

Further information about the DigComp assessment can be found [here](#).

Dashboard

Thank you for filling out the self assessment. Check your personal scores and your results.

Scores by category

Topic	Category	Total Score
Information and data literacy	Browsing, searching and filtering data, Information and digital content	8
Information and data literacy	Evaluating data, information and digital content	10
Information and data literacy	Managing data, information and digital content	3

Overall scores by topic

Topic	Total Score	Percentage
Information and data literacy	21/40	53%

Digital Competence


Digital Competence: 53%

Digital Competence areas


Information and data literacy: 53%

Your personal scores

Which statement do you prefer more?



Which statement is easier to understand?




Which statement is easier to read?




Which statement offers greater detail?



Which statement fits your profession?



Which statement is helpful for a self-assessment?



Please select the option on the furthest right. (B)



«Resultpage» für Admin

Der Admin hat Zugriff auf eine aggregierte Ansicht über alle Benutzer:innen.

Der Admin kann nach einzelnen Benutzer:innen und weiter nach einzelnen «User settings» und Fragen filtern.

Results

Select User

Select Setting

Select Question

All Users

All Settings

All Questions

User 90

User 2

User 80

User 93

User 89

User 86

User 96

User 99

User 77

User 91

User 104

User 20

User 88

User 75

User 82

User 16

User 55

User 27

User 22

Which statement do you prefer more?



Which statement is easier to understand?



Which statement is easier to read?



Which statement offers greater detail?



Which statement fits your profession?



Which statement is helpful for a self-assessment?



Please select the option on the furthest right. (B)




Abbildung 59 - «Resultpage» für Benutzer: innen und aggregierte Ansicht mit Filtermöglichkeit für Admin. In diesem Stadium wurde zusätzlich noch die Selbsteinschätzung zur «Digitalen Kompetenz» der Benutzer: innen erfasst – dies wurde für den aktuellen Prototypen vorerst ausgeblendet.

Erkenntnisse und Konsequenzen für das Projekt:

- Die visuelle Interpretation der Antworten bietet dem Admin eine schnelle Möglichkeit, während und nach einem Test, ein erstes Fazit zu ziehen.
Benutzer: innen wird ebenfalls die Möglichkeit geboten die eigenen Antworten zu interpretieren und signalisiert den Abschluss des User Test.
-

Diskussion

- Das «Control Panel» und die zusätzlichen Konfigurationsmöglichkeiten für den Administrator sind sehr hilfreich für Erweiterungen an der Applikation. (Bspw. neue Prompt-Techniken können so mit minimalem Aufwand ergänzt oder ausgetauscht werden und verfügbar gemacht werden.)
 - Für eine vertiefte Auseinandersetzung mit den Resultaten können die Daten aus der Datenbank als CSV bereitgestellt werden, um zusätzlich die Qualitätsmetriken zu analysieren.
 - Im Sprintmeeting wurde beschlossen die Befragung zur «Digitalen Kompetenz» der Benutzer: innen im ersten Schritt wegzulassen.
Primär ist das Ziel im ersten Schritt eine Aussage über die generierten Statements zu treffen. In unserem User Test, mit Profilerstellung durch den Chatbot (Median 15 Minuten), werden erst nur 14 Statements aus der Rubrik «Information and data literacy» einfließen.
Die Kombination der Bewertung im gleichen Survey ist für die Benutzer: innen anspruchsvoll und zeitaufwändig und kann für Verwirrung sorgen.
Die Befragung zur «Digitalen Kompetenz» ist für Benutzer: innen interessant, wenn Statements aus weiteren Rubriken einfließen, um einen persönlichen Querschnitt über die verschiedenen Kategorien zu ziehen.
 - Die Anpassung der Zeichenanzahl von 150, 250, 350 Zeichen, verändern die originalen Statements zu stark.
Das Enrichment der Statements wird nun prozentual zur Länge des Originalstatement angepasst. (1.3x, 2.0x, 3.0x)
-

13.8 Journal 7

Kalenderwoche (KW) 49 - 50, Projektwoche (PW) 12 - 13, 4.12. bis 18.12.24

Im siebten Sprint wurden das Konzept für den Benutzertest erarbeitet. Es wurden sechs Testgruppen mit verschiedenen Konfigurationen erfasst und die Applikation für einen Benutzertest mit Online-Plattform Prolific vorbereitet. Um Bias im Benutzertest zu reduzieren und eine besser User Experience zu gewährleisten wurden der Benutzertest überarbeitet und fortlaufend verbessert. Im Chatbot wurde die Validierung der Antworten mit AI eingefügt.

Anwendungsversuche

- Anwendungsversuch 12 - «Personal Profile Builder» - Validierung einfügen
-

Anwendungsversuch 12: «Personal Profile Builder» - Validierung einfügen

Ziel des Anwendungsversuchs: Definieren einer Evaluationsmöglichkeit für Antworten von Benutzer: innen im «Personal Profile Builder». Damit der «Personal Profile Builder» einen Mehrwert gegenüber herkömmlichen Inputfeldern generiert, müssen die Antworten in Bezug auf die Fragen einem Qualitätscheck unterzogen werden. Dem Benutzer: innen muss ein Feedback bereitgestellt werden, wie Antwort verbessert werden kann, damit ein genaueres «Personal Profile» angelegt werden kann.

Zeitpunkt, Kontext und Abhängigkeit des Anwendungsversuchs: In Sprint 4 wurde die Implementation des Chatbot umgesetzt und in den Programmfluss integriert. Im aktuellen Anwendungsversuch wurde AI hinzugefügt für die Validierung der Antworten.

Methodik:

Kombinierte Validierung der Eingaben für unterschiedliche Fragen:

- Typprüfung - Sicherstellen, dass die Eingaben dem erwarteten Datentyp entsprechen (Int, String)
- Kohärenzprüfung - Länge und Struktur von Texten wird geprüft (z. B. „aaa“ wird erkannt und abgelehnt)
- LangChain-Validierung - KI-gestützte Analyse welches qualitative Feedback liefert, das über einfache Typ- oder Kohärenzprüfungen hinausgeht:
 - Adaption der Evaluationsmetrik [29, S. 5] für den «Personal Profile Builder» und Implementation als Quality Gate für einzelne Fragen.

Resultat:

Fragen des Chatbots

```
questions_new = [  
    {'id': 'job_role', 'prompt': 'What is your job description?', 'expected_type': 'str'},  
    {'id': 'job_domain', 'prompt': 'Which best describes the broader category or area of your role within the organization? (e.g., Teaching, IT Support, Counseling, Research, Administration, Student)', 'expected_type': 'str'},  
    {'id': 'years_experience', 'prompt': 'How many years of experience do you have? Please provide a full number.', 'expected_type': 'number'},  
    {'id': 'digital_proficiency', 'prompt': 'How would you rate your digital proficiency? Answer with Beginner, Intermediate or Advanced.', 'expected_type': 'str'},  
    {'id': 'primary_tasks', 'prompt': 'What are your primary tasks? (List specific tasks separated by commas)', 'expected_type': 'sentence'},  
]
```

Source Code 20 - Das «Personal Profile» wird mit folgenden Fragen gebildet

Evaluationsmetrik für KI gestützte Analyse

Die Evaluationsmetrik für die KI- gestützte Analyse besteht aus den Parametern *Completeness*, *Clarity*, *Credibility*.

Es wird ein Threshold als Quality Gate (Initial ein Threshold von ≥ 3) definiert. Mit einer Likert Skala von 0 bis 5 wird jede Antwort von Benutzer: innen durch das KI-Model (in diesem Fall GPT-4, bereitgestellt durch LangChain) auf die drei Parameter geprüft.

Im «Personal Profile Builder» wird bei der Prüfung ein Bewertung und ein Feedback von LangChain (OpenAI) verlangt auf jeden der drei Parameter *Completeness*, *Clairty*, *Credibility*.

Wenn ein Threshold nicht erreicht wird, wird das Feedback für Benutzer: innen aufbereitet und in den Chat-Bot-Dialog eingebunden.

KI-gestützte Feedbacks

Für einfache Fragen, welche eine kurze Antwort erwarten, wurde das Feedback nochmal zusammengefasst:

- Bei Frage 1,2 («Job description», «Job domain») wurde das Feedback der drei Parameter nochmals zusammengefasst, um eine natürlichere Konversation zu garantieren. (Abbildung 27)
- Bei Frage 5 («primary tasks») wird das vollständige Feedback aller drei Evaluationsparameter zurückgegeben. So erhalten Benutzer: innen ein genaues Feedback um ihre Antworten zu verbessern. (Abbildung 28)

Profile Builder

Progress: 1 / 5 questions answered



Welcome!
Let's build your profile.



What is your job description?

job description ?



Your answer lacks detail, clarity, and credibility. To improve, you should provide a comprehensive, clear, and believable description of your job.

marketing assistant



Which best describes the broader category or area of your role within the organization?
(e.g., Teaching, IT Support, Counseling, Research, Administration, Student)

Send

Abbildung 60 – Durch die Validierung werden Antworten im Bezug auf die Frage geprüft und Benutzer: innen Feedback erstattet.

Profile Builder

Progress: 4 / 5 questions answered

How would you rate your digital proficiency? Answer with Beginner, Intermediate or Advanced.

Intermediate

What are your primary tasks? (List specific tasks separated by commas)

content creation for social media, going out with friends

I noticed some areas for improvement:

- You should list more tasks related to your work or responsibilities. 'Going out with friends' is not a professional task.
- Your answer is clear but could be made more professional.
- 'Going out with friends' does not sound credible as a primary task in a professional context.

Abbildung 61 - Durch die Validierung werden Informationen welche nicht zum persönlichen «Personal Profile» passen (im Beispiel Marketing Assistant), kritisch geprüft. «Primary Tasks» welche nicht zum angegebenen Job Profil passen werden hier gefiltert. Es wird eine Verbesserung der Antwort erwartet.

```
# Auzug aus den Logs
'summarization': "Please focus on providing more work-related tasks. Make sure your tasks are professional and credible. Eliminate non-professional activities like 'going out with friends' from your list of primary tasks."}
INFO:src.routers.digibot_profile_builder:Checking completeness: 2 against threshold 3
INFO:src.routers.digibot_profile_builder:Score 2 for completeness does not meet threshold 3
INFO:src.routers.digibot_profile_builder:{
  'completeness': "You should list more tasks related to your work or responsibilities. 'Going out with friends' is not a professional task.",
  'clarity': 'Your answer is clear but could be made more professional.',
  'credibility': "'Going out with friends' does not sound credible as a primary task in a professional context."}
INFO:main:Response status code: 200
INFO: 127.0.0.1:52852 - "POST /api/chat-profile-builder HTTP/1.1" 200 OK
```

Source Code 21 – Log's zeigen die Evaluierung der Antwort «Content creation for social media, going out with friends». Für die Parameter *completeness*, *credibility* wird der Threshold von 3 nicht erreicht und das Feedback für Benutzer: innen aufbereitet und in den Dialog eingefügt.

Erkenntnisse und Konsequenzen für das Projekt:

- Bei Fragen 3, 4 («years_experience», «digital_proficiency») wird nur die Typprüfung und Kohärenzprüfung angewendet.
 - Bei Fragen 1, 2, 5 («Job description», «Job domain» und «primary tasks») wird zusätzlich die KI-basierte Validierung angewendet. Der Chatbot ist so in der Lage Antworten, welche nicht zur Frage und den bisherigen Kontext passen, zu filtern.
 - Das KI-gestützte Feedback, der drei Evaluationsparameter, musste bei Frage 1,2 («Job description», «Job domain») zusammengefasst werden. Das ungefilterte Feedback ist, in Erwartung auf die kurze Antwort, zu detailliert.
 - Bei Frage 5 («primary tasks») ist das ungefilterte Feedback erforderlich. Die Details geben wertvolle Hinweise wie die Antwort verbessert werden kann, damit der Threshold erreicht wird.
-

Diskussion

- Die KI-gestützte Validierung erfordert eine sorgfältige Abwägung der Thresholds. Bei Erhöhung des Thresholds wird vom Benutzer: innen eine sehr viel detaillierte Antwort erwartet.
Es gilt dies in Bezug auf jede einzelne Frage zu prüfen und individuell zu setzen.
 - Weiter muss beachtet werden dass die Bewertungen nicht deterministisch sind, was viel manuelles Testen erfordert in Bezug auf die gesetzten Werte.
 - Die KI-gestützten Feedbacks dienen als Brücke zwischen einfacher Validierung (z. B. Typprüfung) und einer inhaltlichen Analyse. Durch weiteres Promptengineering können die Feedbacks weiter verfeinert werden, um dem Nutzer noch gezieltere Hilfestellung zu bieten.
 - Die Natürlichkeit des Feedbacks kann durch Anpassung des Prompts weiter verbessert werden.
 - Die Validierung umfasste im Benutzertest eine Korrekturrunde. Nach der zweiten Antwort wird die Antwort gespeichert, damit im Benutzertest die Benutzer: innen nicht stecken bleiben, oder den Test abbrechen.
-